


学号: S15040552



长春理工大学
Changchun University of Science and Technology

硕士学位论文(毕业)论文

基于贝叶斯理论移动机器人 SLAM 技术研究

研究生姓名: 孙博雅

类别、领域: 控制工程

二〇一八年四月

分类号： TP24

密 级： 可公开

U D C : 621.3

编 号：

基于贝叶斯理论移动机器人 SLAM 技术研究

RESEARCH ON SLAM TECHNOLOGY OF MOBILE ROBOT BASED ON BAYESIAN THEORY

学位授予单位及代码： 长春理工大学 (10186)

类别领域名称及代码： 控制工程 (085210)

研 究 方 向： 机器人测控技术

申请学位级别： 工程硕士

指 导 教 师： 白雪梅 副教授

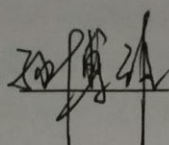
研 究 生： 孙博雅

论文起止时间： 2016.10—2018.04

长春理工大学硕士（或博士）学位论文原创性声明

本人郑重声明：所呈交的硕士（或博士）学位论文，《基于贝叶斯理论移动机器人 SLAM 技术研究》是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

作者签名：

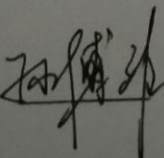


2018年6月8日

长春理工大学学位论文版权使用授权书

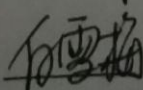
本学位论文作者及指导教师完全了解“长春理工大学硕士、博士学位论文版权使用规定”，同意长春理工大学保留并向中国科学信息研究所、中国优秀博硕士学位论文全文数据库和 CNKI 系列数据库及其它国家有关部门或机构送交学位论文的复印件和电子版，允许论文被查阅和借阅。本人授权长春理工大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，也可采用影印、缩印或扫描等复制手段保存和汇编学位论文。

作者签名：



2018年6月8日

导师签名：



2018年6月8日

摘 要

机器人学是一门将传感、人工智能等复杂多领域交互在一起的学科，不仅涉及人类的方方面面并代表着一个国家前沿科技的领先水准。本文将在贝叶斯理论基础上对移动机器人 SLAM 问题展开研究并在其理论框架内构建数学模型，重点分析数据关联及状态估计两大核心问题。

为了提升移动机器人 SLAM 问题中数据关联度，本文提出在基于联合相容算法上通过层次聚类进行多层次数据关联的算法。通过层次聚类将全部观察值放置于一个大簇中，依据环境划分为小类簇别，同时利用联合相容及最近邻数据关联算法获得局部关联结果，最后从中选定联合相容度最高的匹配对作为最后关联结果。通过仿真对比得出此方法可以明显降低错误关联率并同时缩短运行时间，非常适用于具有多特征点的环境。

针对 CKF 算法在 SLAM 问题中伴随特征点增多，容积点易偏离预想轨迹致使状态估计产生较大误差的缺点，本文提出在容积卡尔曼滤波前提下利用预估值及平方根因子于更新阶段重新确定采样容积点，通过容积变换获得系统的统计特性，再结合新预估观测值改进状态估计，进而提升算法精度做到在高度非线性条件下较小失真。为验证算法准确性，将其在三类维度下仿真对比分析，可以得出该算法能够大大提升机器人位姿精确度。本文最后将在所提算法基础上进行定位与构图的仿真对比分析。

关键词：SLAM 贝叶斯 特征点 精度 容积点

ABSTRACT

Robotics is a subject that interacts in complex fields such as sensing and artificial intelligence. It not only involves all aspects of human beings, but also represents the leading level of a national frontier technology. In this paper, the SLAM problem of mobile robot is studied on the basis of Bayesian theory and the mathematical model is constructed in its theoretical framework, which leads to two core problems of data association and state estimation.

In order to improve the efficiency of data association operation in the robot SLAM problem, a hierarchical clustering algorithm based on the Joint Compatibility Branch and Bound algorithm is proposed in this paper. By hierarchical clustering, all the observation values are placed in a large cluster, and the environment is divided into small clusters according to the environment. At the same time, the local correlation results are obtained by combining the joint compatibility and the nearest neighbor data association algorithm. Finally, the matching pair with the highest joint compatibility is selected as the final correlation result. Through simulation comparison, it is concluded that this method can significantly reduce the false correlation rate and shorten the running time, which is very suitable for the environment with multiple feature points.

In order to solve the problem that the CKF algorithm increases with the increase of the feature points in the SLAM problem and the volume point is easily deviated from the expected trajectory, resulting in the large error of the state estimation, this paper proposes that the volume Calman filter is used to redetermine the sample volume point by the predictive value and the square root factor in the update stage, and the volume transformation is used to obtain the statistical characteristics of the system. Combined with the new estimated value, we can improve the state estimation and further improve the accuracy of the algorithm, so that we can achieve less distortion under highly nonlinear conditions. In order to verify the accuracy of the algorithm, we compare it in three dimensions, and we can conclude that the algorithm can greatly improve the pose accuracy of robot. In the end, the simulation and comparison between location and composition will be done based on the algorithm mentioned above.

Key words: SLAM Bayes characteristic points precision volume point

目 录

摘 要

ABSTRACT

目 录

第一章 绪 论	1
1.1 引言	1
1.2 移动机器人及 SLAM 研究现状	2
1.3 移动机器人发展趋势	4
1.4 内容安排	4
第二章 基于贝叶斯理论机器人 SLAM 系统分析	6
2.1 SLAM 系统总体结构	6
2.2 系统详细介绍	6
2.2.1 移动机器人传感器	6
2.2.2 特征提取	9
2.3 基于贝叶斯理论移动机器人 SLAM 问题分析	9
2.3.1 移动机器人 SLAM 问题数学描述	10
2.3.2 移动机器人 SLAM 关键问题分析	13
2.4 本章小结	13
第三章 移动机器人 SLAM 数据关联研究	14
3.1 SLAM 领域数据关联问题数学模型	14
3.2 基于改进 JCBB 的数据关联算法	17
3.3 仿真对比分析	19
3.4 本章小结	21
第四章 基于改进 CKF 算法 SLAM 问题研究	22
4.1 UKF 算法	22
4.2 CKF 算法	24
4.3 S-CKF 算法	26
4.4 I-CKF 算法	29
4.5 仿真对比分析	30
4.6 本章小结	36
第五章 基于 CI-CKF 方法 SLAM 问题实现	37
5.1 移动机器人 SLAM 仿真平台的构建	37
5.2 仿真对比研讨	41
5.3 本章小结	43
第六章 总结与展望	44
6.1 全文总结	44
6.2 工作展望	44
致谢	46
参考文献	47

第一章 绪 论

1.1 引言

移动机器人作为自主运行的机械装置，在接受人类智慧的同时也能根据原定技术原则及预先编排的程序进行运行操作。主要用于在将来辅助及替代人类进行工作，如建筑业、手工业、零售业或者危险的工作等。

国内对于移动机器人的定义为，移动机器人是一类具有与生物相模拟具有一定只能水平的自动化机械，例如感应能力、动作能力、协作能力及统筹策划能力，是一类具备顶级灵活的自主化机械。

移动机器人是作为顶级整合计算机、机械电子、仿生科学及控制论的结果。其不仅在农业类、手工业类及建筑类都可以应用，且在军事领域也有十分重要的应用。现阶段国内外已对机器人概念实现统一。一般情况下，移动机器人是依靠自身行动力及控制水平从而进行操作的一类机器这种说法是普遍认可的。美国机器人协会在联合国认可下实现对机器人的总体定义，即移动机器人是一类可进行编程及多种用途应用，且可进行材料运输、零件、工具的机器；或者进行各种任务从而具备可以变化及编程运行的专门系统。

在移动机器人分类领域，国内外没有统一标准，按控制方式或按负载重量或按结构划分都有可能，下面简单对移动机器人进行划分：

操作型移动机器人：一般此类机器人是指可以进行自主控制，拥有一定数量自由度且可重复编程，也可以自由运动，且在自动化系统也可以进行应用。

程控型移动机器人：一般指已有一定顺序设定，需要按设定要求进行操控移动机器人的机械类操作；

示教再现型移动机器人：预先教导移动机器人运行动作，再输入工作程序，进而使机器人自主进行作业；

数控型移动机器人：移动机器人通过输入数值及话语示教后进行操作控制；

感觉控制型移动机器人：机器人的运行操作是通过各类传感器进行获取；

适应控制型移动机器人：可以尽快适应周围环境的改变从而自由控制机器人本身行动；

学习控制型移动机器人：此类机器人会具备一定的学习能力且积累工作经验，并将所得经验应用于日常工作领域；

智能移动机器人：基于人工智能来进行操作的机器人。

最近几年，移动机器人伴随着人工智能及移动传感的不断发展正逐渐将信息技术完好融合。基于此种概念的融合了自律、网络化、数据终端化的移动机器人在世界范围内具备领先技术的情况下，不断获得数据信息及应用操作，进而发展了数据驱动型

类创新。移动机器人在制作、服务类不同领域内牵动创造新类型附加值的时候，还能在各类信息转达及日常信息流通等领域带来更大改变的重要装置。

在以往生活中，移动机器人主要代指具有驱动系统、智能操控系统及传感器等重要元素的机器。然伴随着时代变化，数字化及云计算及人工智能类技术的演进，部分移动机器人也可以通过智能操控系统驱动机器人运行而非必须具备驱动系统并可自由通过互联网访问世界各地的信息。在未来，移动机器人随着物联网的演进，单单依靠智能控制便可在各个不同场景自由应用。这样一来，必须具备三大总要因素的机器人定义也会发生变化即未来机器人会具备更为广泛的概念。例如，智能家居及手机，无人驾驶汽车等都会成为移动机器人之一。

1.2 移动机器人及 SLAM 研究现状

移动机器人具备灵活操作性，充分提升生产率及提高产品质量，使劳作条件得以提升等从而获取广泛使用。只是，近阶段所说的移动机器人灵活性主要是指在反复重复编程的情况下，其工作环境是不发生改变的，即此类机器人一般被人们广泛称之为“操作手（Manipulator）”。移动机器人的智能同人类将摸索空间领域及扩展活动范围视为重大进步的标志相同，其智能也充分表现在运行空间的多少上。研究者为了增强移动机器人对于环境之适应水平，也是适应人们不断提升的对机器人操作水平的精准度的要求即为了获取更大的独立操作能力。

移动机器人的性能受多种因素影响，其中自主式移动机器人之复杂度及计算技术水平的限制性是最主要原因，此类机器人之智能将主要表现在具备感应（Sensing）、决策（Decision-making）及行动（Acting）等基本能力。依据基本能力相继实现的先后不同，一般可分为三种常规体系构造：行为系统（Behavior system）、分层递阶结构（Hierarchical architecture）及黑板系统（Blackboard system）。

移动机器人依据受到的约束的不同，其中控制系统可以分为完整系统即以位形变量显式代数方程进行描述的系统；非完整系统定义为约束条件是不完全可积之微分方程。依据现在人工智能及计算机研究阶段，“自主性”并非指代所有环境中都具备适应性良好而是指一定划分环境内的目的任务而言的通用型机器人。

现在应用到的轮式构造因为其和地面产生相对滑移等的原因使得机器人灵活性降低，使之在繁杂的环境（Cluttered environment）中不适合运行，即移动机器人走入家庭化的步伐大大减小。当使用全方位的运行构造使得移动机器人可以方便的前行及转弯等可以提升机器人的操作简单化及灵活性。虽然移动机器人可以进行感应、决策及操作，但是相对于人类而言，机器人远不如人类的认知。基于传感器的反射操作及知识的非无意识行动相结合，将储存知识及传感内容相结合可以构造新的内容构造体系。

移动机器人主要研究领域多种多样，包含传感器技术、机械、信号处理、人工智能、控制及计算机技术等科学研究。所以与之相关的研究学科需要密切关注，依据与

移动机器人相关的这些学科的现阶段发展水平从而敲定机器人之研究方向。

伴随着计算机及人工智能的研究水平的进展，机器人的探讨研制获得了越来越多的瞩目及投入，智能自主机器人伴随计算机技术及人工智能的长足进步已经成为该领域内的重要探研热点及方向，其中移动机器人 SLAM 问题更是其热点研究问题。在许多未知环境领域内，机器人无法应用全局定位系统从而进行定位，并且预先获取机器人的所处环境的地图几乎是无法实现的。那么此时机器人便需要在方位无法确定条件下进行自主定位及导航，这便是移动机器人之同时定位与地图构建（SLAM）问题。关于 SLAM 的研究方面获得了更多瞩目的目光及投入，智能自主式机器人变成其领域内至关重要的方向及投入点。其中机器人的定位及地图构建为自主式移动机器人的重要研讨问题。在环境已知的状态下移动机器人的定位及在已经明确移动机器人方位的地图构建已经在不断研究突破提升中。机器人可以在本身方位无法确认情况下，在陌生环境内构建地图，并且用于地图进行自主定位及导航。这便是机器人之同时定位和地图创建（SLAM）问题，此问题最早是 Smith Self 及 Cheeseman 提出，也同时认为其是真正实现移动机器人整体自动的核心领域。

现阶段 SLAM 解决办法可以分为两种：一种是基于概率模型之办法，另一种是非概率模型办法。其中完全 SLAM、FastSLAM、压缩滤波等解决方法便为基于卡尔曼滤波之 SLAM 办法。SM-SLAM、data association、扫描匹配、模糊逻辑等方法都是基于非概率模型办法。其中 Elfes 及 Moravec 在地图表示方法中提出了栅格地图法，将大环境划分成许多大小一样的栅格，指出全部栅格是否有障碍物存在，后来 Elfes 做出了进一步探讨。

在 SLAM 问题中经常应用到的是由 Smith 和 Cheeseman 提出的扩展卡尔曼滤波算法（Extended Kalman Filter, EKF）。其主要是利用泰勒级数对非线性之整体模型及测察模型进行展开，进而经过卡尔曼滤波算法对模型进行处理。在 EKF-SLAM 算法上，强敏利提出在其基础上应用迭代算法即 IEKF 算法提出相应改进，此算法将迭代算法与 EKF 算法相结合进而将移动机器人之非线性偏差校正，并提升了定位的准确性。随后吕太之在于外部干扰测验对比的基础上，利用膨胀方位偏差的抗干扰 EKF-SLAM 运算方法，提升了该运算方法之鲁棒性。但在线性化之进程内扩展卡尔曼滤波算法只是将运用泰勒级数展开的高次项舍弃，那么在需要高精度的定位环境中，则无法达到所追求的理想效果。并且在运算过程中需要将雅可比矩阵进行推导运算，会加大运算量及时间复杂度。

无迹卡尔曼滤波算法（Unscented Kalman Filter, UKF）由 Julier 及 Uhlmann 提出。经过选择不同权值之 Sigma（采样点）进而伴随非线性函数传递，通过 UT 转换获得随机变量之统计特征。无迹卡尔曼滤波算法在其基本框架内，可以促使定位精确度在相同情况下到二阶水平并同时降低了非线性方程转换至线性化所生成的偏差。利用协方差矩阵之平方根将协方差矩阵进行替代传递，此方法由 Merwe 及 Wan 在数学方法上推导而成。经过验证，此算法可以有效运用到 SLAM 问题操作中。许多研究学者在平

方根无迹卡尔曼滤波基础上，提出通过转变采样点进而进行采样的方式，进而提出一类比例较小偏度单行进行采样之运算方法，将运算过程中的运算量降低，并且同时提升了实时性。然而伴随此算法的缺点也显而易见，在无迹卡尔曼滤波算法中期协方差矩阵可能会非正定，那么就会相应对滤波器的性能造成影响。

Arasaratnam 和 Haykin 两人提出了一种新型非线性系统状态预估算法即容积卡尔曼滤波算法 (Cubature Kalman Filter, CKF)。容积卡尔曼滤波算法在容积原则内选择一组对应之容积点，将其通过加权操作获得随机变量之统计特征。容积卡尔曼滤波算法与无迹卡尔曼滤波算法相比较而言，两者都降低了非线性方程线性化所生成的偏差，但容积卡尔曼滤波算法运算量相对较小，并且其滤波更加稳定的特性被更多的研究者所认可。

1.3 移动机器人发展趋势

(1) 移动机器人由于将向家庭及服务类行业进军，所以机器人本身需要提升微型化及灵活性进而可以在陌生复杂环境中运行。

(2) 高速型-对于室内机器人而言，运行速度并没有特别要求，但是机器人若在室外移动操作的话，那么即需要在速度方面得到提高才可适应未来发展需要。

(3) 良好的人机交互-人类需要一个有效通道进而和移动机器人来沟通交流以便移动机器人可以良好的为人类服务，即称之为良好的人机接口，而目前强力发展的计算机多媒体已为其提供了完美平台。

(4) 安全性良好-移动机器人首先具备的就是不能对人类有所损害。机器人走入千家万户首先需要遵守 Issac Asimov 针对移动机器人所提出的“三大戒律”，即一，机器人不可以损害人类或者在人类被害时刻旁观不顾；二，移动机器人需要服从输入命令，除非与首发戒律相矛盾；三，机器人需要保护自申安全，除非与一、二戒律相矛盾。

(5) 产业化-如果理念不具有深远的发展能力，且无法给社会带来充足社会效益就无法获取社会的帮扶进而无法得到研究学者的关注。即将理论与实际联系在一起的纽带即为此种关注度，进而可以将科学技术转换为生产发展力，则形成产业化才是移动机器人之必行之路。

1.4 内容安排

本文对移动机器人 SLAM 问题进行了详细探讨研究，主要内容分为如下六章。

第一章为本文所研究内容的意义以及相应背景，叙述了移动机器人及 SLAM 问题的国内外研究现状及发展趋势并介绍本文的主要贡献和结构安排。

第二章对移动机器人的 SLAM 系统结构进行了详细分析，并在贝叶斯理论基础上对移动机器人 SLAM 问题进行了数学建模，提出影响其系统运行的两大关键问题即数据关联及状态估计问题。

第三章首先列举了一些经常应用到的数据关联算法，在其基础上提出了一种基于联合相容算法应用层次聚类提升其关联精确度的算法，并将其与其他算法进行了仿真对比分析，得出其优于其他算法的结果，且此算法更适应于具有多个特征点的复杂环境。

第四章针对状态估计问题进行了详细探讨，首先介绍了 UKF 及 CKF 的算法原理，其后在 S-CKF 基础上提出运用 Iterate 算法构成 I-CKF 算法，并在三种维度下进行仿真对比分析，最后得出 I-CKF 算法不论在时间或运算精度上都优于其他算法，可以有效缩减状态估计复杂度。

第五章率先将坐标系模型、里程计模型等仿真实验平台所需要的移动机器人系统模型进行搭建，在此基础上构建仿真操作环境，将总体改进后的算法与其他算法进行详细仿真对比。

第六章总结全文主要研究内容和本文所做主要贡献，并做出今后研究展望及方向。

第二章 基于贝叶斯理论机器人 SLAM 系统分析

本章节将主要介绍 SLAM 系统的整体结构及在贝叶斯理论基础上对 SLAM 系统进行分析，为后面进程提供大致框架。

2.1 SLAM 系统总体结构

时代进程下，在 SLAM 领域已涌现大量研究人员对其进行分析探索，而追其根本都是围绕着同一个框架进行展开摸索，如图所示。

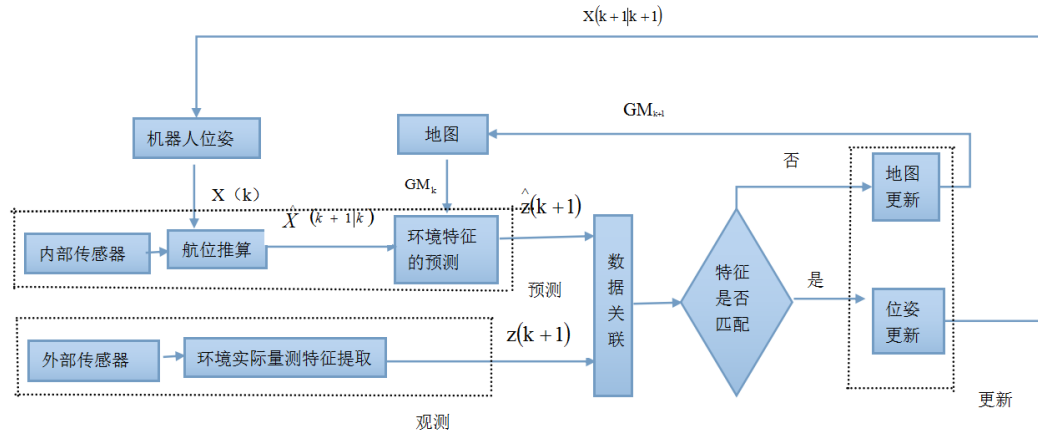


图 2.1 移动机器人同时定位与地图创建框架

航位推算即为在了解当前时刻方位的情况下，经过测查移动之距离及方位。即知晓移动机器人 $k-1$ 时间点位姿 $X(k-1)$ 、陀螺仪等内部传感器及数学模型来推算 k 时刻位姿状态 $X(k|k-1)$ 。

地图特征的预测即为整体依据位姿推算结果预计位置及目前环境中的特征信息，通过计算产生每个特征的估计集合 $\hat{z}(k+1)$ 。

特征提取是对声呐等外部传感器测出的真实环境中的数据通过操作处理从而得出几何特征之集合 $z(k+1)$ 。

进一步为了确保信息的统一性，将特征估计结果 $\hat{z}(k+1)$ 和真实计量的几何特征 $z(k+1)$ 在数据关联方面进行匹配操作，整体依据最终结果将移动机器人位置状态重置：当结果为匹配就进行置换，否，即证明结果为新特征，并把新特征参入进环境地图内，从而实现置换更新。

2.2 系统详细介绍

2.2.1 移动机器人传感器

对于移动机器人而言，传感器起着至关重要的作用，也正是传感器的应用，移动机器人才拥有视觉、知觉等重要反馈能力。传感器主要分为内部传感器及外部传感器：

（1）内部传感器

当探测移动机器人本身状态时就会应用到内部传感器，内部传感器一般用来探测

位姿和方向角，此装置对于完成闭环控制等是必不可少的。机器人会依据此种类型传感装置对取得的数据及运动学模型将位姿推算演变，从而完成移动机器人的导航控制。经常在日常应用到的方法是在移动机器人的下方装配光电编码器码盘，机器人将运算通过光电编码器得出的脉冲数量在一定采样数据周期内从而取得移动机器人下方配置轮子的速率，依据在码盘中获取的速率及方向角便计算出移动机器人路程量来获取位姿状态。




图 2.2 光电编码器

应用光电编码器的最大效用是将大大降低预算成本及降低系统操作难度，将其码盘放置于移动机器人下方，则其运转度数便通过光电编码器的度数计算得到，从而得到机器人位姿改变量。如图 2.3 所示，当机器人下方轮子只进行滚动状态时， S_A 作为轮轴中心点滚动过的实际长度， S_C 为轮外随意一个定点以圆中心 O 随滚动经过的长度， S_A 应与 S_C 相等，即 $S_A = S_C$




图 2.3 轮子滚动示意图

假如应用的光电编码器是 N 线/转， ΔT 阶段内传感器受理 m 个信号， D 作为轮子半径，那么轮子运动过的转角度数 $\Delta\theta$ 则是：

$$\Delta\theta = \frac{2\pi m}{N} \text{ rad} \quad (2.1)$$

K_C 作为单位弧度的圆周长度则为：

$$K_C = \frac{\pi D}{2\pi} = \frac{D}{2} \quad (2.2)$$

则：

$$S_c = \frac{D\Delta\theta}{2} = \frac{\pi m D}{N} \quad (2.3)$$

假如 ΔT 作为从 $X(x_{k-1}, y_{k-1}, \theta_{k-1})$ 到姿态 $X(x_k, y_k, \theta_k)$ 的时间段（如图 2.4），依据 (2.3) 可以获得机器人左右两侧轮子位移长度，设为 Δd_L 及 Δd_R ，那么移动机器人经过的弧长是 $\Delta D_k = (\Delta d_L + \Delta d_R)/2$ ，而 $\Delta\theta_k = (\Delta d_R - \Delta d_L)/B$ 则作为偏转角度， B 是其间距。依据 ΔD_k 及 $\Delta\theta_k$ ，则可以得出其运动半径：

$$R_k = \frac{\Delta D_k}{\Delta\theta_k} \quad (2.4)$$




图 2.4 机器人航位推算示意图

从图中可以了解到，移动机器人最后推算的自定位模型是：

$$X(k) = f(X(k-1), u(k)) = \begin{bmatrix} x_{k-1} + R_k (\cos(\theta_{k-1} + \Delta\theta_k) - \cos(\theta_{k-1})) \\ y_{k-1} + R_k (\sin(\theta_{k-1} + \Delta\theta_k) - \sin(\theta_{k-1})) \\ \theta_{k-1} + \Delta\theta_k \end{bmatrix} \quad (2.5)$$

在公式中 $u(k) = (\Delta D_k, \Delta\theta_k)$ 为依据码盘获取的运动数据。在轮子空转（图 2.3）阶段， $S_c \setminus S_A$ ，在轮子处于被制动阶段，由于惯性继续滚动时，认为 $S_c \setminus S_A$ 。由此可知移动机器人位置确定是依据光电编码器实现，而且受路面情况、光电编码器精度的因素影响，并伴随着距离的拉长增加，计算精度会越来越弱，所以其应用在较短路程中较好，而在相对长距离行进时，就需要根据声呐等传感器获取外部数据，根据多传感器联合保证精准定位，促进移动机器人对环境的适应及智能化水平。

(2) 外部传感器

外部传感器的功用是感知及获取外部环境信息，根据这些传感器就能随时知道其运作环境，且可以依据运作境况修正策略，由此提升其环境适应及智能化水平。经常应用的传感器有超声波、红外、视觉传感器等。

激光测距雷达 (Laser Rangefinder) 是一类应用电磁波进行测查目标之方位的电子应用产品。它的主要功能为包括探索及查找目标：测查行进距离、方位及速度等运行参数；测查目标的发射率及主要形态等特征参数。传统雷达大致由接收、发射及后置信号处置这三部分及应用这三部分共同完成任务的构造构成，而激光雷达与传统雷达构造相同。但与传统雷达所不同的是，传统雷达一般是应用微波及毫米波段之电磁

波完成载波的雷达，而激光雷达是应用以光波段电磁辐射为基础的激光完成载波，其中其波长较微波及毫米波短许多。

超声波探测距离原理与雷达探测距离原理类似，主要是依据从接收器至超声波之间的时间差从而知道距离。超声波发射器是向着其中一个方向进行超声波发射，即刻进行计时，超声波在传播途中遇到妨碍物便即刻退回，一旦接收器接触到返回的超声波便立刻停止计时。（超声波之传播速度是 340m/s，依据计时所得的时间为 t ，便能计算出发射点到妨碍物之长度（ s ），即： $s=340t/2$ ）。

红外测距传感器为一类传感装置，为一种应用红外线作为介质的探测系统，探测范围广泛，其中路途时间极短，在国家防御、工商农业及现代科技领域得到广泛应用。此类传感器具备接收二极管及红外信号发射，红外测距传感器 LDM301 发射出红外光束直某物上后构成反射经过，进而传递回传感器后接收信号，而后应用 CCD 图像处置其时间差之数据信息，最后通过信号处理器运算出其间距离。

视觉系统（Stereo.Vision System）为将摄像机摄录到的画面进行图像处理，进而运算物品之特征量即重心、方位、面积及长度等元素，而后输出判断结论及数据信息的传感器。

从以上分析介绍中，可以知道各个不同传感器都有其潜在缺点，如果仅仅使用其中某一种类型传感器就会造成极大误差，若将多个传感器联合应用，则可有效避免过程中产生的诸多错误，并会极大增加数据精度。

2.2.2 特征提取

此处的特征提取即为外部传感装置获取的图像数据，用于决策每一个特征点是否隶属同个图像特征。其最终结果是将不间断的图像数据表达为用于计算机可以进行调整的离散点集合。目前，以用多个传感器来获得环境特征作为基础，将其匹配联合后使得移动机器人运行，这种方式对于进行移动机器人 SLAM 过程是最具优势的。环境特征主要涵盖平面体、点、线段、角、脊等，由于计算机视觉中对同类领域的探索，与其相对的特征值获取方式因此也较多。因为在实际环境运用里，整个运维整体的全面非结构化，实际环境的需求已经远远超出二维建模领域，因此获取三维特征值实行环境建模是探索的最重要方面。

2.3 基于贝叶斯理论移动机器人 SLAM 问题分析

近段时间以来，SLAM 问题被相关研究者分割为两种类别，都十分具备实际应用意义。两类之中一项是在线 SLAM 问题：在任意时间段都可以完整推算整体运行状态及特征地图。数学公式如下：

$$p(X_r(k), M | z(1:k), u(1:k)) \quad (2.6)$$

$X_r(t)$ 用于代表 k 时移动机器人态势， M 则代表特征地图态势， $z(1:k)$ 和 $u(1:k)$ 代表已测数据值及输入数据，因为需要在任一时刻都要预测该时刻移动机器人态势及修

正特征地图态势所以称之为在线 SLAM 问题。通常情况下此问题解决一般需要将过往时间段的观测值 $z(1:k-1)$ 及控制量 $u(1:k-1)$ 舍弃。

第二类被称之为全状态 SLAM 问题。在其问题中，不仅仅需要测算当时态势 $x(k)$ ，更需要测算整个运行系统的距离轨迹态势 $x(1:k)$ 及特征地图。数学公式如下：

$$p(X_r(1:k), M | z(1:k), u(1:k)) \quad (2.7)$$

在本文 SLAM 问题上将更加关注其实时性和可操作性，所以本文将主要探讨在线 SLAM 问题，一般此问题都需要应用贝叶斯滤波方法。

2.3.1 移动机器人 SLAM 问题数学描述

机器人定位经常使用贝叶斯方法进行描述：

$$\underbrace{p(\theta | X)}_{\text{后验概率密度}} = \eta \underbrace{p(X | \theta)}_{\text{最大似然概率}} \underbrace{p(\theta)}_{\text{先验概率密度}} \quad (2.8)$$

贝叶斯追其根本即运用最大似然函数及先验概率密度函数计算出与样本分布的后验概率密度相符函数，并计算其均值便会获取估计态势。

在移动机器人 SLAM 问题中运用此方法，即拥有多个特征点的陌生环境里的定位研究。如果以全局坐标系为前提，移动机器人状态 $X_r(k) = (X_r(k), y_r(k), \theta_r(k))^T$ ，k 时机器人坐标是 $x_r(k)$ 、 $y_r(k)$ ，而 k 时的角度为 $\theta_r(k)$ ，1~k 时机器人整体状态表示为 $X_r(1:k) = \{X_r(1), X_r(2), \dots, X_r(k)\}$ 。 $X_i = (x_i, y_i, c_i)$ 是路标位置坐标，其间 x_i 、 y_i 是全局坐标系中坐标， c_i 代表路标的关联序数。地图由 $M(k) = \{(X_1(k), X_2(k), \dots, X_N(k))\}$ 代表，N 是路程标记整体数量。k 时间段的控制载入数值为 $u(1:k) = \{u(1), u(2), \dots, u(k)\}$ ， $z(1:k) = \{z(1), z(2), \dots, z(k)\}$ 代表此时间段的观测值。 $n(1:k) = \{n(1), n(2), \dots, n(k)\}$ 为此时间段关联数值， $n(k) = \{c_1, c_2, \dots, c_N\}$ 代表 k 时关联成功的路标。那么加入数据关联的 SLAM 问题数学公式如下：

$$p(X_r(k), M(k) | z(1:k), u(1:k), n(1:k)) \quad (2.9)$$

在贝叶斯网络中 SLAM 问题描述表示如下图所示，在控制输入值的情况下机器人坐标从 $X_r(k-1)$ 到坐标 $X_r(k+1)$ ， $M(k) = \{X_1(k), X_2(k), \dots, X_N(k)\}$ 作为静态地图在各标点周围可以检测到其特征。假设移动装置态势已知，就可以获取地图里特征点之间相互关联。假设未获知移动装置态势，那么特征点则作为相互独立参数存在。

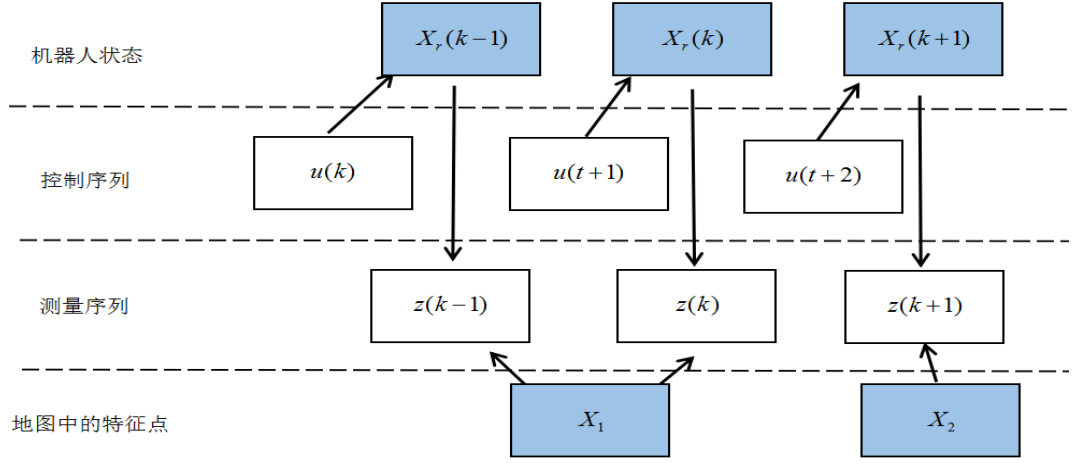


图 2.6 基于贝叶斯的在线 SLAM 过程

以贝叶斯理论为基础的 SLAM 问题，当控制输入量 $u(k)$ 时，移动机器人从 $X_r(k-1)$ 到 $X_r(k)$ 时，可由下式表示：

$$p(X_r(k) | X_r(1:k-1), z(1:k-1), u(1:k)) \quad (2.10)$$

检测模型是在 $X_r(k)$ 态势及地图 M_i 下，将匹配的概率模型进行校对，如下式：

$$p(z(k) | X_r(k), M(k), n(k)) \quad (2.11)$$

移动机器人的运动、观测模型一般可以表示为一阶马尔科夫过程，可以表示为：

$$p(X_r(k) | X_r(1:k-1), z(1:k-1), u(1:k)) = p(X_r(k-1), u(k)) \quad (2.12)$$

综合以上公式进行分解，得出递归公式：

$$\begin{aligned} & p(X_r(k), M(k) | z(1:k), u(1:k), n(1:k)) \\ &= \frac{p(z(k) | X_r(k), M(k), z(1:k-1), u(1:k), n(1:k)) p(X_r(k), M(k) | z(1:k-1), u(1:k), n(1:k))}{p(z(k) | z(1:k-1), u(1:k), n(1:k))} \end{aligned} \quad (2.13)$$

因为 $p(z(k) | z(1:k-1), u(1:k), n(1:k))$ 和 $X_r(k)$ 和 $M(k)$ 没有关联， η 定义为基本常数，那么

$$\begin{aligned} & p(X_r(k), M(k) | z(1:k), n(1:k)) \\ &= \eta p(z(k) | X_r(k), M(k), z(1:k-1), u(1:k), n(1:k)) \\ & p(X_r(k), M(k) | z(1:k-1), u(1:k), n(1:k)) \end{aligned} \quad (2.14)$$

将以上公式以马尔科夫方式简化：

$$\begin{aligned} & p(X_r(k), M(k) | z(1:k), u(1:k), n(1:k)) \\ &= \eta p(z(k) | X_r(k), M(k), n(1:k)) \underbrace{p(X_r(k), M(k) | z(1:k-1), u(1:k), n(1:k))}_A \end{aligned} \quad (2.15)$$

将上式 A 中公式进行分解可以得到：

$$\begin{aligned}
& p(X_r(k), M(k) | z(1:k-1), u(1:k), n(1:k)) \\
&= \underbrace{\int p(X_r(k), M(k) | X_r(k-1), z(1:k-1), u(1:k), n(1:k))}_{B} \\
& p(X_r(k-1) | z(1:k-1), u(1:k), n(1:k)) dX_r(k-1)
\end{aligned} \tag{2.16}$$

将上式 B 中公式进行分解可以得到:

$$\begin{aligned}
& p(X_r(k), M(k) | X_r(k-1), z(1:k-1), u(1:k), n(1:k)) \\
&= \underbrace{p(X_r(k) | M(k), X_r(k-1), z(1:k-1), u(1:k), n(1:k))}_C \\
& p(M(k) | X_r(k-1), z(1:k-1), u(1:k), n(1:k))
\end{aligned} \tag{2.17}$$

将上述 C 中公式以马尔科夫进行简化得到:

$$p(X_r(k) | M(k), X_r(k-1), z(1:k-1), u(1:k), n(1:k)) = p(X_r(k) | X_r(k-1), u(k)) \tag{2.18}$$

综上, SLAM 问题可以演变为如下:

$$\begin{aligned}
& p(X_r(k), M(k) | X(k-1), z(1:k-1), u(1:k), n(1:k)) \\
&= \underbrace{\eta p(z(k) | X(k), M(k), z(1:k-1), u(1:k), n(1:k))}_D \\
& p(M(k) | X(k-1), z(1:k-1), u(1:k), n(1:k)) \\
& \int \underbrace{p(X_r(k) | X_r(k-1), u(k)) p(M(k) | X_r(k-1), z(1:k-1), u(1:k), n(1:k))}_E \\
& \underbrace{p(X_r(k-1) | z(1:k-1), u(1:k), n(1:k))}_F dX_r(k-1)
\end{aligned} \tag{2.19}$$

将上述 D 中公式简化:

$$p(z(k) | X_r(k), M(k), z(1:k-1), u(1:k)) = p(z(k) | M(k), n(1:k)) \tag{2.20}$$

在上述 E 中因为 $M(k)$ 与 $u(k)$ 、 $z(k)$ 、 $n(k)$ 没有关联, 那么

$$\begin{aligned}
& p(M(k) | X_r(k-1), z(1:k-1), u(1:k), n(1:k)) \\
&= p(M(k) | X_r(k-1), z(1:k-1), u(1:k-1), n(1:k-1))
\end{aligned} \tag{2.21}$$

而 F 中 $X_r(k-1)$ 与 $u(k)$ 、 $n(k)$ 没有关联, 那么

$$\begin{aligned}
& p(X_r(k-1) | z(1:k-1), u(1:k), n(1:k)) \\
&= p(X_r(k-1) | z(1:k-1), u(1:k-1), n(1:k-1))
\end{aligned} \tag{2.22}$$

即 SLAM 问题之最终形式为:

$$\begin{aligned}
& p(X_r(k), M(k) | z(1:k), u(1:k), n(1:k)) \\
&= \eta p(z(k) | X_r(k), M(k), n(1:k)) \\
& \int p(X_r | X_r(k-1), u(k)) p(X_r(k-1), M(k-1) | z(1:k-1), u(1:k-1), n(1:k-1)) dX_r(k-1)
\end{aligned}$$

从最终简化公式可知，如需解决移动机器人 SLAM 问题，通过数据关联相关算法获取特征点关联情况 $n(1:k)$ 为首要问题。而后依据状态估计相关算法采用控制数据 $u(1:k)$ 及关联数据 $n(1:k)$ 、测算数据 $z(1:k)$ 便可计算出机器人方位。

2.3.2 移动机器人 SLAM 关键问题分析

依据上节在以贝叶斯理论为基础探讨移动机器人 SLAM 问题的数学描述中可以看出，通过观测得到的环境特征数据及运行控制量进行测算机器人的运行轨迹及特征点方位值是研究的重点探讨问题，而其中多维状态估计问题作为其理论基础。如需检测特征点时，特征点是否被判定已被监测也是主要探讨问题，而数据关联问题是其理论研究基础。

I. 数据关联问题

SLAM 问题的主要复杂性体现在两点：第一，伴随移动机器人的连续运行，填入总体地图内的监测特征点数目也愈渐增加，则对于 SLAM 问题中的数据关联就必须兼具处理冗杂特征及确时实现关联度准确性的能力。第二，相比较在目标追踪领域里关联度不会被前一时刻关联误差影响，而 SLAM 问题中数据关联误差会致使其后状态估计结果发散，通过对过去时间段发生的关联误差改正从而提升定位准确度。即数据关联准确度及时间复杂度在机器人 SLAM 问题研究中是至关重要的。

II. 状态估计问题

在 SLAM 问题里需要估计环境特征状态 $X_i(i=1,2,\dots,n)$ 及移动机器人状态 $X_r=(x_r, y_r, \theta_r)$ 。移动机器人状态 $X_i(i=1,2,\dots,n)$ 经二维坐标 x_r 、 y_r 及方位角 θ_r 构成，其中 i 作为其特征点坐标向量 $X_i=(x_i, y_i)$ 涵盖两个变量。如果总体具有 N 个数量特征点，则变量值便为 $2N+3$ 个，而任意变量则作为状态估计内维度，那么 SLAM 之状态估计问题就可以看做 $2N+3$ 维度的矢量。而在真实环境中可能会具有上千类总体特性，那么大部分计算存储容量将被多维状态估计占据，操作繁杂，也会对 SLAM 运算过程产生巨大的延迟性。在 SLAM 问题中状态估计问题是重中之重，即需要将确保精确度情况下，提升状态估计的速度。

2.4 本章小结

本章首先介绍了 SLAM 系统总体结构，并对其内部结构进行具体分析，而后简单介绍了贝叶斯办法在 SLAM 问题领域内的应用。从以上推导公式可知，如要解决移动机器人 SLAM 问题，必须要得到特征点的关联状况 $n(1:k)$ 。而后依据关联信息 $n(1:k)$ 及运行控制信息 $u(1:k)$ 及观测信息 $z(1:k)$ 应用多维状态估计之相关办法运算得到机器人的方位，继而本文提出了关于 SLAM 问题中的两个最为关键的问题即数据关联及状态估计问题。所以在本文下一章节将对数据关联方法进行具体分析并提出本文的数据关联方法。

第三章 移动机器人 SLAM 数据关联研究

在 SLAM 问题中, 解决传感器过去时间点与目前时间段测察的数据信息间的联系则为数据关联问题, 即找出测察值与特征点之间的关联状态。由于在 SLAM 过程中里程计的偏差致使机器人运行状态无法确定、特征点密度的改变等问题, 都会对数据关联度造成干扰, 其错误的关联结果将最终导致移动机器人定位及构图的失败。而在数据关联问题上, 有许多前人提出的计算方法, 如最近邻计算方法 (ICNN), 连续兼容最近邻算法 (SCNN), 多假设数据关联算法等。本章首先将构建相关问题数学模型, 并在前人研究基础上创建新型关联算法, 进而通过实验仿真将多种算法进行对比并验证本文所提算法的正确性及其主要优点。

3.1 SLAM 领域数据关联问题数学模型

在下面公式中, x 代表移动机器人在特征点为 n 时的态势 $\{f_1, \dots, f_n\}$, \hat{x} 是其估计态势, 设定其中 P 是估计的协方差矩阵:

$$\hat{x} = \begin{pmatrix} \hat{x}_R \\ \hat{x}_{f_1} \\ \vdots \\ \hat{x}_{f_n} \end{pmatrix} \quad P = \begin{pmatrix} P_R & P_{Rf_1} & \cdots & P_{Rf_n} \\ P_{Rf_1}^T & P_{f_1} & \cdots & P_{f_1f_n} \\ \vdots & \vdots & \ddots & \vdots \\ P_{Rf_n}^T & P_{f_1f_n}^T & \cdots & P_{f_n} \end{pmatrix} \quad (3.1)$$

我们将获取 m 个经装置在移动机器人顶部的激光传感器的测察数据 $\{z_1, \dots, z_m\}$:

$$z = \bar{z} + \sigma \quad \sigma \in N(0, R) \quad (3.2)$$

$$z = \begin{pmatrix} z_1 \\ \vdots \\ z_m \end{pmatrix} \quad S = \begin{pmatrix} R_{z_1} & \cdots & R_{z_1z_m} \\ \vdots & \ddots & \vdots \\ R_{z_1z_m}^T & \cdots & R_{z_m} \end{pmatrix} \quad (3.3)$$

在式中, \bar{z} 代表测察的理论性实际值, $H = \{c_1, \dots, c_i, \dots, c_m\}$ 代表关联假设数据, 其内 c_i 代表激光传感器测察数据 z_i 与特征点 f_{c_i} 的关联水平。我们将定义 \hat{z}_H 为预估观察值:

$$\hat{z}_H = h(\hat{x}) = h(\hat{x}_R, \hat{x}_{c_1}, \dots, \hat{x}_{c_i}, \hat{x}_{c_m})^T \quad (3.4)$$

其间 $h(\bullet)$ 作为移动机器人测察方程, 因为具备许多关联假设, 可由解释树模型进而表示, 如下图所示, 该解释树具有 k 层, 而其中所有层级的任一节点都可以称为该层的解释树, 并且都可以提取该层之前的所有数据关联结果。任何节点都具备 $n_i + 1$ 个分支, 而其相对应着测察值 z_i 的 $n_i + 1$ 种关联结果, 如需获得最佳关联方案, 则需进行 $\prod_{i=1}^k n_i + 1$ 次运算, 其中关联的优劣则经常以测察值与特征点的联合兼容性进行判断。

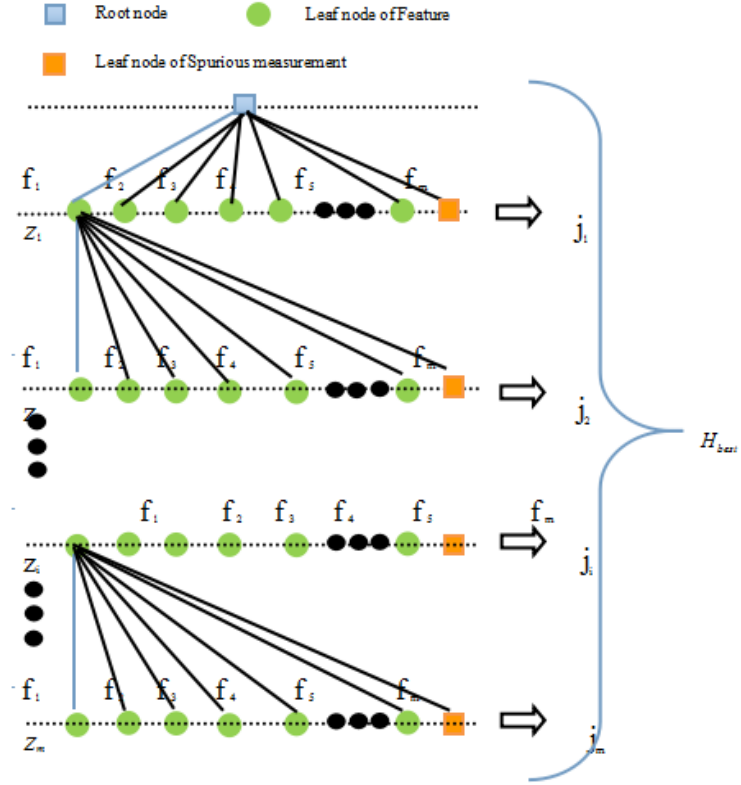


图 3.1 数据关联中的解释树模型

在 SLAM 领域探讨中，对于移动机器人运行及测察方程的干扰问题经常会使用高斯白噪声进行模拟。其中高斯分布的主要特征为量值区间为 $-\infty$ 至 ∞ ，即任意测察值都可以对其中任一特征点实行关联，那么这意味着其间运算量是非常庞大的。若首先在特征点的预计方位为轴心设置范围区间，以其内的测察值定为该特征点测察值，其中范围之限定决定于检验门限。门限过滤法对于解决降低关联假设数额具有非常大的作用，即可以有效降低关联假设的总体数量。

如以某一随机性变量代表其中一特征点的方位情况。经常设定随机变量 x 的预估值是 \hat{x} ， x 之测察预估值是 $\hat{z} = h(\hat{x})$ ，所谓门限范围之大小就是指对于 x 之测察值和预估值两者中的能容许之偏差的最大值。归一化信息——计算马氏距离可以用于检验门限。归一化平方新息即为新息向量之加权范数。假定测察值 z 及预估值 \hat{z} 整合的新息向量是 $v = z - h(\hat{x})$ ， v 之方差是 S ，归一化平方新息即为：

$$d = v^T S^{-1} v \quad (3.5)$$

其中 (3.5) 中 d 遵从自由度是 $\dim(v)$ 之 χ^2 分布。假设确定 δ 是置信度，那么以 χ^2 分布表为基础查找能获取在此置信度下的检测门限 γ ，那么如果

$$d < \gamma \quad (3.6)$$

d 与 γ 满足此种条件时，测察值 z 源于特征点 x 的结论正确。

数据关联法经常预先采用门限过滤来去掉较小概率的数据关联假设，下图 3.2 为

其基本过程，当测察值在以预估值 \hat{z} 为轴心之椭圆距离里方可称为此特征的关联假设。如果在特征点相对较繁杂的时刻预计会产生许多测察值在其距离范围中，即会造成不正确的数据关联结果，如图 3.3。为了降低数据关联的偏差性应最大程度缩小椭圆的大小，伴随而来的是有可能把准确关联结果排除在外。

其中具有数量较多的随机变量之设定校验也可以应用门限过滤方法，这一点需要着重强调，而全部随机变量的数目额度即为 χ^2 分布的维数。




图 3.2 数据关联中门限过滤法的描述图




图 3.3 难以确定数据关联的描述图

Singer 在门限过滤法基础上提出最近邻数据关联算法从而将门限方法中一个特征点需要与多个数量测察值进行匹配的问题解决。而最近邻数据关联算法的特征点之数据关联结果是在于门限范围里选取和此特征点预估值最近之测察值。其中“最近”是指在下式中定义的最小归一化平方新息：

$$c_i = \arg \min \{ f_j \mid d_{ij} \langle \gamma \rangle \} \quad (3.7)$$

上式中， c_i 代表其中第 i 个测察值之关联变量。如集合 $\{z_i \mid d_{ij} \langle \gamma \rangle = \emptyset\}$ ，那么就说明在测察值 z_i 上无特征点与之相关联，这时 $c_i = 0$ 。

如果在特征点密度较大数量较多的环境中，运用运算时间复杂度并不高但比较适宜在拥有较少特征点之环境内应用的最近邻数据关联方法会出现伴随着特征点的增多其累计误差也逐渐累积的情况。如图 3.3 中当测察值 z_i 在门限范围取值在 x_1 到 x_2 内时，此时应用最近邻数据关联算法则不能计算出测察值 z_i 之关联结果，不正确的数据关联结果便随之产生。

3.2 基于改进 JCBB 的数据关联算法

Neira 等研究者在基于最近邻数据关联算法方面即当环境中含有多个特征点的环境下匹配精度低问题的不断克服中，提出了 JCBB 算法即联合相容（Joint Compatibility Branch and Bound, JCBB）性校验数据信息的关联方法。此算法最先指出最近邻数据关联方法并未能够确保在地图内的全部特征点及观测值之联合相容性，其方法会伴随特征点数量密度及特征点方位的无法确定性加大，造成许多非正确性匹配数据关联结果出现。将同时间内全部特征点和测察值之间的关联假设之联合相容性进行校验则称其为联合相容性校验法，而最终的测察值之关联结果为其中相容性最大的关联假设。

$F_t = \{f_i | i=1, \dots, n\}$ 作为在环境中 t 时刻的 n 个环境特征点， $Z_t = \{z_j | j=1, \dots, m\}$ 代表 m 个通过传感器获取的测察值。 $H_k = \{c_1, c_2, \dots, c_m\}$ 代表 z_f 之第 k 个关联假设，其中第 j 个测察值和地图内特征点之关联结果表示为 c_j ， H_k 与一组测察值和特征点的关联对 $\{(z_1, f_{c_1}), (z_2, f_{c_2}), \dots, (z_m, f_{c_m})\}$ 相对应。方差矩阵和联合新息在 H_k 之关联设定下，经 (3.4) 式可以获得全部特征点之联合预估方位 \hat{z}_{H_k} ，即：

$$v_{H_k} = Z_t - \hat{z}_{H_k} \quad (3.8)$$

$$S_{H_k} = \nabla h_{H_k} P_{H_k} \nabla h_{H_k}^T + R_{H_k} \quad (3.9)$$

在上式中，观测误差方差矩阵为 R_{H_k} ， ∇h_{H_k} 是以一阶偏导数进而形成的矩阵即雅可比矩阵， \hat{F}_{H_k} 的预估方差矩阵为 P_{H_k} 。从而联合相容性可以作出定义：

$$D_{H_k} = v_{H_k}^T S_{H_k}^{-1} v_{H_k} \quad (3.10)$$

若 H_k 相容度较大即其中所容纳 F_t 内特征点数量相对较多。该算法最先假设门限 γ ，一般我们全部关联假设 $\{H_k | D_{H_k} > \gamma\}$ 即相容性大于 γ ，其中归一化平方新息定义为 D_{H_k} ，其遵从自由度是 $\dim(v_{H_k})$ 之 χ^2 的分布。在其中选定相容度最大的关联假设当作 Z_t 之关联选取值，则称此算法为联合相容算法——JCBB。




图 3.4 机器人测察距离内关联度不大的两组特征分布图

在诸多环境内，测察值具有相对显著的分布情况。在上图中可以清晰看到，移动机器人的测察范围左右两侧分别分布着两组测察值，其内 A 组及 B 组测察值之关联度并不大。若研究者把全部测察值联合于一起利用联合相容计算方法从而获得相容度最高的一组关联就将生成十分庞大的计算量。面对这样大的运算量，复杂度自然也会加大其时间复杂度，那么此种算法运用起来便并不简单。

本文将在前人研究基础上提出一种基于联合相容算法通过层次聚类进行多层次数据关联的算法，当移动机器人运行过程中，通过层次聚类算法将全部的测察值放置于一个簇中，进而依据环境情况划分为小类簇别。而后将每一个簇利用联合相容数据关联算法进而获得局部关联结果 Group. J，为了确保数据关联的鲁棒性，运算过程中我们也对所有簇内的测察值利用最近邻的数据关联方法获得局部关联结果 Group. I。每一次划分成更详细的簇表示为解释树中一层，其中 Group. I 及 Group. J 作为解释树之一层次内的两个节点。最后我们将从此解释树中选定联合相容度最高的匹配对作为最后之关联结果，本文将此种方法定义为 C-J 算法。

算法描述图如下图 3.5 所示：

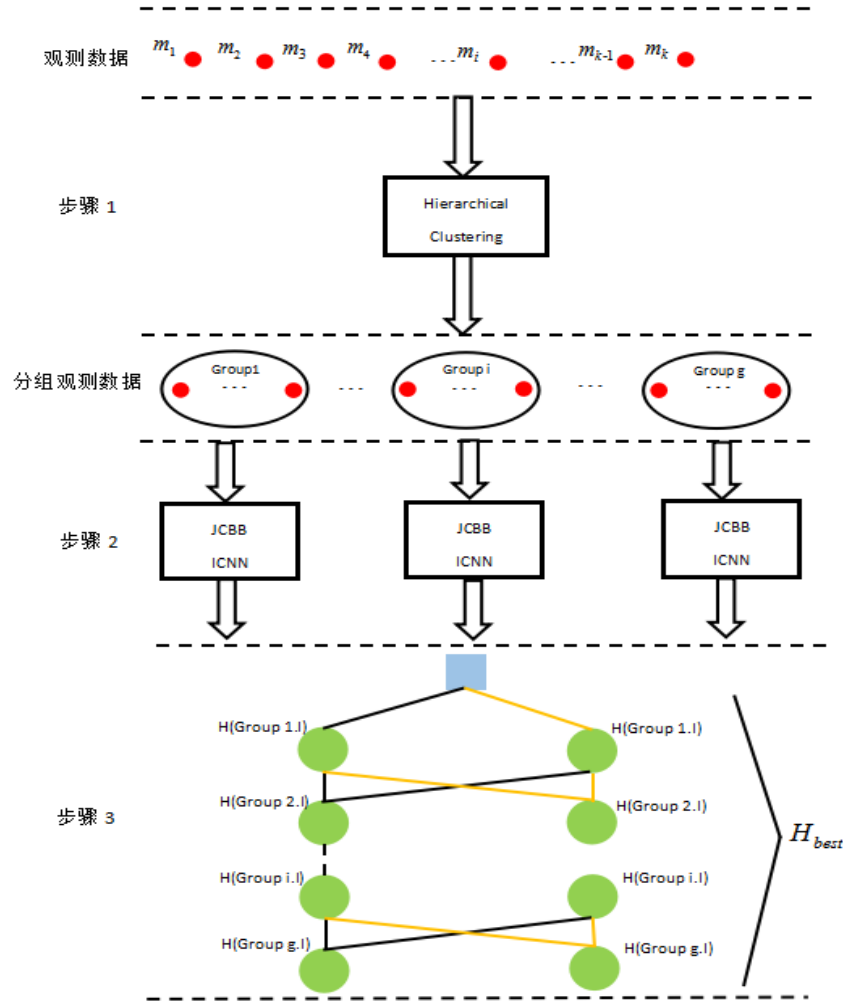


图 3.5 C-J 算法描述图

3.3 仿真对比分析

此次仿真的目的主要为将最近邻数据关联算法、联合相容数据关联算法及本文提出的 C-J 算法在 Neira 构建的 SLAM 仿真研究平台进行对比从而分析其各自的时间复杂度及关联准确性。将移动机器人放置于一个方形廊道，同时在机器人上配置可以测出廊道内全部特征点的激光传感器及里程计装置，最后利用扩展卡尔曼滤波之状态估计的计算方法从而预估移动机器人及特征点的方位情况。

下图 3.6 中为本次研究所应用的仿真实验环境。其中图内红色实心圆形标记代表特征点之实际方位，红色三角形标记代表移动机器人之运行路线，设定移动机器人从方位坐标点 $(0, 0)$ 处开始运行，以逆时针方向顺着方形轨迹运行 168 步总共运行长度为 40m。而数据信息采集将利用激光传感器进行，设定激光传感器所能采集到的最远距离是 3.5 米，假定所能勘测到的最大测察角度是 90° ，最小的测察角度是 -90° ，并且距离测察偏差遵从 0.1m 之高斯分布，测察到的角度偏差遵从 1.25 之高斯分布。首先设

置 536 个环境特征点，而后将移动机器人运行的每一步之累计误差数量及累计运动时长进行记录，而后降低环境特征数目至 328 个，为了考证该算法的鲁棒性，将此数目下的误差数量及累计算法运动时长进行记录。




图 3.6 数据关联仿真环境图

其中特征点数目为 536 个时，将三种算法即联合相容数据关联方法、最近邻数据关联方法及 C-J 数据关联算法之累积运行时间做出对比如下图所示。从此图中我们可以清晰看到三种算法中联合相容算法所用时长较其他两种算法多出许多，而最近邻数据关联算法与本文所提 C-J 算法则在时间领域优于联合相容算法仅为其七分之一左右，而其中的最近邻数据关联算法则伴随着运行步数其累积运行时间呈线性增长态势。

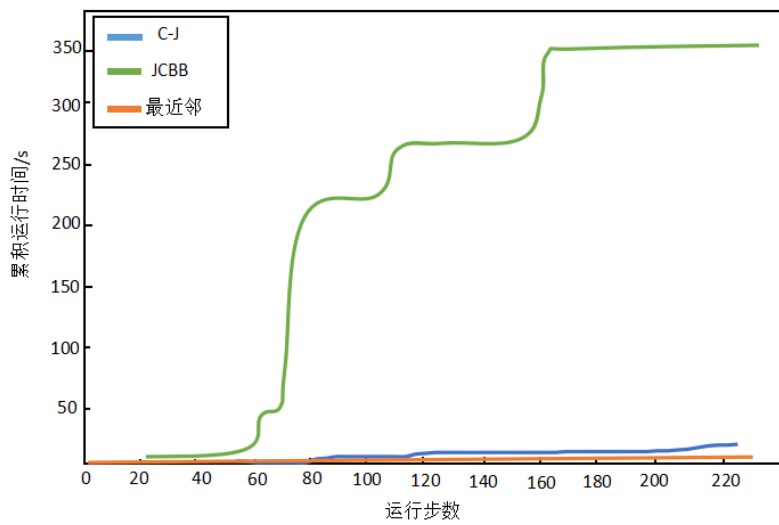


图 3.7 三种算法的累计运行时间对比图

在下图 3.8 中我们会看到随着运行步数的逐渐增多，最近邻数据关联算法逐渐显现弊端，其累计错误关联次数增长迅猛，而其他两种算法则较最近邻数据关联算法的误关联数量低出许多。




图 3.8 三种算法的累计误关联数量对比图

我们将特征点的总体数量降低，从而考证运算方法的鲁棒性及其效率，可以清晰看到 C-J 数据关联方法与联合相容方法的关联精确度均高于最近邻数据关联算法，而本文所提出的 C-J 算法伴随特征点数量的降低其累积时长则逐渐接近联合相容算法，即 C-J 数据关联算法可以适用于具备数量较多的特征点的环境内，其具体数据信息如下表所示：

误关联次数					算法运行时间		
特征点数量		关联次数					
		最近邻	JCBB	C-J	最近邻	JCBB	C-J
328	5099	567	16	8	0.043	3.83	3.92
360	5643	1397	28	37	0.055	5.64	4.49
408	6388	1675	125	146	0.061	19.87	6.17
456	7075	1963	26	112	0.065	30.56	6.52
536	8357	2407	92	65	0.092	329.43	11.16

表 3.1 数据关联算法仿真结果对比分析表

3.4 本章小结

本章节率先对数据关联问题进行数学建模，并介绍了一些经常应用到的数据关联运算方法。而后提出了一种基于联合相容算法通过层次聚类进行多层次数据关联的算法。在本章最后仿真对比最近邻、联合相容及提出的 C-J 数据关联算法运行所用时长及数据关联精度，可以看到 C-J 算法在将错误关联度降低的同时，运行时长也较短，普遍适合于具备特征点密度较高的环境内。

第四章 基于改进 CKF 算法 SLAM 问题研究

传感器勘测的偏差受移动机器人在运行时刻里程计的累积误差因素影响，所以本文决定采取以高斯滤波器为基础的相应理论研究对状态估计问题进行探讨分析。

4.1 UKF 算法

UKF (Unscented Kalman Filter) 即无迹卡尔曼滤波，为 UT 变换及标准卡尔曼滤波两者的结合。UKF 近似 n 维目标采样点的方式是加权点 δ ，运算 δ 点需通过非线性函数的传递，经过非线性状态方程从而获取变换后的滤波值，进而跟踪所定目标。

①UT 变换

UT 变换为使用一定数量额的参数支来近似某一高斯分布，它的实现原理是：将原来分布中依据某一原则提取一些点，利用提取点的平均值是协方差态势分布和原态势分布之平均值及协方差相同；把这些提取点非线性函数中代入，即可以获得非线性函数的点集，经过此点集即能获取转换后的均值及协方差。如下为其各阶段运算：

$$x_{k-1}^0 = m_{k-1} \quad (4.1)$$

$$x_{k-1}^i = m_{k-1} + \sqrt{N + \lambda} [P_{k-1}]_i \quad (4.2)$$

$$x_{k-1}^{i+n} = m_{k-1} - \sqrt{N + \lambda} [\sqrt{P_{k-1}}]_i, i=1, \dots, N \quad (4.3)$$

在上式中， $\lambda = \alpha^2(N + \kappa) - N$ 是比例系数。 α 取值一般介于 e^{-4} 至 1 之间， κ 经常取为 $3-N$ 。 P_{k-1} 由 Cholesky 分解得到平方根矩阵之第 i 列 $[\sqrt{P_{k-1}}]_i$ 。Sigma 的传达途径是：

$$x_k^i = f(x_{k-1}^i, u(k)), i=0, \dots, 2N \quad (4.4)$$

$X(k)$ 之平均值 m_k 及协方差 P_k 用转换后的 sigma 点样本的平均值及协方差进行叙述：

$$m_k \approx \sum_{i=0}^{2N} W_i^m \chi_k^i \quad (4.5)$$

$$P_k \approx \sum_{i=0}^{2N} W_i^p (\chi_k^i - m_k)(\chi_k^i - m_k)^T \quad (4.6)$$

W^m 是均值权重， W^p 是方差权重，运算过程如下：

$$W_0^p = \frac{\lambda}{N + \lambda} \quad (4.7)$$

$$W_0^p = \frac{\lambda}{N + \lambda} + 1 - \alpha^2 + \beta \quad (4.8)$$

$$W_i^m = W_i^P = \frac{1}{2(N + \lambda)}, i = 1, \dots, 2N \quad (4.9)$$

在上式中 β 是先验知识参数，优化为： $\beta = 2$ 。

②UKF 滤波器

依据上节描述，整体运行模型及测察模型如下式所示：

$$X(k) = f(X(k-1), u(k)) + \varpi(k) \quad (4.10)$$

$$Z(k) = h(X(k)) + v(k) \quad (4.11)$$

首先我们定义 k 时刻的态势 $X(k)$ 之平均值是 m_k ，方差是 P_k 。对比于 4.2.1 中公式定义可以得到下面的 UKF 滤波过程。

• 预估过程

1) sigma 点初始化：

$$x_{k-1}^0 = m_{k-1} \quad (4.12)$$

$$x_{k-1}^{i+n} = m_{k-1} - \sqrt{N + \lambda} [\sqrt{P_{k-1}}]_i, i = 1, \dots, N \quad (4.13)$$

2) 由整体的运行模型推导 sigma 点：

$$\chi_k^i = \underbrace{f(\chi_{k-1}^i, u(k))}_{\text{系统的运动模型}}, i = 0, \dots, 2N \quad (4.14)$$

3) 求出预估之平均值及方差：

$$P_k^- \approx \sum_{i=0}^{2N} W_i^P (\chi_k^i - m_k^-)(\chi_k^i - m_k^-)^T + Q(k-1) \quad (4.15)$$

• 校改过程

1) 依据态势预估之平均值及方差，产生 sigma 点：

$$\bar{x}_{k-1}^{i+n} = m_k^- - \sqrt{N + \lambda} [\sqrt{P_k^-}]_i, i = 1, \dots, N \quad (4.16)$$

2) 经过整体之测察模型运算非线性转换后之 sigma 点：

$$\bar{z}_k^{-i} = h(\bar{x}_k^i), i = 0, \dots, 2N \quad (4.17)$$

3) 校改后之预估平均值及方差：

$$m_k = m_k^- + K_k [Z(k) - \mu_k] \quad (4.18)$$

$$P_k = P_k^- - K_k S_k K_k^T \quad (4.19)$$

4.2 CKF 算法

容积卡尔曼滤波算法（Cubature Kalman Filter, CKF）是由 Simon Haykin 根据高斯滤波结构框架提出的非线性滤波算法，CKF 之主要核心为三阶球面-相径容积规则。

①三阶球面-相径容积原则：

将高斯滤波器中全部积分过程转换如下式所示

$$I = C \int f(x) \exp(x^T x) dx \quad (4.20)$$

在上式中 C 设定为常数， $f(x)$ 为矩阵函数。

其中点集 D 有如下限定：

若有 x, y ，且 $x \in D$ ，将 x 中所有元素变换次序及变换运算符号获取 y ， $y \in D$ ，且 x 与 y 权值相同那么我们可以称 D 为全对称。

假设 D 中有一元素 $\mu = (u_1, u_2, \dots, u_r, 0, \dots, 0) \in D$ ，

且 $u_i \geq u_{i+1} > 0, i = 1, 2, \dots, r-1, \mu \in R^n$ ，即定义 μ 是为此区域内生成元。并且同时认为 $[(u_1, u_2, \dots, u_r)^T]$ 表示上述集合。

上式（4.20）中排除常数 C 的影响，通过积分转换可以得到

$$I = \int_0^\infty \int_{U_n} f(\gamma y) \gamma^{n-1} e^{-r^2} d\sigma(y) dr \quad (4.21)$$

$\sigma(\bullet)$ 作为 n 维单位球面集合中的元素，可以将（4.20）转换为球面积分及相径积分：

$$S(\gamma) = \int_{U_n} f(\gamma y) d\sigma(y) \quad (4.22)$$

$$I = \int_0^\infty S(\gamma) \gamma^{n-1} e^{-r^2} dr \quad (4.23)$$

在 $f(\gamma y)$ 中 $\{y_1^{d_1} y_2^{d_2} \cdots y_n^{d_n}\}$ ， d_i 代表变量阶次，当 d_i 的整体的和是奇数时，那么此项在球面上积分是零。当应用三阶球面容积法则近似此积分时，两者在其规则条件下的球面积分可以分为：

$$f(y) = 1 \quad 2nw = w \sum_{i=1}^{2n} 1 = \int_{U_n} d\sigma(y) = A_n \quad (4.24)$$

$$2wu_1^2 = w \sum_{i=1}^{2n} f([u]_i) = \int_{U_n} y_1^2 d\sigma(y) = \frac{A_n}{n} \quad (4.25)$$

在上式中， $A_n = 2\sqrt{\pi^n / \Gamma(n/2)}$ 代表球面表面积，其中 $\Gamma(n) = \int_0^\infty x^{n-1} \exp(-x) dx$ 。

通过（4.25）可得到（4.24）的解，即 $w = A_n / 2n, u_1 = 1$ ， $\mu = [u_1, u_2, \dots, u_{n-1}, 0]^T$ ，从而得到 $u_2 = u_3 = \dots = u_{n-1} = 0$ ，那么单位球面和各个坐标轴之交点即为容积点，为点集 [1]。这时，

$$S(r) \approx \sum_{i=1}^{2n} w f(r[1]_i) \quad (4.26)$$

假设 $\sqrt{x} = r$ ，利用相径积分公式经过积分转换可得到高斯-拉盖尔积分公式：

$$I = \frac{1}{2} \int_0^\infty S(\sqrt{x}) x^{\frac{n}{2}-1} e^{-x} dx \quad (4.27)$$

假设当 $S(\sqrt{x})=1$ 或者 x 时，也就是说当 $S(r)=1$ 或 r^2 之时，根据上述公式即可以得到更为确切的积分式，且由球面-相径容积规则设定全部奇数阶项都为零，那么这时选择的积分点及权值分别取为：

$$\omega_1 = \Gamma(n/2)/2 \quad (4.28)$$

$$r_1 = \sqrt{n/2} \quad (4.29)$$

$$I \approx \sum_{j=1}^1 \omega_j S(r_j) \quad (4.30)$$

将三阶球面-相径容积之近似方略应用至标准高斯分布积分领域可以得到

$$I_1 = \int f(x) N(x;0,1) dx = \frac{1}{(2\pi)^{n/2}} \int f(x) \exp(-\frac{1}{2} x^T x) dx \quad (4.31)$$

令上式中 $y = \sqrt{\frac{1}{2}} x$ ，带入可转化为

$$I_1 \approx \frac{1}{(\pi)^{n/2}} \sum_{i=1}^{2n} \omega f(\sqrt{2} r_1 [1]_i) = \frac{1}{2n} \sum_{i=1}^{2n} f(r[1]_i) \quad (4.32)$$

其中，

$$r = \sqrt{2} r_i = \sqrt{\frac{2n}{2}}。$$

根据 I_1 的求得办法得到

$$I_2 = \frac{1}{2n} \sum_{i=1}^{2n} f(\sqrt{P} \xi_i + \hat{x}) \quad (4.33)$$

在上式中， $\xi_i = \sqrt{n}[1]_i$

②CKF 滤波器

上节推出的整体运行及测察模型如下所示：

$$X(k) = f(X(k-1), u(k)) + \omega(k)$$

$$Z(k) = h(X(k)) + v(k)$$

首先以在 k 时刻态势 $X(k)$ 之平均值是 m_k ，方差是 P_k ，依照 UKF 运算过程可推导 CKF 的滤波过程则为：

- 预估过程

- 1) 容积点初始化

$$\chi_{k-1}^i = m_{k-1} + \sqrt{P_{k-1}} \xi_i, i = 1, \dots, 2N \quad (4.34)$$

- 2) 经过整体的运行模型运算非线性转换后之容积点

$$\chi_k^i = \underbrace{f(\chi_{k-1}^i, u(k))}_{\text{系统的运动模型}}, i = 1, \dots, 2N \quad (4.35)$$

- 3) 运算态势预估之平均值及方差

$$m_k^- \approx \frac{1}{2N} \sum_{i=1}^{2N} \chi_k^i \quad (4.36)$$

$$P_k^- \approx \frac{1}{2N} \sum_{i=1}^{2N} (\chi_k^i - m_k^-)(\chi_k^i - m_k^-)^T + Q(k-1) \quad (4.37)$$

- 校正过程

- 1) 依据态势预估之平均值及方差产生容积点

$$\bar{x}_k^i = m_k^- + \sqrt{P_k^-} \xi_i, i = 1, \dots, 2N \quad (4.38)$$

- 2) 经过整体之测察模型运算非线性转换后的容积点

$$\bar{z}_k^i = h(\bar{x}_k^i), i = 1, \dots, 2N \quad (4.39)$$

- 3) 运算校改后的预估平均值及方差

$$m_k = m_k^- + K_k [Z(k) - \mu_k] \quad (4.40)$$

$$P_k = P_k^- - K_k S_k K_k^T \quad (4.41)$$

4.3 S-CKF 算法

S-CKF 算法即为在卡尔曼滤波框架内，应用三阶球面-相径容积原则，以确实容积

点集传递之后再行加权获取非线性函数之平均值及协方差平方根因子。其中将利用协方差矩阵平方根替换协方差矩阵从而解决因为计算机舍入之偏差可能致使滤波器的发散问题。详细算法叙述如下：

预估阶段：

容积点运算：

$$x_{k-1}^j = L_{k-1}^A \xi_j + S_{k-1}^A \quad (4.42)$$

式中 j 是容积点序号，取值从 1 至 $2(n_u + n_s)$ 。其中 x_{k-1}^j 涵盖了 $k-1$ 时间内之位姿数据信息，特征点数据及运行控制数据信息。将移动机器人态势信息 S_{k-1} 及运行信息 u_k 增广成高斯噪声变量，通过下式处理可以获得 L_{k-1}^A 和 S_{k-1}^A 。

$$S_{k-1}^A = \begin{bmatrix} S_{k-1} \\ u_k \end{bmatrix}, L_{k-1}^A = \begin{bmatrix} L_{k-1} & 0 \\ 0 & \sqrt{Q_k} \end{bmatrix} \quad (4.43)$$

ξ_i 代表相互正交之完全对称的容积点集，代表 ξ_i 具备 $2(n_u + n_s)$ 列

$$\xi_i = \sqrt{n_s + n_u} \left\{ \begin{bmatrix} 1 \\ 0 \\ \dots \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ \dots \\ 0 \end{bmatrix}, \dots, \begin{bmatrix} 0 \\ \dots \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ \dots \\ 0 \\ 1 \end{bmatrix}, \dots, \begin{bmatrix} -1 \\ 0 \\ \dots \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \\ \dots \\ 0 \end{bmatrix}, \dots, \begin{bmatrix} 0 \\ \dots \\ -1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ \dots \\ 0 \\ -1 \end{bmatrix} \right\} \quad (4.44)$$

运算所有容积点之先验估计，以 j 容积点做为例子：

$$x_{k|k-1}^j = f(x_{k-1}^j) \quad (4.45)$$

移动机器人 $k-1$ 时刻方位数据信息及 k 时刻运行信息可以通过每个容积点通过非线性运行方程传递后获得，从而预估 k 时刻机器人位姿数据信息。

$$I = \int f(y) N(y; \mu, \Sigma) dy \approx \frac{1}{2n_y} \sum f(\sqrt{\Sigma} \xi_i + \mu) \quad (4.46)$$

依据上式中容积变换式可以得到，

$$S_{k|k-1} = \frac{1}{2(n_s + n_u)} \sum_{j=1}^{2(n_s + n_u)} x_{k|k-1}^j \quad (4.47)$$

将误差向量 $A_{k|k-1}$ 通过 QR 分解后可以获得平方根因子 $C_{k|k-1}$ 从而进行下一阶段操作，

$$A_{k|k-1} = \frac{1}{\sqrt{2(n_s + n_u)}} \begin{bmatrix} x_{k|k-1}^1 - S_{k|k-1} & x_{k|k-1}^2 - S_{k|k-1} \dots x_{k|k-1}^{2(n_s + n_u)} - S_{k|k-1} \end{bmatrix} \quad (4.48)$$

$$[Q \quad R] = qr(A_{k|k-1}^T), C_{k|k-1} = R^T \quad (4.49)$$

更新阶段：

i 作为其中某一特征点，则在 K 时刻之测察值是 z_k^i ，它的测察模型是：

$$z_{k|k-1}^i = h(S_k^r) + V_k \quad (4.50)$$

容积点运算：

$$D_{k-1}^j = C_{k|k-1} \xi_j + S_{k|k-1} \quad (4.51)$$

其中 D_{k-1}^j 涵盖 $K-1$ 时间移动机器人位姿数据信息，运行控制数据信息及所有特征点预估数据信息。

计算所有特征点之测察预估，并以 i 特征点为例：

$$z_{k|k-1}^{i,j} = h(D_{k-1}^{i,j}) \quad (4.52)$$

$D_{k-1}^{i,j}$ 代表 D_{k-1}^j 所涵盖的 i 特征点的相关数据信息，通过非线性测察方程传递能获得所有与容积点相对应之测察值。

依据上面容积转换式可得：

$$\bar{z}_{k|k-1}^i = \frac{1}{2n} \sum_{j=1}^{2n} z_{k|k-1}^{i,j} \quad (4.53)$$

$$B_{k|k-1}^i = \frac{1}{2n_s} [z_{k|k-1}^1 - \bar{z}_{k|k-1}^i \quad z_{k|k-1}^2 - \bar{z}_{k|k-1}^i \cdots \bar{z}_{k|k-1}^{2(n_s+n_u)} - \bar{z}_{k|k-1}^i] \quad (4.54)$$

$[Q \quad R] = qr([B_{k|k-1}^i \quad \sqrt{R_k}]^T)$ 可以求取平方根因子：

$$P_{k|k-1}^{zz} = R^T \quad (4.55)$$

计算卡尔曼增益，进行位姿数据信息更新及预估平方根因子。

$$P_{k|k-1}^{xz} = A_{k|k-1} B_{k|k-1}^T \quad (4.56)$$

卡尔曼增益：

$$W = P_{k|k-1}^{xz} \cdot (P_{k|k-1}^{zz} \cdot P_{k|k-1}^{zz})^{-1} \quad (4.57)$$

位姿更新：

$$S_k = S_{k|k-1} + W_k (z_k^i - \bar{z}_{k|k-1}^i) \quad (4.58)$$

平方根因子更新：

$$[Q \quad R] = qr([C_{k|k-1} - W_k \cdot z_{k|k-1}]^T), C_k = R^T \quad (4.59)$$

如有多个特征点进行观测时，需将 4-53 至 4-59 式重复计算。

4.4 I-CKF 算法

S-CKF 算法虽可以有效提升机器人位姿定位精确度及整体操控的稳定性，但伴随地图内特征点总体数量的提高，系统测察之维度便将逐步增加，致使容积点最终与理想轨迹形成偏差，进而在状态估计过程中造成较大误差。

本文将应用 Iterate 算法, 于其更新过程中应用预估值及平方根因子将采样容积点进行重新确定，经过容积转换进而获得系统之统计特性，而后有效将预估阶段预估的新的测察值进行结合从而提升系统状态估计，有效提升算法精确度。具体算法叙述如下：

预估阶段：

K 时刻，进行 4-42 至 4-49 式预估移动机器人位姿 $S_{k|k-1}$ 及平方根因子 $C_{k|k-1}$ 。

更新阶段：

假设特征点 i ， $S_{k|k-1}$ 及 $C_{k|k-1}$ 分别为迭代初始值， $S_{k|k-1}^{(l)}$ 、 $C_{k|k-1}^{(l)}$ 分别是第 l 次迭代机器人位姿数据信息及平方根因子。

迭代容积点运算

$$D_{k-1}^{j,(l)} = C_{k|k-1}^{(l)} \xi_j + S_{k|k-1}^{(l)} \quad (4.60)$$

第 l 次迭代卡尔曼增益运算

$$z_{k|k-1}^{i,j,(l)} = h(D_{k-1}^{i,j,(l)}) \quad (4.61)$$

$$\bar{z}_{k|k-1}^{i,(l)} = \frac{1}{2n_s} \sum_{j=1}^{2n_s} z_{k|k-1}^{i,j,(l)} \quad (4.62)$$

$$B_{k|k-1}^{i,(l)} = \frac{1}{\sqrt{2n_s}} [z_{k|k-1}^1 - \bar{z}_{k|k-1}^{i,(l)} \quad z_{k|k-1}^2 - \bar{z}_{k|k-1}^{i,(l)} \quad \cdots \quad z_{k|k-1}^{2(n_s+n_u)} - \bar{z}_{k|k-1}^{i,(l)}] \quad (4.63)$$

$$[Q \quad R] = qr([B_{k|k-1}^{i,(l)} \quad \sqrt{R_k}]^T) \quad P_{k|k-1}^{zz,(l)} = R^T \quad (4.64)$$

$$P_{k|k-1}^{xz,(l)} = A_{k|k-1}^{(l)} B_{k|k-1}^{(l)T} \quad (4.65)$$

卡尔曼增益：

$$W_k^{(l)} = P_{k|k-1}^{xz,(l)} \cdot (P_{k|k-1}^{zz,(l)T} \cdot P_{k|k-1}^{zz,(l)})^{-1} \quad (4.66)$$

迭代 $l+1$ 次机器人位姿数据信息 $S_{k|k-1}^{(l+1)}$ 及平方根因子 $C_{k|k-1}^{(l+1)}$ 运算

$$S_{k|k-1}^{(l+1)} = S_{k|k-1}^{(l)} + W_k^{(l)} [z^k - h(S_{k|k-1}^{(l)}) - P_{k|k-1}^{xz,(l)T} \cdot B_{k|k-1}^{i,(j)-1} (S_{k|k-1}^{(l)} - S_{k|k-1}^{(l)})] \quad (4.67)$$

$$C_{k|k-1}^{(l+1)} = C_{k|k-1} - W_k^{(l)} \cdot (W_k^{(l)})^T \quad (4.68)$$

设置迭代截止条件

迭代最大次数为 $l = L_{\max}, L_{\max}$ ，即为预先设定的固定常量

迭代截止后，所有数据更新：

$$S_{k|k-1} = S_{k|k-1}^{(L_{\max})} \quad (4.69)$$

$$C_{k|k-1} = C_{k|k-1}^{(L_{\max})} \quad (4.70)$$

位姿更新：

$$S_k = S_{k|k-1} + W_k (z_k^i - \bar{z}_{k|k-1}^i) \quad (4.71)$$

4.5 仿真对比分析

此小结将在算法精确度及运算速度等角度于三种维度下全面分析 UKF、S-CKF、I-CKF 算法的性能。

①1 维非线性系统如下：

$$x(k) = 0.2x(k-1) + 0.01x(k-1)^2 + 8 * \cos(1.2(k+1)) + w_k$$

$$y(k) = x(k)^2 + v_k$$

在上式中， w_k 及 v_k 是和初始态势无关的高斯白噪声，其中作为 w_k 及 v_k 方差的方差 $Q=10$ 及 $R=0.01$ 。将实际初始值设定为 $x(0)=1$ ，且 $x_estimate(i)=0.5$ ，预估方差为 $P=1000$ 。

若仿真步长设定为 100，在滤波办法的预估准确度方面应用 RMS 进行对比，其中，

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_estimate(i) - x(i))^2} \quad (4.72)$$

在上式中仿真步长 $x(i)$ 之实际态势数值设定为 N ，预估态势值为 $x_estimate(i)$ ，如下图所示为 UKF、S-CKF、I-CKF 运算方法的预估值及实际值的对比分析：




图 4.1 三种算法的估计值和真实值对比图

在上图中可以看出 UKF 在迭代数量为 87 次时刻左右预估实际值出现最大偏差。相对 UKF 算法而言，S-CKF 及 I-CKF 的预估成果相差无多，UKF、S-CKF、I-CKF 的预估误差图如下图所示：




图 4.2 三种算法估计的误差值对比图

通过以上数值仿真分析可以看出，S-CKF 及 I-CKF 运算之预估结果都相对 UKF 具有优势，我们再来对比三种算法之均方根误差，最后结果如下表：

表 4.1 三种算法的均方根误差

UKF	S-CKF	I-CKF
7.152	0.853	1.623

通过表 4.1 可以了解在运算准确度角度而言,UKF 运算精度最低,而 S-CKF 与 I-CKF 相差无多。

表 4.2 三种算法的运行时间

UKF	S-CKF	I-CKF
0.0104	0.0103	0.0065

在上表可以了解到 UKF 与 S-CKF 的运行速度与 I-CKF 相比较慢,综合所有因素考虑,I-CKF 运算方法为最优选择,在本文中主要需要解决多维状态估计问题,那么我们需要来分析 I-CKF 方法在多维状态估计中是否能带来很好的效果。

②设定 3 维非线性系统:

$$x(k) = \begin{bmatrix} x_1(k) \\ x_2(k) \\ x_3(k) \end{bmatrix} = \begin{bmatrix} 3\sin^2(x_2(k-1)) \\ x_1(k-1) + e^{-0.03x_3(k)} \\ 0.2x_1(k-1)(x_2(k-1) + x_3(k-1)) \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} w_k$$

$$y(k) = \cos(x_1(k)) + x_2(k) + x_3(k) + v_k$$

在上式中, w_k 和 v_k 是和初始态势无关的高斯白噪声,其中作为 w_k 和 v_k 方差的方差 $Q=0.7$ 及 $R=1$ 。

设定整体态势的实际初始值是 $x(0) = [-0.7 \ 1 \ 1]^T$, 预估初始值是 $x_estimate(0) = [0 \ 0 \ 0]^T$, 预估方差初始值为 $P = diag(1,1,1)$, 且设定此次仿真步长是 100, UKF、S-CKF、I-CKF 三种算法在三种维度下分析对比图如下:




图 4.3 x_1 维度下三种算法的估计值和真实值对比图




图 4.4 x_2 维度下三种算法的估计值和真实值对比图

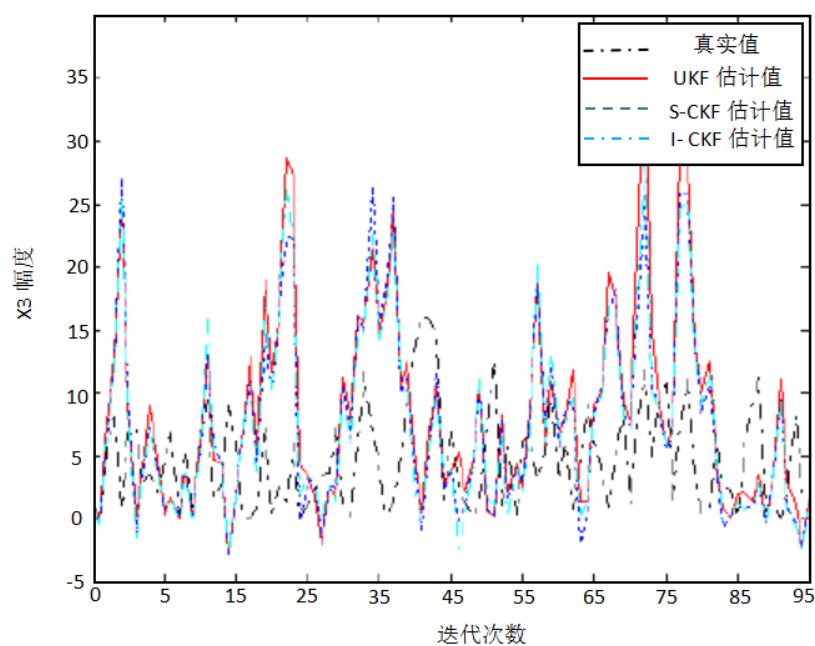


图 4.5 x_3 维度下三种算法的估计值和真实值对比图

以上为三种算法在三种维度下的预估结果，而在迭代次数为 45 次左右时刻，UKF 在 x_1 出现较大偏差并在 x_3 维度下多次出现相对较大偏差。

其中 UKF、S-CKF、I-CKF 在三个维度的预估误差图如下所示：




图 4.6 x_1 维度下三种算法估计的误差值对比图




图 4.7 x_2 维度下三种算法估计的误差值对比图




图 4.8 x_3 维度下三种算法估计的误差值对比图

可以从上面三幅仿真图中看出不论在哪种维度，UKF 都不及 I-CKF 及 S-CKF，对比三种维度下 UKF、S-CKF、I-CKF 之均方根误差如下表所示：

表 4.3 三种算法在各个维度下的均方根误差

维度	UKF	S-CKF	I-CKF
x_1	1.6781	1.4434	1.4060
x_2	1.8583	1.8012	1.8190
x_3	9.3815	8.6132	8.5606

从上表中可以了解到 I-CKF 在 x_1 及 x_3 两类精度是最准确的, S-CKF 居中, 而 UKF 算法精准度最差。

表 4.4 三种算法在 3 维状态估计中的运行时间

UKF	S-CKF	I-CKF
0.2262	0.3415	0.1195

在表 4.4 中可以看出相比于 I-CKF 算法运行时间只有 0.1195 而言, S-CKF 为 0.3415, UKF 为 0.2262。综合以上多种因素考虑, I-CKF 算法均优于其他两种算法, 所以最后本文在状态估计问题上将采用 I-CKF 算法进行研究探讨。

4.6 本章小结

在本章中首先分别介绍了 UKF、CKF、S-CKF 的基本原理, 并在其理论上提出运用 Iterate 算法在其更新过程中应用预估值及平方根因子将采样容积点进行重新确定的方法并将其定义为 I-CKF 算法, 通过三种算法在三种维度下的仿真对比分析得出不论在时间或运算精度上 I-CKF 都高于其他算法的结论, 并将其应用于状态估计问题领域。

第五章 基于 CI-CKF 方法 SLAM 问题实现

上面章节分别对移动机器人 SLAM 问题中两个关键问题即数据关联及状态估计进行了相关改进方案的研究探讨，而本章节将在以上研究基础上构建仿真实验平台，并且将应用上文提到的改进方法从而实现移动机器人的定位及构图。

5.1 移动机器人 SLAM 仿真平台的构建

本章将建立包括里程计模型、全局坐标系模型、传感器模型等在内的一系列数学模型从而实现对移动机器人的运行过程、测察过程以及特征点等的数学描述，进而为移动机器人 SLAM 算法构建统一的实验平台环境。

假设在实验环境中地面平坦，并无任何人为因素干扰移动机器人运行，在运行过程中轮子无偏差，且移动机器人本身参数不会存在因运行导致其变化，基于以上假设从而确立机器人之各方面模型：

I. 整体坐标模型

DIN7000、笛卡尔及极坐标系三种坐标系统经常被广泛应用在移动机器人定位领域，在本文 SLAM 问题中，分别定义移动机器人坐标系 $X_R O_R Y_R$ 、全局整体坐标系 $X_W O_W Y_W$ 及传感器测察坐标系 $X_S O_S Y_S$ 。而其中移动机器人本身测察特征点之传感器方位 $X_s = (x_s, y_s)$ 、方位态势 $X_r = [x_r, y_r, \theta_r]^T$ 及环境特征方位 $X_i = (x_i, y_i)$ 都应用笛卡尔坐标系；如图 5.1 可见其相互关联。

II. 移动机器人位姿模型

以全局坐标系内 (x_r, y_r) 代表机器人之方位情况， θ_r 作为机器人方位与坐标轴 x_w 之间的夹角即机器人偏离方向角。其中 0° 为 x_w 轴，最大角度为 360° ，其中规定逆时针代表正方向，顺时针代表负方向，详细情况如图 5.1 所示。




图 5.1 移动机器人位姿坐标系统

III. 移动机器人里程计模型

在本文研讨中，将应用双轮差分机器人平台，那么移动机器人之相应位姿的数据采集便可以通过分别装置于两个驱动轮中的光电编码器数据也即是里程计采集的信息

内容采集到。

其中设定车轮半径是 r ，在 Δt 范围内脉冲数是 N ，光电码盘是 p 线/转，那么车轮运行长度 Δd 可以表示为：

$$\Delta d = 2 \times (N / p) \times \pi r \quad (5.1)$$

通过光点编码器数据采集，假设左轮移动距离设定为 Δd_L ，右轮移动距离设定为 Δd_R ， w 作为左右两轮之间间距，移动机器人在 $X_r(k) = (x_r(k), y_r(k), \theta_r(k))^T$ 位置移动到 $X_r(k+1) = (x_r(k+1), y_r(k+1), \theta_r(k+1))^T$ 位置，即运行长度为 $\Delta D(k) = (\Delta d_L + \Delta d_R) / 2$ ， $\Delta \theta_r(k) = (\Delta d_L - \Delta d_R) / w$ 为其转角。当时间间距非常小时，移动机器人可以看成直线移动距离为零或者为 $r_k = \Delta D(k) / \Delta \theta(k)$ 之圆形轨迹。




图 5.2 里程计数学模型分析图

需要考虑一个周期内的方位及方向角的改变为里程计模型划分中的圆弧运动模型，而如在短时间范围内忽略方向角度的改变的话，则可简化为里程计数学模型中的直线运动模型。

假定在预定时间 Δt 内，移动机器人运行轨迹为圆弧形，则在此周期中终止运行位置与起始运行位置的方向角差值为 $|\Delta \theta_r^k| > 0$ ，那么其可以表述为：

$$\begin{aligned} X_r(k) &= f(X_r(k-1), u(k)) \\ &= \begin{bmatrix} x_r(k-1) + r_k (\cos \theta_r(k) + \Delta \theta_r(k)) - \cos \Delta \theta_r(k) \\ y_r(k-1) + r_k (\sin \theta_r(k) + \Delta \theta_r(k)) - \sin \Delta \theta_r(k) \\ \theta_r(k-1) + \Delta \theta_r(k) \end{bmatrix} \end{aligned} \quad (5.2)$$

假定在预定时间 Δt 内，且偏转角差值为零即 $\Delta \theta_k = 0$ ，此时则可应用里程计数学模型中的直线模型进行模拟，推导可得直线模型方程为：

$$\begin{aligned} X_r(k) &= f(X_r(k-1), u(k)) \\ &= \begin{bmatrix} x_r(k-1) + \Delta D(k) (\theta_r(k-1) + \cos \Delta \theta_r(k) / 2) \\ y_r(k-1) + \Delta D(k) (\theta_r(k-1) + \sin \Delta \theta_r(k) / 2) \\ \theta_r(k-1) + \Delta \theta_r(k) \end{bmatrix} \end{aligned} \quad (5.3)$$

里程计由于光电编码器的测察偏差等会在移动机器人运行过程中误差逐渐加大，

而矫正这些偏差只能依靠激光测距仪、视觉传感器等，具体如下图所示：

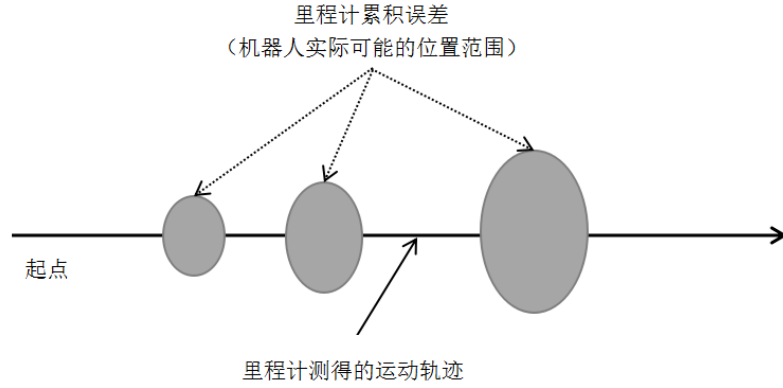


图 5.3 里程计误差累积

其中构造精准正确的里程计模型及仔细分析累积误差可以有效提高移动机器人方位及方向角的正确性。

IV. 移动机器人运行模型

$X(k)$ 作为移动机器人 k 时态势，而移动机器人的运行模型则表示输入 $u(k)$ 及噪声干扰 $\omega(k)$ 两者共同作用下 $X(k)$ 的变化过程，可以表示为：

$$X_r(k) = f(X_r(k-1), u(k)) + \omega(k) \quad (5.4)$$

在上式中 $f(X_r(k-1), u(k))$ 为非线性状态转换函数，即为：

$$\begin{aligned} X_r(k) &= f(X_r(k-1), u(k)) \\ &= \begin{bmatrix} x_r(k-1) + \Delta D(k)(\theta_r(k-1) + \cos \Delta \theta_r(k) / 2) \\ y_r(k-1) + \Delta D(k)(\theta_r(k-1) + \sin \Delta \theta_r(k) / 2) \\ \theta_r(k-1) + \Delta \theta_r(k) \end{bmatrix} + \begin{bmatrix} \omega_x \\ \omega_y \\ \omega_\theta \end{bmatrix} \end{aligned} \quad (5.5)$$

V. 地图构建表示

国内外研究学者经常采用栅格地图、特征地图及拓扑地图在 SLAM 问题中进行地图表示。

在本文研究中将应用特征地图进行移动机器人 SLAM 问题技术研究，在操作过程中，将应用激光传感器获取周围环境特征点从而在笛卡尔坐标系下建立环境地图。

以 $X_i = (x_i, y_i)$ 代表地图中特征点， i 的取值为从 1 至 n ，将 (x_i, y_i) 用于代表某点的实际坐标方位。

VI. 传感器测察模型

本文将应用安装在机器人外部的激光传感器测察到的数据信息从而矫正移动机器人预估方位态势，测察值 z 在笛卡尔坐标系及极坐标系下分别可以表示为：

$$Z = [x, y]^T \quad Z = [\rho \phi]^T \quad (5.6)$$

传感器之测察值和移动机器人方位及方向角之间的联系可以通过测察模型得出，

下式为测察模型方程描述形式

$$Z(k) = h(X_r(k)) + v(k) \quad (5.7)$$

在上式中, $Z(k)$ 为在 k 时之测察值, $v(k)$ 为测察噪声, 即为测察中噪声及模型自身的偏差, $h(\bullet)$ 为测察函数。




图 5.4 传感器观测模型

在本文探讨中需要三类测察值表述办法, 且对应于三类不同坐标系下的测察方程:

a. 在传感器测察坐标系下环境特征之测察方程:

在此坐标系下, 测察值由周围特征点至传感器的距离 $\rho(k)$ 及方位角 $\phi(k)$ 进行表述。假定此时传感器方位为 $(X_s(k), Y_s(k), \theta_s(k))$, 此时移动机器人方位角是 $(X_r(k), Y_r(k), \theta_r(k))$, 因为在全局坐标系下移动机器人的方向与传感器的方向相同, 则 $\theta_s(k) = \theta_r(k)$ 。在传感器测察坐标系假定某特征点方位是 $X_i = (x_i, y_i)$ 之测察模型表示:

$$Z(k) = \begin{bmatrix} \rho(k) \\ \phi(k) \end{bmatrix} = \begin{bmatrix} \sqrt{(x_i - x_s(k))^2 + (y_i - y_s(k))^2} \\ \arctan\left(\frac{y_i - y_s(k)}{x_i - x_s(k)}\right) - \theta_s(k) \end{bmatrix} + v(k) \quad (5.8)$$

b. 在移动机器人坐标系下环境特征之测察方程:

假定此时移动机器人方位及方位角为 $(X_r(k), Y_r(k), \theta_r(k))$, 在环境中某特征点为 $X_i = (x_i, y_i)$, 在移动机器人坐标系下的测察值坐标是 $x_R(k)$ 和 $y_R(k)$, 那么此时整体测察模型可以表示为:

$$Z(k) = \begin{bmatrix} x_R(k) \\ y_R(k) \end{bmatrix} = \begin{bmatrix} (y_i - y_r(k)) \sin(\theta_r(k)) + (x_i - x_r(k)) \cos(\theta_r(k)) \\ (y_i - y_r(k)) \cos(\theta_r(k)) - (x_i - x_r(k)) \sin(\theta_r(k)) \end{bmatrix} + v(k) \quad (5.9)$$

c. 在全局坐标系下的环境特征之测察方程:

假定此时移动机器人方位及方向角为 $(X_r(k), Y_r(k), \theta_r(k))$, 测察值的坐标分别为 $x_R(k)$ 和 $y_R(k)$, 在全局坐标系下测察值的坐标分别为 $x_w(k)$ 和 $y_w(k)$, 那么此时整体测察模型可以表示为:

$$Z(k) = \begin{bmatrix} x_w(k) \\ y_w(k) \end{bmatrix} = \begin{bmatrix} (x_r(k) + x_R(k)) \cos(\theta_r(k)) - y_R(k) \sin(\theta_r(k)) \\ (y_r - x_R(k)) \sin(\theta_r(k)) + y_R(k) \cos(\theta_r(k)) \end{bmatrix} + v(k) \quad (5.10)$$

VII. 基于环境特征之动态模型

假定在本文研讨中环境为静止， $X_i = (x_i, y_i)$ 代表全局坐标系内方位坐标， i 取值为 $1 \sim n$ 代表全部特征点数额，则环境特征之模型可以表示为：

$$X_r(k) = X_i(k-1) \quad (5.11)$$

$$\begin{bmatrix} x_i(k) \\ y_i(k) \end{bmatrix} = \begin{bmatrix} x_i(k-1) \\ y_i(k-1) \end{bmatrix} \quad (5.12)$$

VIII. 传感器噪声及环境噪声模型

移动机器人在定位过程中会经受各种噪声干扰，并在激光传感器等传感器共同作用下采集相关应用信息，且移动机器人为高阶非线性系统模型，在一般情况下会对高阶模型进行简化从而得到简化近似模型，在此过程中或多或少有些许偏差，所以为了更好的对噪声及偏差进行模拟，在建构仿真实验平台时经常使用高斯白噪声模型，如下图所示，设定平均值为 μ ，标准差是 σ 。




图 5.5 高斯分布函数图

5.2 仿真对比研讨

依据前面章节中移动机器人运行模型、环境噪声模型及传感器测察模型等构造仿真研讨平台，预先给出仿真环境中移动机器人运行态势，其中特征点的实际方位如下图所示。将绿色线条作为移动机器人实际运行路线，蓝色星点作为特征点实际方位，其中移动机器人始于点 $(0, 0)$ ，规定机器人按逆时方向运行。




图 5.6 仿真实验环境图

首先应用基于改进 C-UKF 的方法进行机器人 SLAM 实现,最后仿真成果如下图所示。在途中以黑色线条代表机器人所在方位,利用 UKF 算法预估出的特征点方位用红色+号作为标记,其中红色的椭圆形线条作为预估的无法确定范围,可以看到在左下及右上位置有较多预估偏差。




图 5.7 基于改进 C-UKF 的机器人定位与构图仿真结果

本文将改进后的数据关联及状态估计算法生成的新算法定义为 CI-CKF 算法,应用基于改进 CI-CKF 的方法进行机器人 SLAM 实现,最后仿真成果如下图所示。在途中以黑色线条代表机器人所在方位,利用 CI-CKF 算法预估出的特征点方位用红色+号作为标记,其中红色的椭圆形线条作为预估的无法确定范围,可以看到在全部运行过程中算法之预估的偏差都相对较小。




图 5.8 基于改进 CI-CKF 的机器人定位与构图仿真结果

预定共有 8780 个预估方位点构成，将 C-UKF 及 CI-CKF 两类方法的运行时间及预估均方误差进行对比分析。RMS(X) 及 RMS(Y) 分别代表算法预估横坐标及纵坐标的均方误差，RMS(θ) 代表移动机器人预估方向角的均方误差。

表 5.1 两种算法估计均方根误差、算法运行时间对比分析表

算法	运行时间/s	RMS(X)/m	RMS(Y)/m	RMS(θ)/°
CI-CKF	60.6	0.9596	0.7572	0.5990
C-UKF	54.5	2.2690	1.1600	0.2845

可以在上表中观察到，虽 C-UKF 相对于 CI-CKF 方法时间复杂度相对少 10%左右，因在 CKF 方法中矩阵需要进行分解，其中高维的矩阵分解的时间更多，将稀疏矩阵的相应研讨办法贯穿在 CKF 的矩阵分解内，可以更快的进行分解，这将是下一步研讨内容，但可以清晰看到在目标方位(X,Y)上 CI-CKF 预估精确度相对精准许多，在以上的直观图以及对比表中都可以看出此法的优越性。

5.3 本章小结

在本章中率先介绍了一系列系统模型包括机器人位姿模型、里程计模型、坐标系模型及传感器模型等为构建机器人所需实验仿真平台服务。而后进行基于 C-UKF 及 CI-CKF 两种改进算法的仿真对比分析，可以看出在移动机器人 SLAM 研究领域中, CI-CKF 算法精准度更高，其中误差度仅为前一种算法的 50%左右。

第六章 总结与展望

6.1 全文总结

本文主要是在基于贝叶斯理论上对移动机器人 SLAM 问题展开研究探讨, 创新提出数据关联及状态估计方法进而提升移动机器人在 SLAM 过程中之精确度及降低时间复杂度。

在现今社会人口老龄化严重, 资源危机及公共交通经常性拥堵等问题显现前提下, 可以看出移动机器人 SLAM 问题重要性, 继而详细地阐述了关于此问题的国内外研究现状及其最新动态发展趋势。本文应用贝叶斯理论基础进行相关问题数学描述, 通过公式简单清晰地分析了数据关联及状态估计两大问题领域, 并与此同时提出了关于这两大问题的核心重点。

在探讨研究移动机器人之数据关联问题中, 本文首先对此问题进行了相关数学描述, 而后列举了一些前人经常应用到的数据关联算法, 详细分析了各种算法的优点及劣势, 最后本文创新提出了一种基于联合相容算法通过层次聚类进行多层次数据关联的算法, 并经过仿真对比可以得出本文所提方法与其他算法相比具有其显著优势, 应用本文算法可以明显降低误关联率且将运行时间显著缩短, 非常适用于具有多特征点环境。

对于多维状态估计问题而言, 本文首先介绍了 UKF 及 CKF 基本原理, 并在此基础上分析了 S-CKF 算法, 进而应用 Iterate 算法对其作出相应改进, 本文将其定义为 I-CKF 算法。阐述其原理同时且做出详细推导, 并在三种维度下进行相关仿真对比分析, 最后得出不论运行时间还是运算精度 I-CKF 算法都优于其他三种算法。

本文最后建立了包括里程计模型、全局坐标系模型、传感器模型等在内的一系列数学模型从而实现对移动机器人的运行过程、测察过程以及特征点等的数学描述, 进而为移动机器人 SLAM 算法构建统一的实验平台环境。并在此仿真平台上运用整体改进后的算法进行定位与构图的仿真实验操作, 对比研究了本文所提算法在 SLAM 问题领域相较其他算法的优势, 通过仿真对比图可以清晰直观的看到本文提出算法的优点。

6.2 工作展望

本文虽在贝叶斯理论上研究移动机器人 SLAM 问题方面取得了一定的研究成果, 但还有诸多问题可以进一步深入探讨, 具体涵盖如下方面:

(1) 本文中涉及的数据关联算法还可进一步改进, 可以使其最后自动辨别各类环境, 伴随测察数据的改变, 自适应的校正分组之规则及各组的大小, 可在确保关联度精确度下降低该算法时间复杂性。

(2) 本文所涉及的全部研究内容都是在以单个机器人探测环境数据信息基础上构

建而成，若应用多个机器人合作的形式则可以更快感知环境数据且不易于受到干扰。所以如何将多个机器人的数据融合，构建机器人 SLAM 整体数学框架将是需要研讨的核心及难点。

致谢

在此谨向曾经给予我深刻关怀、教导以及帮助的领导、老师致以诚挚的谢意。

通过两年多对移动机器人 SLAM 问题方面的研究，我顺利地在学习基础上完成了这篇硕士论文，在此我要对我的指导老师——白雪梅老师表以衷心的感谢。不论是入学时课程的孜孜教导，开题的详细解答，还有后期论文撰写时的疑惑白老师都给予最细心的讲解并为我提出许多宝贵意见。白老师严谨的学术作风以及渊博的知识都使我受用无穷。

同时我也要十分感谢我们实验室的学术带头人郭滨教授，他在为各位同学提供了一个非常适于学习的科研环境的同时，也在平时点点滴滴的生活中教会我们许多做人的道理，在以丰富的理论知识滋养着我们的同时也引导着我们健康积极的生活方向，郭老师用他严谨的学术作风、求真务实的科学态度都在指导我们的过程中让我们深有体会，而这些都必将使我受益终生。

最后，诚挚感谢在百忙之中抽出时间对论文进行评阅的专家、教授。

参考文献

- [1] Houles A, Bar-Shalom Y. Multisensor tracking of a maneuvering target in clutter[J]. IEEE Transactions on Aerospace & Electronic Systems, 1989, 25(2):176 – 189.
- [2] Neira J, Tardós J D. Data association in stochastic mapping using the joint compatibility test[J]. Robotics and Automation, IEEE Transactions on, 2001, 17(6): 890-897.
- [3] Colegrove S B, Davey S J. On using nearest neighbours with the probabilistic data association filter[C]. Radar Conference, 2000. The Record of the IEEE 2000 International. IEEE, 2000:53 – 58.
- [4] Castellanos J A, Montiel J M M, Neira J, et al. The SPmap: a probabilistic framework for simultaneous localization and map building[J]. IEEE Transactions on Robotics & Automation, 1999, 15(5):948--953.
- [5] Colegrove S B, Davey S J. On using nearest neighbours with the probabilistic data association filter[C]. Radar Conference, 2000. The Record of the IEEE 2000 International. IEEE, 2000:53 – 58.
- [6] Zhou, B, Bose, N.K. Multitarget tracking in clutter: fast algorithms for data association[J]. Aerospace & Electronic Systems, IEEE Transactions on, 1993, 29(2):352 – 363.
- [7] Kim M S L H. New data association method for automotive radar tracking[J]. Radar Sonar & Navigation Iee Proceedings, 2001, (5):297-301.
- [8] Ruiz I T, Petillot Y, Lane D M, et al. Feature extraction and data association for AUV concurrent mapping and localisation[C]. Robotics and Automation, 2001. Proceedings 2001 ICRA. IEEE International Conference on. IEEE, 2001, 3: 2785-2790.
- [9] Ahnel D H, Thrun S, Wegbreit B, et al. Towards Lazy Data Association in SLAM[J]. Springer Tracts in Advanced Robotics, 2004:421-431.
- [10] Zhang S, Xie L, Adams M. An efficient data association approach to simultaneous localization and map building[J]. The International Journal of Robotics Research, 2005, 24(1): 49-60.
- [11] Wijesoma W S, Perera L D L, Adams M D. Toward multidimensional assignment data association in robot localization and mapping[J]. Robotics, IEEE Transactions on, 2006, 22(2): 350-365.
- [12] Bailey T, Nebot E M, Rosenblatt J K, et al. Data association for mobile robot navigation: A graph theoretic approach[C]. Robotics and Automation, 2000. Proceedings. ICRA'00. IEEE International Conference on. IEEE, 2000, 3: 2512-2517.
- [13] 武二永, 项志宇, 沈敏一, 等. 大规模环境下基于激光雷达的机器人SLAM算法[J]. 浙江大学学报: 工学版, 2008, 41(12): 1982-1986.
- [14] Cheeseman P, Smith R, Self M. A stochastic map for uncertain spatial relationships[C]. 4th International Symposium on Robotic Research. 1987: 467-474.
- [15] Smith R C, Cheeseman P. On the representation and estimation of spatial uncertainty[J]. The international journal of Robotics Research, 1986, 5(4): 56-68.
- [16] Durrant-Whyte H F. Uncertain geometry in robotics[J]. Robotics and Automation, IEEE Journal of, 1988, 4(1): 23-31.
- [17] Crowley J L. World modeling and position estimation for a mobile robot using ultrasonic ranging[C]. Robotics and Automation, 1989. Proceedings., 1989 IEEE International Conference on. IEEE, 1989: 674-680.
- [18] Chatila R, Laumond J P. Position referencing and consistent world modeling for mobile robots[C]. Robotics and Automation. Proceedings. 1985 IEEE International Conference on. IEEE, 1985, 2: 138-145.

- [19] Dissanayake M W M G, Newman P, Clark S, et al. A solution to the simultaneous localization and map building (SLAM) problem[J]. Robotics & Automation IEEE Transactions on, 2001, 17(3):229 – 241.
- [20] Chatterjee A, Matsuno F. Improving EKF-based solutions for SLAM problems in Mobile Robots employing Neuro-Fuzzy Supervision[C]. Intelligent Systems, 2006 3rd International IEEE Conference on. IEEE, 2006:683 – 689.
- [21] Choi M, Sakthivel R, Wan K C. Neural Network-Aided Extended Kalman Filter For Slam Problem[J]. Proceedings IEEE International Conference on Robotics & Automation, 2007:1686 – 1690.
- [22] 王耀南, 余洪山. 未知环境下移动机器人同步地图创建与定位研究进展[J]. 控制理论与应用, 2008, 25(1):57-65.
- [23] Leonard J J, Feder H J S. Decoupled stochastic mapping [for mobile robot & auv navigation[J]. Oceanic Engineering, IEEE Journal of, 2001, 26(4): 561-571.
- [24] Williams S B, Dissanayake G, Durrant-Whyte H. An efficient approach to the simultaneous localisation and mapping problem[C]. Robotics and Automation, 2002. Proceedings. ICRA'02. IEEE International Conference on. IEEE, 2002, 1: 406-411.
- [25] Leonard J, Newman P. Consistent, convergent, and constant-time slam[J]. Ijcai, 2003.
- [26] Estrada C, Neira J, Tardós J D. Hierarchical SLAM: Real-Time Accurate Mapping of Large Environments[J]. Robotics IEEE Transactions on, 2005, 21(4):588 – 596.
- [27] Paz L M, Neira J. Optimal Local Map Size For EKF-Based Slam[C]. Intelligent Robots and Systems, 2006 IEEE/RSJ International Conference on. 2006:5019 – 5025.
- [28] Chong K S, Kleeman L. Large Scale Sonarray Mapping using Multiple Connected Local Maps[M]. Field and Service Robotics. Springer London, 1998:507-514.
- [29] Geoffrey T, Lindsay K, Iterated Extended Kalman Filter[J]. Advanced Robotics, 2006, 26:pp. 185-187.
- [30] Tully S, Moon H, Kantor G, et al. Iterated filters for bearing-only SLAM[J]. Proceedings – IEEE International Conference on Robotics and Automation, 2008:1442 – 1448.
- [31] Sun R, Ma S, Li B, et al. Improving consistency of EKF-based SLAM algorithms by using accurate linear approximation[C]. Advanced Intelligent Mechatronics, 2008. AIM 2008. IEEE/ASME International Conference on. IEEE, 2008:619 – 624.
- [32] Arulampalam, M.S, Maskell, S, Gordon, N, et al. A tutorial on particle filters for online nonlinear/non-gaussian bayesian tracking[J]. IEEE Transactions on Signal Processing, 2002, 50(2):174 – 188.
- [33] Murphy K P. Bayesian Map Learning in Dynamic Environments[C]. NIPS. 1999: 1015-1021.
- [34] Montemerlo M, Thrun S, Koller D, et al. Fast SLAM: A factored solution to the simultaneous localization and mapping problem[C]. AAAI/IAAI. 2002: 593-598.
- [35] Roller D, Montemerlo M, Thrun S, et al. Fastslam 2.0: an improved particle filtering algorithm for simultaneous localization and mapping that provably converges[C]. Proceedings of the International Joint Conference on Artificial Intelligence. 2003.
- [36] Julier S J, Uhlmann J K. Unscented filtering and nonlinear estimation[J]. Proceedings of the IEEE, 2004, 92(3): 401-422.
- [37] Martinez-Cantin R, Castellanos J A. Unscented SLAM for large-scale outdoor environments[C]. Intelligent Robots and Systems, 2005. (IROS 2005). 2005 IEEE/RSJ International Conference on. IEEE, 2005: 3427-3432.
- [38] Eustice R, Walter M, Leonard J. Sparse extended information filters: Insights into sparsification[C]. Intelligent Robots and Systems, 2005. (IROS 2005). 2005 IEEE/RSJ

International Conference on. IEEE, 2005: 3281-3288.

[39] Liu Y, Thrun S. Results for outdoor-SLAM using sparse extended information filters[C]. ICRA. 2003: 1227-1233.

[40] 董海巍, 陈卫东. 基于稀疏化的快速扩展信息滤波SLAM算法[J]. 机器人, 2008, 30(3): 193-200. [41] 梁志伟, 马旭东, 戴先中, 等. 基于分布式感知的移动机器人同时定位与地图创建[J]. 机器人, 2009, 31(1): 33-39.

[42] Grimson W E L, Lozano-Perez T. Localizing overlapping parts by searching the interpretation tree[J]. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 1987 (4): 469-482.

[43] 韩崇昭, 朱洪艳, 段战胜. 多源信息融合[M]. 清华大学出版社有限公司, 2006.

[44] Bailey T. Mobile robot localisation and mapping in extensive outdoor environments[D]. The University of Sydney, 2002.

[45] Singer R A, Sea R G. A new filter for optimal tracking in dense multitarget environments[C]. Annual Allerton Conference on Circuit and System Theory, 9 th, Monticello, Ill. 1972: 201-211.

[46] Mc Lachlan G, Krishnan T. The EM algorithm and extensions[M]. John Wiley & Sons, 2007.

[47] Julier S J, Uhlmann J K, Durrant-Whyte H F. A new approach for filtering nonlinear systems[C]. American Control Conference, Proceedings of the 1995. IEEE, 1995, 3: 1628-1632.

[48] Julier S J. The scaled unscented transformation[C]. American Control Conference, 2002. Proceedings of the 2002. IEEE, 2002, 6: 4555-4559.

[49] Arasaratnam I, Haykin S. Cubature kalman filters[J]. Automatic Control, IEEE Transactions on, 2009, 54(6): 1254-1269.