

密 级_____



桂林电子科技大学

GUILIN UNIVERSITY OF ELECTRONIC TECHNOLOGY

硕 士 学 位 论 文

(全日制专业学位硕士)

题目 _____ 面向移动机器人导航的 SLAM 研究

(英文) _____ Research on SLAM for mobile robot navigation

研 究 生 学 号: _____ 1501302003

研 究 生 姓 名: _____ 冯磊

指导教师姓名、职称: _____ 张彤 副教授

申 请 学 位 类 别: _____ 工程硕士

领 域: _____ 机械工程

论 文 答 辩 日 期: _____ 2018 年 6 月

独创性（或创新性）声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果；也不包含为获得桂林电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：冯磊

日期：2018.06.05

关于论文使用授权的说明

本人完全了解桂林电子科技大学有关保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属桂林电子科技大学。本人保证毕业后离校后，发表论文或使用论文工作成果时署名单位仍然为桂林电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。（保密的论文在解密后遵守此规定）

本学位论文属于保密在____年解密后适用本授权书。

本人签名：冯磊

日期：2018.06.05

导师签名：张彤

日期：2018.06.05

摘要

近几年，伴随着众多新型高新技术的快速发展，智能化和自动化的需求在工业、农业和军事等领域日益增长。机器人作为众多高新技术和学科的代表也得到了迅速发展，移动机器人属于机器人的一个范畴，同样也得到了快速发展。自主导航是移动机器人智能化的标志，而移动机器人的定位和地图构建是自主导航的基本要求，所以对机器人的定位和地图构建的研究有着重大的意义和使用价值。

本文主要剖析了机器人导航中的即时定位与地图构建（SLAM）的问题，对移动机器人即时定位与地图构建的框架和数学模型进行了研究，同时针对传统算法在处理移动机器人定位和地图构建上精度和运算效率不高的问题，进行了改进。主要内容如下所示：

1、本文对移动机器人的技术背景和国内外目前取得的研究成果以及研究意义进行了介绍。对移动机器人导航中的即时定位与地图构建问题、基本原理、地图模型和常用的方法进行了概述。为了更清晰的理解移动机器人即时定位和地图构建的过程，对其进行数学建模的研究。

2、通过对移动机器人即时定位与地图构建的原理分析，对常用的基于卡尔曼滤波和基于粒子滤波的即时定位与地图构建的方法的原理进行了介绍。通过对这两种算法的理论分析，推导出其及改进算法在即时定位与地图构建上的应用。同时在仿真软件上对这两种算法进行了验证和分析，证明了这两种算法的可行性和有效性。着重提出了基于粒子滤波的快速即时定位与地图构建算法的改进，针对快速即时定位与地图构建中粒子耗尽的问题，提出了重采样和结合 UKF 计算每个粒子的提议分布的改进方法。

3、针对移动机器人即时定位与地图构建中的数据关联问题进行了改进，提出了局部圆和循环闭环的数据关联策略。将改进的算法用来解决扩展卡尔曼即时定位与地图构建中的数据关联问题，经过实验仿真，提出的改进方法对数据关联的准确性提高了。数据关联是移动机器人即时定位与地图构建的一部分，从而即时定位与地图构建的精度也相应的提高了。

4、对机器人操作系统（ROS）进行了研究，详细介绍了机器人操作系统（ROS）的架构。同时选用基于粒子滤波器的快速即时定位与地图构建算法在机器人操作系统（ROS）框架下编写功能包，实现移动机器人在机器人操作系统（ROS）下的即时定位与地图构建。

最后，本文对移动机器人即时定位与地图构建进行了总结和展望。

关键词：即时定位与地图构建；卡尔曼滤波及改进算法；粒子滤波及改进算法；数据关联；ROS

Abstract

In recent years, be accompanied by the develop rapidly of many new high technologies, the demand for intelligence and automation is increasing in the fields of industry, agriculture and military. Robot as a representative of many high-tech and disciplines has also been rapid development, mobile robot belongs to a category of robot, also has been rapid development. Autonomous navigation is the symbol of intelligent mobile robot, and the localization and map construction of mobile robot is the basic requirement of autonomous navigation, so it is meaningful and valuable to study and explore the localization and map construction of mobile robot.

This paper analyzes the simultaneous localization and mapping of mobile robot navigation in the construction of the problem of framework and mathematical model of simultaneous localization and mapping of mobile robot is studied, and the traditional algorithm, improves the real-time localization and mapping of mobile robot's accuracy and efficiency. The main contents are as follows:

1.This paper discusses the research background of mobile robots, the status and significance of the research at home and abroad. This paper introduces the problem of real-time location and map building in mobile robot navigation, and summarizes its basic principles, map models and common location methods. The motion of the mobile robot is modeled, and the real-time positioning and map building of the mobile robot are studied on its mathematical model.

2.Through the analysis of the principle of simultaneous localization and mapping of mobile robot, the simultaneous localization and map building method commonly used: Kalman filter and Particle filter are introduced the principle. Through the theoretical analysis of these two algorithms, the algorithm flow and framework of the real-time location and map building are derived. The two algorithms are simulated on the MATLAB simulation platform, and the feasibility and effectiveness of the two algorithms are verified. An improved algorithm based on particle filter for fast real-time location and map building is put forward. Aiming at particle degradation in fast real-time location and map building, an improved method of resampling and combining UKF to calculate each particle's proposal distribution is proposed.

3. According to the data association problem of simultaneous localization and mapping of mobile robot in this paper, put forward the strategy of local data association and circulation loop. The improved algorithm is used to solve the data association problem

in Kalman's real-time location and map building. The experimental simulation not only improves the performance of data association, but also improves the accuracy of robot localization.

4. The robot operating system (ROS) is studied, and the architecture of the robot operating system (ROS) is introduced in detail. At the same time, particle filter based fast location and map building algorithm is applied to write functional package under the framework of robot operation system (ROS), so as to realize real-time location and map building of mobile robot in robot operation system (ROS).

Finally, this paper summarizes and prospects the real-time localization and map construction of mobile robots.

Key words: Simultaneous Localization and Mapping; Kalman filtering and improved algorithm; Particle filtering and improved algorithm; Data association; ROS

目录

摘要	I
Abstract.....	II
目录	IV
第一章 引言	1
§1.1 研究背景和意义	1
§1.2 移动机器人的研究概述	2
§1.3 移动机器人的即时定位与地图构建概述	3
§1.4 本文的内容安排及创新点	5
§1.4.1 本文的创新点	6
第二章 SLAM 原理与相关数学模型	7
§2.1 SLAM 原理	7
§2.1.1 SLAM 原理状态	7
§2.1.2 SLAM 流程图	8
§2.2 SLAM 概率模型 ^[17]	9
§2.3 移动机器人运动模型	9
§2.4 机器人观测模型	11
§2.5 本章总结	12
第三章 基于卡尔曼滤波器的 SLAM 研究	13
§3.1 卡尔曼滤波	13
§3.1.1 卡尔曼滤波原理和算法	13
§3.1.2 扩展卡尔曼滤波简介	14
§3.1.3 Unscented 卡尔曼滤波原理和算法	15
§3.2 EKF_SLAM 算法	16
§3.3 UKF_SLAM 算法	18
§3.4 实验仿真与分析对比	20
§3.5 本章总结	23
第四章 基于粒子滤波及改进算法的 SLAM 研究	24
§4.1 粒子滤波原理和算法流程	24
§4.1.1 基本原理	24
§4.1.2 算法流程	25
§4.1.3 实验仿真与分析对比	26
§4.2 基于 Rao-Blackwellise 粒子滤波的 Fastslam 算法	27

§4.3 FastSLAM 算法的改进	29
§4.3.1 移动机器人状态估计	30
§4.3.2 环境特征估计	31
§4.3.3 重采样	32
§4.4 实验仿真与分析对比	32
§4.5 本章总结	35
第五章 SLAM 数据关联算法的研究	37
§5.1 数据关联概述	37
§5.2 最近邻算法	38
§5.3 优化最近邻数据关联算法	38
§5.3.1 局部圆闭环数据关联	39
§5.3.2 改进的 EKF_SLAM 算法	39
§5.4 仿真试验与分析	40
§5.5 本章总结	42
第六章 移动机器人 SLAM 在 ROS 框架下的运用	43
§6.1 ROS 操作系统简介	43
§6.2 ROS 框架下机器人平台	44
§6.3 本章总结	46
第七章 总结与展望	47
§7.1 总结	47
§7.2 展望	48
参考文献	49
致 谢	53
作者在攻读硕士期间主要研究成果	54

第一章 引言

§ 1.1 研究背景和意义

作为高新前沿科技，机器人的诞生是人类开创智能 2.0 时代的标志，也是人类在智能方面取得的重要成果。机器人的出现得到了各个领域的关注，它是人类在人工智能和自动化方面的重要进步。作为高新科技的代表，机器人涉及了许多学科和众多的研究课题，例如路径规划、传感器数据融合与运动控制等，并且可以应用于各种恶劣的环境中，如高污染、高噪声、高辐射等场合^[1]。不仅可以提高工作效率，而且避免了工作者在高危行业受到危害。智能机器人越来越多的应用在各行各业中，并得到了重点的关注。移动机器人是机器人的一个子集，其主要体现在移动的特性上。在自动化流水生产线上，需要大量的人力每天重复着同样的工作和步骤，不仅会让人产生焦躁感，而且在生产系统中生产效率不高，使用智能移动机器人来代替重复的工作，即可以保障生产效率又节省了开支；在家庭领域，出现了智能扫地机来代替打扫房间，节约了人的大量时间；在国防领域，智能移动机器人可以当作侦察兵完成前方环境的侦查和远距离的攻击敌人等任务^[2]。

自主导航是智能移动机器人基本的特点，即通过自身安装的传感器来对外部环境进行探测和自身状态估计，实现在未知的环境中主动的向指定的目的地移动。根据 Leonard 和 Durrant-Whyte 将移动机器人的导航任务分为四个基本问题：“Where am I?”、“What does the world looks like?”、“Where am I going?”和“ How do I get there?”^[3]。首先“Where am I”问题就是要回答机器人在哪的问题，也就是要处理的是移动机器人在什么位置的问题，解决的是移动机器人在环境中的位姿和航行舵角；其次是关于地图构建的问题，解决的是移动机器人四周运动环境是什么样子的；然后就是关于目标识别和路径规划的问题，它们解决的是移动机器人要到哪里去，以及怎样最便捷快速的到达目的地。为了完成导航任务，首先要解决的就是定位和地图构建的问题。机器人定位可以通过自身安装的编码器、惯性传感器来解决其相对于世界坐标系的位置。地图构建可以通过机器人安装的外部摄像头、激光雷达等传感器来解决其运动环境是什么样子的，构建运动环境地图。精确的环境地图是依赖于准确的定位，而准确的定位反过来又能建立更加精确的地图，定位和地图构建是相辅相成的，不能把它们单独的分开来对待。因此，移动机器人的定位和地图构建是相关的过程。

即时定位与地图构建 (Simultaneous Localization and Mapping, SLAM)，也可以称之为同时定位与地图构建 (Concurrent Mapping and Localization, CML)，SLAM 这个概念第一次被提出是在 20 世纪 80 年代^[4]。之所以很多研究者对移动机器人即时定位与地图构建进行研究和不断改进，是由于 SLAM 是实现移动机器人自主导航和自

自动驾驶的基本部分，对其研究是解决其他问题的关键。

§ 1.2 移动机器人的研究概述

移动机器人是机器人的一个子集，简单来说移动机器人是可以自动的去执行任务的一款机器装置。它可以按照使用者事先编好的程序自主运行，也可以直接由控制者手动控制，其最大的特性就是具有移动性，可以实现智能移动、智能避障、自主导航等多种功能^[5]。其发展前景和研究价值得到了国内外的普遍关注。

移动机器人的研究始于上个世纪中期以美国为代表的多个国家。由美国斯坦福研究院（SRI）开发研制出了世界上第一台自主移动机器人 Shakey, Shakey 机器人底盘使用惯性传感器采用航迹估计法来确定其运动方位，可以进行环境建模、定位并完成一定的工作任务，它的研发成功标志人类进入智能时代的大门^[6]。它的出现推动了移动机器人研发的热潮，同时促进了相关技术的发展。时至今日，世界上涌现出一大批对移动机器人研究的公司，其中以美国和日本公司为例开始研制移动机器人平台。2012 年，亚马逊斥资收购 Kiva systems 公司的机器人项目，并研发了一款用于仓库搬运的 Kiva 机器人，专注于如何利用机器人在仓库里完成网上大量的订单派发工作，节省了大量的人力用来分发商品；2014 年，美国 Fetch Robotics 机器人公司生产了一款“Freight”的自动货架车，能够在仓库中移动，对产品进行识别并将它们取下货架；日本本田公司也致力于移动机器人方面的发展，经过研究和设计出人形机器人（以 ASIMO 为代表）促进了机器人技术以及相关应用产品的研发与打造；日本的 Fanuc 发那科机器人公司专注于制作工业机器人，其研发的 Fanuc 机器人广泛应用在工业上。



图 1.1: Kiva 机器人



图 1.2: Fanuc 机器人

除了地表领域，机器人的研发也扩展到了水下、太空等多个领域。美国加州制造的 Scorpia ROV 水下机器人，可以下潜水深达到 914 米，促进了对海洋的探索；美国和苏联对太空的探索自月球计划以来，从来没有间断过，相继发射了“勇气号”火星探测机器人和“登月者”号在无人驾驶的情况下降落在月球表面，通过移动机器人上携带的多种仪器对火星和月球进行探索。

在移动机器人领域，国内的研究发展比其他国家较晚。但是在国家的重视发展之下，进步明显并取得了不错的成绩。在国家的支持下，许多公司和高校联合组建机器人实验室，研发和攻破了多个移动机器人难题。由哈尔滨工业大学研发的智能家庭清扫机器人，不仅可以自主的寻找充电站进行自主充电，而且还可以自动识别走过的路径，提高工作效率，避免重复清扫；阿里公司研发的搬货机器人，每一个机器人都有一个固定的轨迹可以自主运行到货架下，将货架运到快递员面前，节省了大量的人力，分拣效率大大提高。国内在移动机器人的发展方面也得到了丰硕的成果，有许多的科技公司在逐渐的发展壮大。

近几年，我国在太空方面，在 2013 年将“玉兔号”探测车送到了月球，在无人驾驶的情况下安全着落在月球，并在月球表面自主导航和探测；在海洋方面，沈阳自动化研究所在 2010 年，主持研制成一款新型水下机器人—北极 ARV，可进入深海无人驾驶探测，在北极考察中获取了大量科学数据。这些研究成果促进了国内移动机器人的发展，但总体而言，我国在移动机器人方面与国外还存在一定的差距。




图 1.3：阿里巴巴仓库机器人



图 1.4：北极 ARV

§ 1.3 移动机器人的即时定位与地图构建概述

移动机器人即时定位与地图构建（Simultaneous Localization and Mapping, SLAM）的问题可概述为：把机器人放在一个未知的环境中从一个位置开始运动，在移动过程中根据自身携带的传感器观测数据逐步构建周围环境地图，同时在所构建地图的基础上对机器人的位姿进行估计和更新，把机器人的即时定位与增量式的地图构建融为一体，从而实现机器人的自主定位和导航^[7]。移动机器人 SLAM 是无人驾驶和自动导航方面广泛研究的课题，也是首要解决的问题。

移动机器人 SLAM 是把定位和地图构建融为一体，定位是移动机器人实现自主导航的首要条件，其目的就是明确自身在运动环境中的位置^[8]，确定了自身的坐标之

后再进一步的运动就更加明确。传统的定位方法采用内部里程计的航迹推算法，其定位方法是当前的位置的定位是以以往的测量结果的累积，存在误差累积的问题，随着机器人步长的增大，其误差会累积，产生很大的定位误差。针对这种相对定位误差累积增大的缺点，采用组合定位的方法，并采用内外传感器相结合的形式，利用内部传感器对移动机器人进行相对定位，同时使用外部传感器对移动机器人的环境进行观测，将观测值用来更新移动机器人的定位^[9]。

地图构建是描述移动机器人的运动环境是什么样子的，地图是环境的模型。当前主要有栅格地图、拓扑地图和几何地图这三种环境模型的表达形式。栅格地图就是把移动机器人的运动环境分割成许多的小栅格，每一个分割的栅格就是环境的一部分，其中每一个栅格给一个可能值，表示该栅格被占据的概率；拓扑地图把环境表示为由拓扑节点和连接节点的边组成，其抽象度高，适合于大环境的结构化描述；几何地图简单来说就是用几何特征（点、线、面）表示运动环境，具备存储量小和表达直观的特点^[10]。地图构建依赖于机器人的定位，定位的准确性反过来又影响着地图构建的精确性，因此，移动机器人的定位和地图构建是相关的过程。

SLAM 问题简单来说就是准确估计机器人当前的状态，在已知初始状态、不同阶段外部传感器测量到的环境信息和控制输入量的条件下，通过一定的算法来准确的估计机器人当前的状态。在 SLAM 问题中，移动机器人的运动过程具有不确定性，传感器对运动环境的观测过程具有不确定性，针对 SLAM 问题的不确定性，采用基于卡尔曼滤波及改进算法和基于粒子滤波及改进算法的概率估计的方法来解决 SLAM 问题^[11]。

卡尔曼滤波是一种寻找最优线性递归估计的算法，但是使用卡尔曼滤波的系统被限制在高斯分布的线性系统中，但是现实中大部分系统是非线性系统，卡尔曼滤波的适用范围很窄，需要对其进行优化。扩展卡尔曼滤波（Extended Kalman Filter, EKF）就是卡尔曼滤波的优化算法，可以用来处理非线性系统，它是把非线性系统通过一阶泰勒级数展开转化为线性系统，从而利用卡尔曼滤波的理论来近似求出非线性系统^[12]。EKF 在地标数量较少时对机器人定位估计较准确，在地标数量较多时计算量过大而且具有很大的累计误差。

粒子滤波是采用大量离散的样本来估计系统状态后验概率密度函数的方法，其思想是贝叶斯采样估计的序列重要性采样（SIS）^[13]。粒子滤波适用于任何系统中，并且有很强适用性。随着对粒子滤波的研究，在处理 SLAM 问题上主要为基于粒子滤波算法及其改进算法研究。FastSLAM 是采用 RBPF-slam(Rao-Blackwellized Particle Filtering)分解的思想，是粒子滤波器和 EKF 滤波器相结合的算法，粒子滤波算法对机器人的位姿进行估计，利用 EKF 对环境路标的位置进行估计^[14]。相比于 EKF_SLAM 算法，FastSLAM 算法有很高的鲁棒性和计算效率，并且其适用性较广，但存在粒子匮乏的问题。因此基于粒子滤波的 FastSLAM 算法研究重点在如何克服样本的贫化的

问题。

§ 1.4 本文的内容安排及创新点

本文通过开展移动机器人 SLAM 的相关知识的研究,以及相关的数据关联算法的研究,结合上述背景与国内外研究现状,以及传统的解决 SLAM 问题的方法。对移动机器人 SLAM 问题进行了研究和探讨,主要是针对 FastSLAM 算法出现粒子耗尽的问题,提出了采用合适的提议分布并从中提取粒子和进行重采样的策略。针对 SLAM 中数据关联计算效率和准确度较低的问题,提出了局部圆闭环的数据关联策略。将改进的算法与原算法在 MATLAB 仿真平台下,进行仿真对比试验。实验结果表明,改进的算法使机器人定位精度和计算效率提高。本文的具体内容由 6 章构成:

第1章: 引言

第一章分析了移动机器人 SLAM 的原理和相关知识,阐述了其国内外研究背景和研究意义。从传统上与目前的热点两个方面,列举了 SLAM 的研究方法,还介绍了本文的主要研究工作和组织结构。

第2章: SLAM 原理与相关数学模型

根据移动机器人的工作方式和移动特性,介绍了移动机器人相关的数学模型和 SLAM 相关的数学模型,详细介绍了 SLAM 问题的运动模型和观测模型。

第3章: 基于卡尔曼滤波器的 SLAM 研究

首先简单介绍了卡尔曼滤波的原理,本章主要阐述了 SLAM 问题中传统的算法扩展卡尔曼滤波器,并在此基础上采用了非线性 SLAM 问题的无迹卡尔曼滤波器。基于 MATLAB 仿真平台,对这两种算法进行了分析对比。

第 4 章: 基于粒子滤波及改进算法的 SLAM 研究

本章介绍了 PF 的基本理论和算法流程,主要阐述了基于 Rao-Blackwellise 粒子滤波的 FastSLAM 算法,针对 FastSLAM 算法出现粒子耗尽的问题,进行了改进提议分布和重采样的策略,同时在 MATLAB 仿真平台上,对这两种算法进行了仿真对比。

第 5 章: SLAM 数据关联算法的研究

本章对 SLAM 中数据关联的算法进行了研究,对于数据关联的最近邻算法的计算效率和鲁棒性较低的弱点,进行了改进措施,采用了局部圆闭环的数据关联策略。实验仿真结果表明,将改进的算法用来解决 EKFSLAM 中的数据关联问题,不仅提高了数据关联的性能,而且提高了机器人定位的准确性。

第 6 章: 移动机器人 slam 在 ROS 框架下的运用

介绍了机器人操作系统(Robot Operating System,ROS)的结构原理,对基于 ROS 的机器人即时定位与地图构建的改进算法进行了实验,并最终在 ROS 上实现了机器人即时定位与地图构建。

最后, 对本论文课题研究工作进行了总结与展望, 并对存在的问题和下一步的改进进行了展望。

§ 1.4.1 本文的创新点

本文对基于卡尔曼滤波的 SLAM 方法、基于粒子滤波的 SLAM 方法、SLAM 数据关联以及 SLAM 在 ROS 框架下的应用进行了比较深入的研究。本文的创新点:

- (1) 介绍了基于粒子滤波的 SLAM 方法, 详细讲述了粒子滤波的改进算法基于 Rao-Blackwellise 粒子滤波的 FastSLAM 算法的框架以及具体过程, 同时针对 FastSLAM 算法存在的粒子耗尽、样本多样性的缺失和一致性降低的缺点, 对 fastSLAM 算法进行了优化。并经过仿真实验对这两种算法进行了仿真实验对比, 验证了 fastSLAM 优化算法比 fastSLAM 算法在移动机器人 SLAM 问题上具有更好的效果, 对于移动机器人位姿的估计和环境特征点估计更准确, 同时避免了粒子耗尽的现象, 保持了粒子多样性和算法的一致性。
- (2) 对 SLAM 中的数据关联过程采用了局部圆闭环的改进措施。其中, 局部圆的策略是用来提高数据关联过程中的计算效率, 闭环是用来提高数据关联的准确性。改进的措施使得数据关联的准确性提高, 同时兼顾了计算效率。
- (3) 将基于粒子滤波的 FastSLAM 算法在 ROS 框架下进行编写功能包来实现移动机器人 SLAM。在 ROS 系统上可以实时观测到机器人的位姿和地图构建的过程。

第二章 SLAM 原理与相关数学模型

移动机器人 SLAM 系统模型是研究移动机器人 SLAM 问题的基础，结合 SLAM 原理和概率解决方法对 SLAM 问题的数学模型进行了介绍，并对 SLAM 问题中包含的相关数学模型进行了定义。SLAM 系统数学模型的研究对 SLAM 方法的研究提供了理论基础。

§ 2.1 SLAM 原理

§ 2.1.1 SLAM 原理状态

SLAM 问题包括定位和地图构建这两个相辅相成的模块，机器人定位来构建环境地图，同时用构建好的环境地图来更新移动机器人的位姿。SLAM 原理结构如图 2.1 所示，在未知环境中机器人依靠其内部传感器采用航迹推算法来递推出自身的位置，同时根据外部传感器来获取环境路标，得到机器人相对环境路标的相对距离和相对角度，用得到的观测数据更新移动机器人的定位^[15]。SLAM 的过程可以简化为“预测”——“观测”——“更新”。




图 2.1 SLAM 原理结构图

其中 x_k 表示 k 时刻机器人的位姿, m_j 表示第 j 个环境特征, u_k 为 k 时刻控制输入量, z_k 为 k 时刻的观测值。机器人在 k 时刻的位姿 x_k 与上一时刻的位姿 x_{k-1} , 当前时刻的输入量 u_k 和观测值 z_k 相关。

此外, 这些信息变量集合表示为:

移动机器人 k 时刻历史的位姿集合表示为: $X_{0:k} = \{x_0, x_1, \dots, x_k\} = \{X_{0:k-1}, x_k\}$

移动机器人 k 时刻历史的控制输入量为: $U_{0:k} = \{u_0, u_1, \dots, u_k\} = \{U_{0:k-1}, u_k\}$

n 个环境特征集合为: $m = \{m_1, m_2, \dots, m_n\}$

移动机器人 k 时刻传感器观测值的集合为: $Z_{0:k} = \{z_0, z_1, \dots, z_k\} = \{Z_{0:k-1}, z_k\}$

§ 2.1.2 SLAM 流程图

移动机器人即时定位与地图构建包含许多步骤, 整个过程主要有传感器数据的获取、特征提取、数据关联和定位与地图构建。移动机器人根据当前状态和控制信息对下一时刻移动机器人位姿进行预测和环境特征的提取, 对传感器提取到的环境特征进行数据关联, 数据关联是用传感器获取的测量信息来判断与地图中的哪一个地标相对应并进行关联, 利用观测信息对移动机器人的定位进行更新和环境地图的构建^[16]。

移动机器人即时定位与地图构建的流程图如下所示:

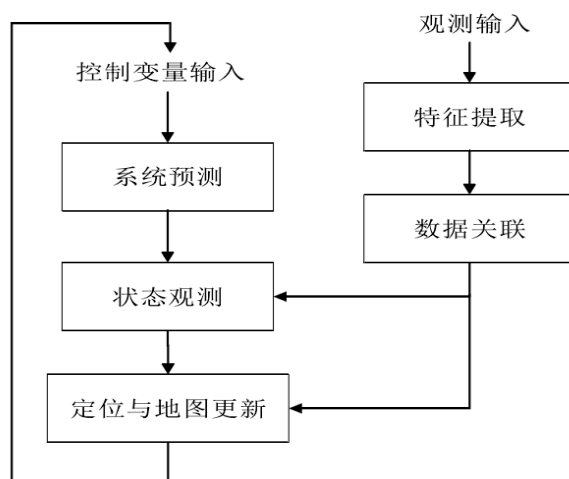


图 2.2 SLAM 流程图

移动机器人 SLAM 是一个循环迭代的过程, 定位的结果用来构建精确的运动环境地图, 精确的地图反作用于机器人位姿的更新。

§ 2.2 SLAM 概率模型^[17]

移动机器人通过内部传感器进行自身位姿的估计同时利用外部传感器获取的环境信息进行更新，同时增量式的构建地图。移动机器人 SLAM 算法用概率形式描述为一个关于路径和地图构建的后验概率分布，其公式为：

$$p(x_k, m | Z_{0:k}, U_{0:k}, x_0) \quad (2-1)$$

SLAM 算法的本质是根据传感器从 0 到 k 时刻观测得到的数据 $Z_{0:k}$ ，控制输入量 $U_{0:k}$ 和初始位姿来估计移动机器人的位姿 x_k 和环境特征 m 。SLAM 问题可以采用递推估计的方法，假设已知 $k-1$ 时刻的后验概率 $p(x_{k-1}, m | Z_{0:k-1}, U_{0:k-1}, x_0)$ ，根据贝叶斯公式和 k 时刻系统的控制输入 u_k 和 k 时刻的观测量 z_k 可计算出 k 时刻的后验概率分布：

$$p(x_k, m | Z_{0:k}, U_{0:k}, x_0) = \eta p(z_k | x_k, m) \int p(x_k | x_{k-1}, u_k) \times p(x_{k-1}, m | Z_{0:k-1}, U_{0:k-1}, x_0) dx_{k-1} \quad (2-2)$$

上式中， η 为常数， $p(z_k | x_k, m)$ 为移动机器人系统的观测模型的概率表示形式，可描述为在 k 时刻的位姿 x_k 和环境地图路标的结合 m 下，可求解观测模型。同理 $p(x_k | x_{k-1}, u_k)$ 为移动机器人系统的运动模型概率表示形式，可描述为在 $k-1$ 时刻的位姿 x_{k-1} 和 k 时刻的控制输入量 u_k 下，可求解运动模型。

§ 2.3 移动机器人运动模型

移动机器人 SLAM 过程中主要涉及到全局坐标系 $X_w O_w Y_w$ 、机器人坐标系 $X_r O_r Y_r$ 和传感器坐标系 $X_s O_s Y_s$ 这三种之间的关系和转换，如图 2.3 所示三个坐标系之间的转换关系。因传感器安装在机器人上，故机器人坐标跟传感器坐标可当作同一个坐标系。




图 2.3 移动机器人坐标系统

移动机器人的运动估计就是确定移动机器人在全局坐标系下的位姿，机器人的位姿在笛卡尔坐标系下，包括位置坐标和方向角坐标。其位姿可用三维的状态向量 $X_{v,k} = [x_{v,k}, y_{v,k}, \theta_{v,k}]^T$ 表示。其代表在 k 时刻机器人在全局坐标系下的位置为 $(x_{v,k}, y_{v,k})$ ， k 时刻移动机器人的方向角为机器人与全局坐标系 X_w 正方向的夹角 $\theta_{v,k}$ ，取值范围为 $(-\pi, \pi)$ ，机器人的方向角有正负之分，规定如下：以全局坐标系 X_w 为起点，逆时针转动为正，顺时针转动为负。

移动机器人运动模型用于描述机器人随时间变化的位姿状态向量的变换规律，在控制输入量和噪声的作用下，其运动模型的方程为：

$$X_{v,k} = f(X_{v,k-1}, u_k) + R_k$$

在上式中， $X_{v,k}$ —— k 时刻机器人的位姿

$f(\bullet)$ ——机器人系统状态转换函数，一般为非线性

$X_{v,k-1}$ —— $k-1$ 时刻机器人的位姿

R_k ——系统过程中的噪声

在仿真实验中，采用简化的运动模型来近似，移动机器人运动简化模型如下图所示：其中 (x_k, y_k, θ_k) 表示 k 时刻机器人的位姿， $(x_{k+1}, y_{k+1}, \theta_{k+1})$ 表示 $k+1$ 时刻的位姿。




图 2.4 移动机器人运动模型

假设机器人在 $k+1$ 时刻相对于 k 时刻的变化量为 $\Delta X_{v,k} = [\Delta x_{v,k}, \Delta y_{v,k}, \Delta \theta_{v,k}]^T$ ，其变化量可以由内部惯性传感器里程计、陀螺计等获得。建立机器人运动方程为：

$$X_{v,k+1} = \begin{bmatrix} x_{v,k+1} \\ y_{v,k+1} \\ \theta_{v,k+1} \end{bmatrix} = \begin{bmatrix} x_{v,k} \\ y_{v,k} \\ \theta_{v,k} \end{bmatrix} + \begin{bmatrix} \cos \theta_{v,k} & -\sin \theta_{v,k} & 0 \\ \sin \theta_{v,k} & \cos \theta_{v,k} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \Delta x_{v,k} \\ \Delta y_{v,k} \\ \Delta \theta_{v,k} \end{bmatrix} + R_k \quad (2-3)$$

以上式子表示传统的相对定位航迹推算法。航迹推算法采用惯性传感器，给出移动机器人初始位置，依靠机器人安装的内部惯性传感器递推出下一时刻的位置。这种方法是相对于上一时刻的相对定位，对于简单环境下的移动机器人的定位具有简单、快捷的优点，但由于随着机器人运动步长的增加和运动时间的增长，定位误差累积增大^[18]。

§ 2.4 机器人观测模型

移动机器人通过自身携带的传感器来获取外部环境信息用来构建环境地图，同时更新机器人的位姿，在移动机器人 SLAM 过程中，使用传感器获取环境中的地标与传感器之间的相对距离和角度^[19]。传感器测量模型可以描述为移动机器人的位姿 $X_{v,k}$ 与对环境特征的测量值之间的关系，其表达式为：

$$Z_k = h(X_k) + Q_k$$

上式中， Z_k 表示 k 时刻的测量值， $h(\bullet)$ 为观测函数， X_k 表示机器人在 k 时刻的位姿， Q_k 为观测噪声。

在简化的观测模型中，移动机器人观测简化模型如图 2.5 所示：




图 2.5 移动机器人观测模型

在移动机器人 SLAM 过程中，通常采用激光雷达观测得到环境中的地标信息，用传感器观测量 Z_k 获取路标 (x_i, y_i) 与移动机器人 $(x_{v,k}, y_{v,k})$ 之间的相对距离 r 和角度 θ 。其计算公式为：

$$Z_k = \begin{bmatrix} r \\ \theta \end{bmatrix} = \begin{bmatrix} \sqrt{(x_i - x_{v,k})^2 + (y_i - y_{v,k})^2} \\ \arctan \frac{y_i - y_{v,k}}{x_i - x_{v,k}} \end{bmatrix} + Q_k \quad (2-4)$$

§ 2.5 本章总结

本章介绍了移动机器人 SLAM 结构流程图，同时结合数学建模构建了 SLAM 问题的数学模型、移动机器人运动模型和观测模型。通过对 SLAM 问题中模型的研究为后续 SLAM 算法的研究提供了基础知识。

第三章 基于卡尔曼滤波器的 SLAM 研究

移动机器人即时定位与地图构建问题是一个概率估计的问题，根据上一章的知识，SLAM 问题是在观测数据集、控制数据集和初始位姿下的关于路径和地图构建的后验概率估计的问题。在移动机器人 SLAM 过程中，系统的状态是由机器人位姿和地图信息构成的，系统的观测是由机器人安装的传感器观测环境信息获取的观测值构成。那 SLAM 可以采用扩卡尔曼滤波器来实现。扩展卡尔曼滤波器是研究移动机器人即时定位与地图构建问题的基础理论方法。

§ 3.1 卡尔曼滤波

§ 3.1.1 卡尔曼滤波原理和算法

卡尔曼滤波 (Kalman Filter, KF)，也称为线性二次型 (Linear Quadratic Estimation, LQE)。卡尔曼滤波是一种常见的传感器数据融合算法，使用系统的运动模型、控制输入量和观测模型来对系统状态的变化量进行估计。KF 是一种寻找最优线性递归估计的算法，使用随时间观察到的一系列测量值，包含统计噪声和其他不确定性消息，并且通过估计每个时间的变量上的联合概率分布，产生对未知变量的估计，该估计往往比仅基于单个测量值的估计更精确^[20]。卡尔曼滤波算法分为状态预测和状态更新两个步骤^[21]。

卡尔曼滤波器可以根据系统的状态运动方程和观测方程进行估计，主要针对线性系统进行估计，其状态方程和观测方程为：

$$x_k = Fx_{k-1} + Bu_k + w_k$$

$$z_k = Hx_k + v_k$$

上式中： x_k ——系统 k 时刻的状态向量

F 、 B 、 H ——系统状态转移矩阵、控制输入矩阵和观测矩阵

z_k ——系统 k 时刻的观测向量

u_k ——系统 k 时刻的输入向量

w_k 、 v_k ——系统运动过程噪声和观测噪声， w_k 和 v_k 相互独立且服从于 $w_k \sim N(0, R_k)$ ， $v_k \sim N(0, Q_k)$ 。

卡尔曼滤波通过状态预测方程及时地由当前时刻系统的状态和输入量估计出下一时刻的系统状态，然后经过传感器测量获取观测信息加入到状态更新方程中得到先验估计，并最终得到系统状态的后验估计^[22]。其原理图如下所示。

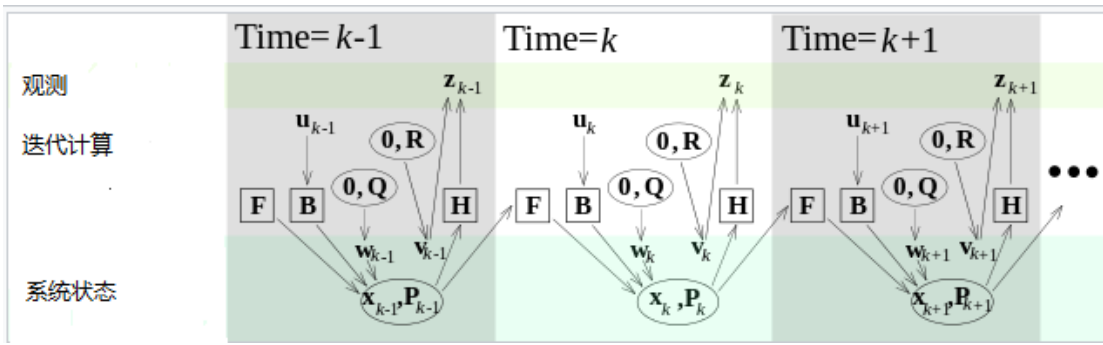


图 3.1 卡尔曼原理图

卡尔曼滤波算法的过程为：

1) 预测阶段：

$$\hat{x}_{k|k-1} = F\hat{x}_{k-1|k-1} + Bu_k \quad (3-1)$$

$$P_{k|k-1} = FP_{k-1|k-1}F^T + Q_k \quad (3-2)$$

2) 更新阶段：

$$\text{计算卡尔曼增益: } K_k = P_{k|k-1}H^T(HP_{k|k-1}H^T + R)^{-1} \quad (3-3)$$

$$\text{状态更新: } \hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k(z_k - H(\hat{x}_{k|k-1})) \quad (3-4)$$

$$\text{协方差矩阵: } P_{k|k} = (I - K_kH)P_{k|k-1} \quad (3-5)$$

基本的卡尔曼滤波是采用递推法进行计算的，不需要知道所有的值，只需要知道当前时刻的前一时刻的值进行递推，因此其在数据处理计算和存储上较小，KF 算法简单容易被实现。但是卡尔曼滤波算法（KF）被限制在符合高斯分布的线性动态系统，但是现实中大部分系统是非线性系统，这就需要对卡尔曼滤波进行改进，以便适应于非线性动态系统。

§ 3.1.2 扩展卡尔曼滤波简介

扩展卡尔曼滤波（Extended Kalman Filter, EKF）是对卡尔曼滤波算法的改进，是一种比较常用的非线性滤波方法，它是把非线性系统通过一阶泰勒级数展开保留一阶项转化为线性系统，从而利用卡尔曼滤波的理论来近似求出非线性系统^[23]。

在 EKF 算法中，系统的状态模型和观测模型不需要为系统的线性函数，而是可微函数。系统的状态模型和观测模型如下式所示：

$$x_k = f(x_{k-1}, u_k) + w_k$$

$$z_k = h(x_k) + v_k$$

其中， w_k 和 v_k 分别表示为协方差为 R_k 和 Q_k 的零均值多元高斯噪声的运动噪声和观测噪声， $f(\bullet)$ 表示为非线性系统的状态函数， $h(\bullet)$ 为非线性系统的观测函数。EKF 是通过泰勒级数将非线性函数 $f(\bullet)$ 和 $h(\bullet)$ 转化为近似线性函数，从而使用 KF 递推算

法计算系统的估计。EKF 算法由预测和更新两个阶段组成：在预测阶段，滤波器通过对上一状态的估计值，来计算当前状态的值；在更新阶段，通过传感器在当前状态采集到的观测信息，用来优化和更新当前预测值，以便得到一个更准确地估计值，使其接近真实值^[21]。

EKF 算法的过程为：

(1) 预测阶段

$$\text{状态向量的预测值: } \hat{x}_{k|k-1} = f(\hat{x}_{k-1|k-1}, u_k) \quad (3-6)$$

$$\text{预测状态向量的协方差矩阵值: } P_{k|k-1} = F P_{k-1|k-1} F^T + Q_k \quad (3-7)$$

(2) 更新阶段：

$$\text{卡尔曼增益: } K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1} \quad (3-8)$$

$$\text{状态向量的更新: } \hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k (z_k - h(\hat{x}_{k|k-1})) \quad (3-9)$$

$$\text{状态向量的协方差矩阵的更新: } P_{k|k} = (I - K_k H_k) P_{k|k-1} \quad (3-10)$$

式中， F_k 表示系统状态函数 $f(\cdot)$ 的雅可比矩阵， H_k 表示系统观测函数 $h(\cdot)$ 的雅可比矩阵，分别表示为：

$$F_k = \frac{\partial f(x, u_k)}{\partial x}$$

$$H_k = \frac{\partial h(x)}{\partial x}$$

扩展卡尔曼滤波算法可以有效的处理近似于线性系统的非线性系统，但对于强的非线性系统，扩展卡尔曼算法不稳定，甚至发散。其对于非线性系统，不是最优估计并且其扩展性不好。

§ 3.1.3 Unscented 卡尔曼滤波原理和算法

EKF 算法是通过泰勒级数的方法把非线性转化为线性函数实现递推估计，Unscented 卡尔曼滤波（UKF）是通过无迹（UT）变换来处理非线性系统，使其适用于线性系统下的 KF 算法。UKF 的本质思想是通过使用一组代表状态向量的 Sigma 点构造出系统的均值和方差，然后将得到的均值、估计方差和观测值在卡尔曼滤波器的框架下进行迭代，实现非线性系统的估计问题^[24]。

假设非线性系统的状态向量的维数为 n_x ， k 时刻系统的状态向量的均值和方差是 \hat{x}_k 和 P_k 。UKF 算法的过程为：

(1) 计算 Sigma 点

$$x_{k|k}^0 = \hat{x}_{k|k}$$

$$x_{k|k}^j = \hat{x}_{k|k} + \left(\sqrt{(n_x + \lambda) P_{k|k}} \right)_j \quad j = 1, 2, 3, \dots, n_x$$

$$x_{k|k}^j = \hat{x}_{k|k} - \left(\sqrt{(n_x + \lambda) P_{k|k}} \right)_j \quad j = n_x + 1, \dots, 2n_x \quad (3-11)$$

上式中, $\left(\sqrt{(n_x + \lambda)P_{k|k}}\right)_j$ 表示取均方根矩阵的第j列, λ 取值由下式决定。

$$\lambda = \beta^2(n_x + \kappa) - n_s \quad (3-12)$$

λ ——比例因子

β ——尺度参数, 决定 Sigma 点的散落尺度, 通常 β 取值为 1, κ 取值为 0

n_s ——表示为增广前状态向量的维数

(2) 预测阶段

状态预测值: $x_{k+1|k}^j = f(x_{k|k}^j, u_k)$

状态预测均值: $\hat{x}_{k+1|k} = \sum_{j=0}^{2n_x} w_j^{(m)} x_{k+1|k}^j$

状态预测方差: $P_{k+1|k} = \sum_{j=0}^{2n_x} w_j^{(c)} [x_{k+1|k}^j - \hat{x}_{k+1|k}] [x_{k+1|k}^j - \hat{x}_{k+1|k}]^T$

观测预测值: $z_{k+1|k}^j = h(x_{k+1|k}^j)$

观测预测均值: $\hat{z}_{k+1|k} = \sum_{j=0}^{2n_x} w_j^{(m)} z_{k+1|k}^j$

$$P_{zz} = \sum_{j=0}^{2n_x} w_j^{(c)} [z_{k+1|k}^j - \hat{z}_{k+1|k}] [z_{k+1|k}^j - \hat{z}_{k+1|k}]^T \quad (3-13)$$

$$P_{xz} = \sum_{j=0}^{2n_x} w_j^{(c)} [x_{k+1|k}^j - \hat{x}_{k+1|k}] [z_{k+1|k}^j - \hat{z}_{k+1|k}]^T \quad (3-14)$$

上式中, $w_j^{(m)}$ 为均值权值, $w_j^{(c)}$ 为方差权值, 取值范围为:

$$w_0^{(m)} = w_0^{(c)} = \frac{\lambda}{n_x + \lambda}$$

$$w_j^{(m)} = w_j^{(c)} = \frac{1}{2(n_x + \lambda)} \quad j = 1, 2, 3, \dots, 2n_x$$

(3) 更新阶段:

卡尔曼增益计算: $K = P_{xz}(P_{zz})^{-1}$ (3-15)

滤波值: $\hat{x}_{k+1} = \hat{x}_{k+1|k} + K(z_{k+1} - \hat{z}_{k+1|k})$ (3-16)

滤波方差: $P_{k+1} = P_{k+1|k} - KP_{zz}K^T$ (3-17)

UKF 比 EKF 在处理非线性系统方面较强, 不需要经过泰勒展开把非线性系统转化为线性系统, 采用 UT 变换解决非线性系统, 估计精度提高, 并且不需要计算雅可比矩阵, UKF 的收敛效果比 EKF 较好。

§ 3.2 EKF_SLAM 算法

扩展卡尔曼滤波为移动机器人 SLAM 问题提供了一个可解决性方案, EKF_SLAM 算法可描述为一个不断循环迭代估计校核的过程。基于扩展卡尔曼移动

机器人 SLAM 算法的基本思想是把移动机器人的状态位姿向量和环境地图向量结合成可扩展的联合系统状态向量，利用 EKF 对移动机器人联合状态向量做最小均方差估计，实现移动机器人位姿状态和环境地图的同时估计，并把移动机器人在观测阶段通过外部传感器观测到的新路标向量加入到联合系统状态向量中，并以此来构建环境地图同时更新移动机器人在环境中的位置^[25]。

基于扩展卡尔曼滤波的移动机器人 SLAM 算法可分为：预测阶段、观测阶段、更新阶段和数据关联四个步骤^[26]，EKF_SLAM 算法的结构图，如图 3.2 所示：

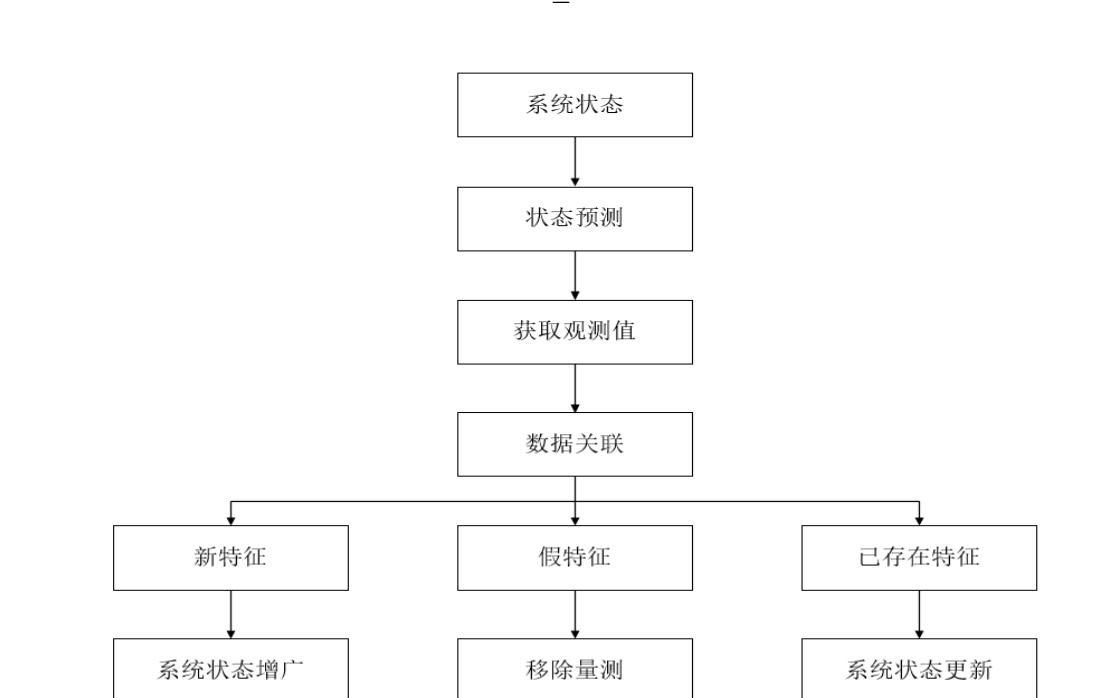


图 3.2 EKF_SLAM 算法结构图

EKF_SLAM 算法的迭代更新过程如下^[27]：

假设移动机器人在 $k-1$ 时刻的位姿为 $X_{v,k-1} = [x_{k-1}, y_{k-1}, \theta_{k-1}]^T$ ，地图特征的集合 $m = [m_1^T, m_2^T, m_3^T, \dots, m_i^T]^T$ ，其中 $i = 1, 2, 3, 4, \dots, N$ ， N 为环境特征的总个数， $m_i = [m_x^i, m_y^i]^T$ 表示第 i 个环境特征在世界坐标系的位置，则移动机器人在 k 时刻系统的联合状态向量 X_k 表示为：

$$X_k = \begin{bmatrix} X_{v,k} \\ m \end{bmatrix} = \begin{bmatrix} f(X_{v,k-1}, \mu_k) + \varepsilon_k \\ m \end{bmatrix} \quad (3-18)$$

移动机器人的运动方程模型为：

$$X_{v,k} = f(X_{v,k-1}, \mu_k) + \varepsilon_k$$

移动机器人的观测方程模型为：

$$Z_k = h(X_{v,k}) + \eta_k$$

上式中， $f(\cdot)$ 和 $h(\cdot)$ 分别表示为移动机器人的状态函数和观测函数， ε_k 和 η_k 分别表示为在运动过程中和观测过程中的噪声。

(1) 预测阶段：通过移动机器人的运动方程和 EKF 的预测估计，可估计得到 k

时刻系统的预测联合状态向量 $\hat{X}_{k|k-1}$ 和协方差矩阵 $P_{k|k-1}$:

$$\hat{X}_{k|k-1} = \begin{bmatrix} f(\hat{X}_{v,k|k-1}) \\ m \end{bmatrix} \quad (3-19)$$

$$\begin{aligned} P_{k|k-1} &= \begin{bmatrix} P_{vv} & P_{vm} \\ P_{vm}^T & P_{mm} \end{bmatrix} = E[(X_k - \hat{X}_{k|k-1})(X_k - \hat{X}_{k|k-1})^T] \\ &= \begin{bmatrix} \nabla f_x \cdot P_{vv} \cdot \nabla f_x^T + \nabla f_\mu \cdot Q_{k-1} \cdot \nabla f_\mu^T & \nabla f_x P_{vm} \\ (\nabla f_x P_{vm})^T & P_{mm} \end{bmatrix} \end{aligned} \quad (3-20)$$

其中, P_{vv} 代表移动机器人位姿的协方差估计, P_{mm} 代表地图特征位置的协方差估计, P_{vm} 表示移动机器人与路标的相互协方差估计。一般以为所观察到的路标是静止的, 即 $m_{i,k+1} = m_{i,k} = m_i$; ∇f_x 和 ∇f_μ 表示状态转换函数 $f(\cdot)$ 对移动机器人位姿 X_v 和控制输入量 μ 的雅可比函数, 其表达式为:

$$\nabla f_x = \frac{\partial f}{\partial X_v} |_{(\hat{X}_{v,k-1|k-1}, \mu_k)} \quad (3-21)$$

$$\nabla f_\mu = \frac{\partial f}{\partial \mu} |_{(\hat{X}_{v,k-1|k-1}, \mu_k)} \quad (3-22)$$

(2) 观测阶段: 移动机器人通过观测函数可求出观测预测值, 同时通过携带的外部传感器获取对环境中的真实观测值 Z_k 。

(3) 数据关联: 用来建立传感器测量与地图中已有的特征之间的匹配关系, 传感器观测到的环境路标是否为新路标或者是地图中已有的路标。若为新地标, 则加入到系统状态向量中; 若为地图中已有的路标, 确定对应于地图中的哪个路标。

(4) 更新阶段:

$$\text{计算卡尔曼增益 } K_k: \quad K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1} \quad (3-23)$$

利用观测值对预测状态向量和协方差矩阵进行更新:

$$\hat{X}_{k|k} = \hat{X}_{k|k-1} + K_k (Z_k - h(\hat{X}_{k|k-1})) \quad (3-24)$$

$$P_{k|k} = (I - K_k) P_{k|k-1} \quad (3-25)$$

其中, R_k 为观测过程中的噪声的协方差矩阵。 H_k 为观测函数 $h(\cdot)$ 对系统状态向量的雅可比矩阵, 即:

$$H_k = \frac{\partial h}{\partial X} |_{(\hat{X}_{k|k-1})}$$

EKF_SLAM 算法原理简单, 但系统噪声均服从于高斯噪声, 并且需要计算大量的雅可比矩阵, 计算复杂度高, 由于 EKF 适用于线性系统, 但 SLAM 问题是一个非线性问题, 因此存在较大的线性误差, 会导致算法发散, 不能更好的收敛于真实值。

§ 3.3 UKF_SLAM 算法

UKF_SLAM 算法是把无迹卡尔曼滤波用来解决 SLAM 问题的一种方法。由于 EKF_SLAM 算法的计算复杂度高, 并且其对于非线性系统具有较大的误差, 而

UKF_SLAM 采用 UT 变换对非线性系统进行处理，不需要去计算雅可比矩阵，在计算量和算法精度方面比 EKF_SLAM 较好^[28]。

UKF-SLAM 算法是把由机器人位姿和控制量和观测值组成的状态增广向量用一系列的 Sigma 点重构出系统的均值和方差，并以卡尔曼算法为框架，采用确定性采样的策略来逼近 SLAM 系统，UKF_SLAM 算法的具体内容如下所示^[29]：

(1) 状态向量增广：假设 k 时刻系统的状态增广矩阵为 $\hat{\mathbf{X}}_k$ ，其协方差矩阵为 \mathbf{P}_k ，移动机器人的运动方程和观测方程如上式所示。

(2) 计算 Sigma 点：

$$\begin{aligned}\chi_{k|k}^0 &= \hat{\mathbf{X}}_{k|k} \\ \chi_{k|k}^i &= \hat{\mathbf{X}}_{k|k} + \left(\sqrt{(n_x + \lambda) \mathbf{P}_{k|k}} \right)_i \quad i = 1, 2, \dots, n_x \\ \chi_{k|k}^i &= \hat{\mathbf{X}}_{k|k} - \left(\sqrt{(n_x + \lambda) \mathbf{P}_{k|k}} \right)_i \quad i = n_x + 1, \dots, 2n_x\end{aligned}\quad (3-26)$$

上式中， n_x 为状态增广矩阵的维数， λ 是状态增广前与增广后维数之差。每个 sigma 点由机器人的位姿、控制量和观测量构成^[30]。

(3) 预测阶段：

$$\text{预测状态值:} \quad \chi_{k+1|k}^i = f(\chi_{k|k}^i, \mu_k)$$

$$\text{预测状态均值:} \quad \hat{\mathbf{X}}_{k+1|k} = \sum_{i=0}^{2n_x} w_i^{(m)} \chi_{k+1|k}^i$$

$$\text{预测状态方差:} \quad \mathbf{P}_{k+1|k} = \sum_{i=0}^{2n_x} w_i^{(c)} [\chi_{k+1|k}^i - \hat{\mathbf{X}}_{k+1|k}] [\chi_{k+1|k}^i - \hat{\mathbf{X}}_{k+1|k}]^T$$

$$\text{预测观测量值:} \quad z_{k+1|k}^i = h(\chi_{k+1|k}^i)$$

$$\text{预测观测量均值:} \quad \hat{z}_{k+1|k} = \sum_{i=0}^{2n_x} w_i^{(m)} z_{k+1|k}^i$$

$$\mathbf{P}_{zz} = \sum_{i=0}^{2n_x} w_i^{(c)} [z_{k+1|k}^i - \hat{z}_{k+1|k}] [z_{k+1|k}^i - \hat{z}_{k+1|k}]^T \quad (3-27)$$

$$\mathbf{P}_{xz} = \sum_{i=0}^{2n_x} w_i^{(m)} [\chi_{k+1|k}^i - \hat{\mathbf{X}}_{k+1|k}] [z_{k+1|k}^i - \hat{z}_{k+1|k}]^T \quad (3-28)$$

式中， $w_i^{(m)}$ 和 $w_i^{(c)}$ 分别表示为均值权值和方差权值，其值为：

$$\begin{aligned}w_0^{(m)} &= w_0^{(c)} = \frac{\lambda}{n_x + \lambda} \\ w_i^{(m)} &= w_i^{(c)} = \frac{1}{2(n_x + \lambda)} \quad i = 1, 2, \dots, 2n_x\end{aligned}$$

(4) 更新阶段：

$$\text{卡尔曼增益:} \quad \mathbf{K} = \mathbf{P}_{xz} (\mathbf{P}_{zz})^{-1} \quad (3-29)$$

$$\text{更新预测值:} \quad \hat{\mathbf{X}}_{k+1|k+1} = \hat{\mathbf{X}}_{k+1|k} + \mathbf{K} (z_{k+1} - \hat{z}_{k+1|k}) \quad (3-30)$$

$$\text{更新方差值:} \quad P_{k+1|k=1} = P_{k+1|k} - K P_{zz} K^T \quad (3-31)$$

UKF_SLAM 使用 UT 变换计算状态向量的均值和协方差^[31], 其对于非线性较强的移动机器人系统具有较好的处理能力。

§ 3.4 实验仿真与分析对比

在 MATLAB 仿真平台上对基于扩展卡尔曼滤波的 SLAM 算法和基于无迹卡尔曼滤波的 SLAM 算法进行仿真实验, 仿真实验环境设置了一个 $250 \times 200m^2$ 的方形区域, 机器人在这个设定的区域内运动, 实验参数设置如表 3.1 所示, 其移动机器人的运动方程为:

$$X_{v,k} = \begin{bmatrix} x_k \\ y_k \\ \theta_k \end{bmatrix} = \begin{bmatrix} x_{k-1} + v_k \cdot dt \cdot \cos \theta_{k-1} \\ y_{k-1} + v_k \cdot dt \cdot \sin \theta_{k-1} \\ \theta_{k-1} + w_k \cdot dt \end{bmatrix} \quad (3-32)$$

本实验中外部传感器采用激光雷达, 其移动机器人的观测方程为:

$$Z_k = \begin{bmatrix} r \\ \theta \end{bmatrix} = \begin{bmatrix} \sqrt{(x_i - x_v)^2 + (y_i - y_v)^2} \\ \arctan \frac{y_i - y_v}{x_i - x_v} \end{bmatrix} + Q_k \quad (3-33)$$

表 3.1: 实验参数设置

参数	设置的数值
地图大小	$250 \times 200m^2$
移动速度	$3m/s$
最大舵角	$\pi/6rad$
控制 航向角速度	$\pi/9rad/s$
参数 采样时间	$0.025s$
车轮大小	$4m$
速度误差	$0.3m/s$
角度误差	$3rad$
控制噪声时间间隔	$0.025s$
传感 雷达扫描距离	$30m$
器参 检测路标时间间隔	$0.2s$
距离误差	$0.1m$
数 角度误差	$1rad$

假设机器人在如图 3.3 所示的区域中运动, 在图 3.3 中, 机器人的理论路径是绿色实线, ‘*’ 表示在移动机器人路径两边加入的环境路标, 设置移动机器人的位姿点数为 17 个, 环境路标点数为 35 个。


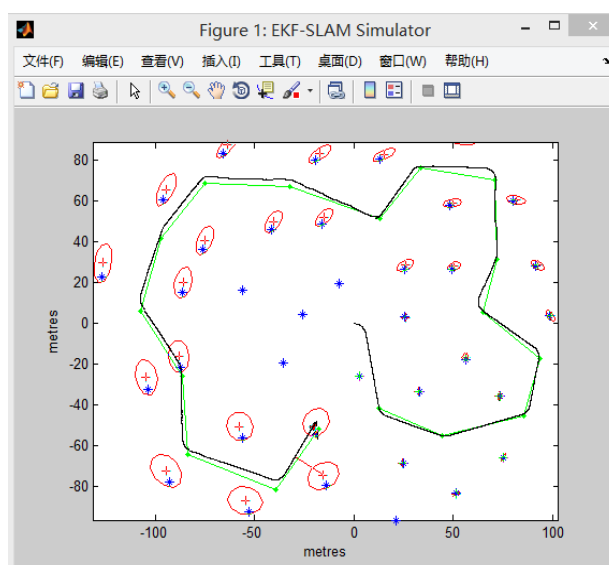
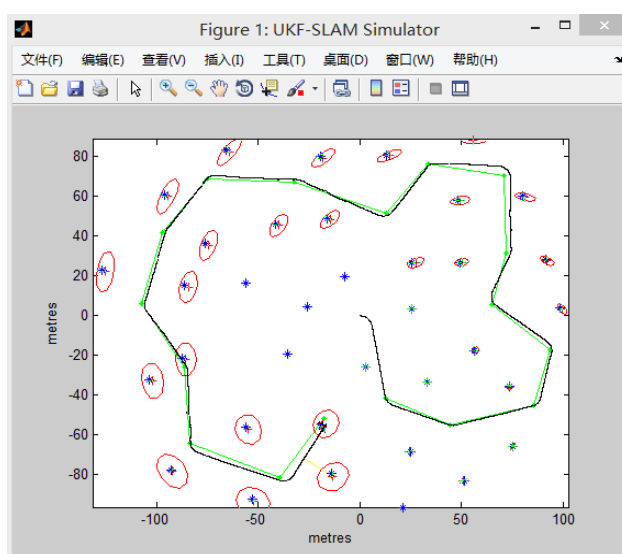


图 3.3: 移动机器人仿真环境

将 EKF_SLAM 和 UKF_SLAM 进行仿真, 仿真实验中, 移动机器人是从 $(0, 0)$ 初始位置开始逆时针运动, 每一时刻, 根据移动机器人的运动方程确定移动机器人的真实位姿, 激光雷达的扫描范围为一个半圆形区域, 位于激光雷达的扫描区域的特征会被提取出来, 相应的观测值由移动机器人的观测方程和移动机器人的真实位姿给出, 提取出来的特征跟地图特征进行最近邻数据关联。所得到的仿真图如图 3.4 表示:



(a) EKF_SLAM 仿真图



(b) UKF_SLAM 仿真图

图 3.4: (a) EKF_SLAM 仿真图、(b) UKF_SLAM 仿真图

通过对图 3.4 的仿真图可以看出,UKF-SLAM 算法对移动机器人的定位和对环境特征的估计比 EKF_SLAM 较好,由于 UKF_SLAM 不需要计算雅可比矩阵并且其计算的准确性精确到泰勒级数的二次项,故对移动机器人的定位和对环境特征的估计精确。同时可以看出机器人的估计曲线跟真实曲线有一定的误差,这两种算法的误差曲线如下图 3.5 和图 3.6 所示:




图 3.5: EKF_SLAM 误差曲线图

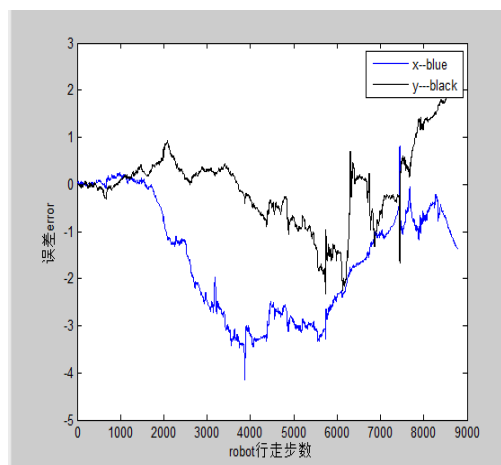


图 3.6: UKF_SLAM 误差曲线图

通过误差曲线图可以明显的看出,总体来说,UKF_SLAM 算法比 EKF_SLAM 算法在估计移动机器人的位姿和环境特征方面较好。UKF_SLAM 算法中系统状态向量的预测值跟真实值之间的误差较小,估计误差小。

§ 3.5 本章总结

本章主要介绍了卡尔曼滤波算法及其改进算法在移动机器人即时定位与地图构建问题的应用。首先，简单阐述了卡尔曼滤波（KF）、扩展卡尔曼滤波（EKF）和无迹卡尔曼滤波(UKF)的原理和算法过程，然后详细讲述了 EKF-SLAM 和 UKF_SLAM 的算法框架以及具体的算法过程。最后，对于 EKF_SLAM 和 UKF_SLAM 进行了实验仿真和分析对比，总的来说，UKF-SLAM 比 EKF_SLAM 算法在估计移动机器人位姿上更加准确。

第四章 基于粒子滤波及改进算法的 SLAM 研究

根据上一章的知识，卡尔曼滤波算法及其改进算法在解决 SLAM 问题中有许多的缺点，如适用范围是移动机器人系统中的运动噪声和观测噪声服从于高斯分布，EKF 的预测阶段是采用泰勒级数的方法，取泰勒级数的一阶项把非线性系统转化为线性系统，忽略了泰勒级数的高阶项，给移动机器人系统带来了截断误差^[32]，对移动机器人的状态估计产生较大的估计误差。SLAM 问题是在观测数据集、控制数据集和初始位姿下的关于路径和地图构建的后验概率估计的问题，那 SLAM 可以采用粒子滤波及改进算法来实现。

§ 4.1 粒子滤波原理和算法流程

§ 4.1.1 基本原理

粒子滤波(Particle Filter, PF),也称为序贯蒙特卡罗方法(Sequential Monte Carlo, SMC)是用来解决信号处理和贝叶斯统计推断中出现的滤波问题的遗传蒙特卡罗算法^[33]。粒子滤波是利用部分观测值估计系统的内部状态，也就是采用样本的概率来估计系统的概率，通过传感器观测值来调节样本的权值，从而近似全概率分布，并用样本估计的均值作为全概率值。

粒子滤波的核心思想是用在状态空间随机分布的表示状态变量概率密度函数的粒子，通过观测值对每个粒子及其权重进行更新修正，最终将所有粒子进行加权求和以获得系统状态向量的最优估计，是一种处理非线性非高斯系统的有效方法^[34]。粒子滤波使用选择采样的方法，用一组粒子也称为样本来表示在给定了噪声和部分观测值的情况下的某些随机过程的后验概率分布，状态空间模型可以是非线性，并且初始状态和噪声分布可以采取所需的任何形式，同时对于非线性系统的建模问题有更强的能力^[35]。粒子滤波使用带权值的粒子来估计非线性系统的后验概率分布，可以用来解决 SLAM 问题。

假设有一个系统，它的状态方程和测量方程如下：

$$x_k = f(x_{k-1}, \mu_k) + w_k$$

$$z_k = h(x_k) + v_k$$

其中 f 和 h 为状态函数和观测函数且已知， w_k 和 v_k 为状态方程和观测方程的噪声， x_k 为 k 时刻状态向量， z_k 为 k 时刻观测值。

粒子滤波可以解决的问题简单来说就是在已知 $h(\cdot)$ ， $f(\cdot)$ 的解析形式以及 μ_k 、 w_k 和 v_k 的条件下利用 z_k 递推估计后验分布 $p(x_{0:k}|z_{0:k})$ 。通过利用系统状态模型预测状态的

先验概率分布，也就是根据当前时刻系统的状态和输入量预测下一时刻的系统状态，然后经过传感器测量获取观测值信息，加入到状态更新方程得到后验概率分布，也就是对之前的预测进行修正^[36]。

§ 4.1.2 算法流程

粒子滤波算法是一种采样估计的统计滤波方法。假设已知上一时刻的概率密度 $p(x_{k-1}|z_{1:k-1})$ ，贝叶斯滤波的过程分为预测和更新阶段^[37]：

预测阶段：由上一时刻的概率密度 $p(x_{k-1}|z_{1:k-1})$ 得到 $p(x_k|z_{1:k-1})$ ，其过程为：

$$p(x_k|z_{1:k-1}) = \int p(x_k, x_{1:k-1}|z_{1:k-1}) dx_{k-1} = \int p(x_k|x_{k-1}, z_{1:k-1}) p(x_{k-1}|z_{1:k-1}) dx_{k-1} = \int p(x_k|x_{k-1}) p(x_{k-1}|z_{1:k-1}) dx_{k-1} \quad (4-1)$$

更新阶段：利用 k 时刻传感器获取的环境信息对上面的预测 $p(x_k|z_{1:k-1})$ 更新，得到 k 时刻系统的后验概率密度 $p(x_k|z_{1:k})$ 。

$$p(x_k|z_{1:k}) = \frac{p(z_k|x_k, z_{1:k-1}) p(x_k|z_{1:k-1})}{p(z_k|z_{1:k-1})} = \frac{p(z_k|x_k) p(x_k|z_{1:k-1})}{p(z_k|z_{1:k-1})} \quad (4-2)$$

其中归一化常数：

$$p(z_k|z_{1:k-1}) = \int p(z_k|x_k) p(x_k|z_{1:k-1}) dx_k \quad (4-3)$$

针对贝叶斯滤波算法中要用到积分的问题，为了解决积分的难题，利用蒙特卡罗采样来代替计算后验概率分布。倘若从后验概率分布中采样到 N 个粒子，则每个粒子后验概率的计算表示为：

$$\hat{p}(x_{0:k}|z_{1:k}) = \frac{1}{N} \sum_{i=0}^N \delta(dx_{0:k}) \quad (4-4)$$

上式中， $\hat{p}(x_{0:k}|z_{1:k})$ 表示 Z 观测值下的 x 概率密度， $\delta(\cdot)$ 为狄拉克函数。在实际系统中，直接从目标函数采样是不可能实现的，那么就需要构造一个近似于目标函数并且可以采样的建议分布函数 $q(x_{0:k}|z_{1:k})$ 。

分布函数可以进行如下分解：

$$q(x_{0:k}|z_{1:k}) = q(x_{0:k-1}|z_{1:k-1}) q(x_k|x_{0:k-1}, z_{1:k}) \quad (4-5)$$

后验概率密度的递推形式为：

$$p(x_{0:k}|z_{1:k}) = \frac{p(z_k|x_{0:k}, z_{0:k-1}) p(x_{0:k}|z_{0:k-1})}{p(z_k|z_{0:k-1})} = \frac{p(z_k|x_{0:k}, z_{0:k-1}) p(x_k|x_{0:k-1}, z_{0:k-1}) p(x_{0:k-1}|z_{0:k-1})}{p(z_k|z_{0:k-1})} = \frac{p(z_k|x_k) p(x_k|x_{k-1}) p(x_{0:k-1}|z_{0:k-1})}{p(z_k|z_{0:k-1})} \propto p(z_k|x_k) p(x_k|x_{k-1}) p(x_{0:k-1}|z_{0:k-1}) \quad (4-6)$$

假设系统状态符合于马尔科夫形式，并且传感器获取的测量值之间是互不相关的，则权值的计算为：

$$w_k = \frac{p(z_{1:k}|x_{0:k}) p(x_{0:k})}{q(x_k|x_{0:k-1}, z_{1:k}) q(x_{0:k-1}|z_{1:k})} = w_{k-1} \frac{p(z_k|x_k) p(x_k|x_{k-1})}{q(x_k|x_{0:k-1}, z_{1:k})} \quad (4-7)$$

通过对贝叶斯和蒙特卡罗算法的推导，粒子滤波算法的步骤如下：

a) 初始化 $k = 0$

采样 $x_0^i \sim p(x_0)$ 即根据 $p(x_0)$ 分布采样得到 x_0^i , $i=1, 2, 3, \dots, N$

b) 重要性权值计算

采样 $x_k^i \sim q(x_k | x_{0:k-1}^i, z_{0:k})$, $i = 1, 2, 3, \dots, N$

重要性权值计算如下：

$$w_k^i = w_{k-1}^i \frac{p(z_k | x_k^i) p(x_k^i | x_{k-1}^i)}{q(x_k^i | x_{0:k-1}^i, z_{0:k})}, i = 1, 2, \dots, N$$

归一化重要性权值：

$$\tilde{w}_k^i = w_k^i / \sum_{i=1}^N w_k^i$$

c) 更新概率密度函数，并对后验概率密度函数进行估计。

§ 4.1.3 实验仿真与分析对比

结合上一章所讲的扩展卡尔曼滤波和无迹卡尔曼滤波算法原理，粒子滤波算法对于非线性非高斯系统的估计具有很高的精度，为了更好的说明粒子滤波算法比扩展卡尔曼滤波算法和无迹卡尔曼算法有较高的准确性，现对 EKF、UKF 和 PF 对同一系统进行估计效果的仿真分析实验，其所采用的动态空间模型为非线性模型，公式如下所示：其中 $w(t)$ 为运动噪声方差为 10， $e(t)$ 为观测噪声方差为 1，粒子的个数为 100。

$$x(t+1) = 0.5x(t) + (25x(t) / (1 + x(t)^2)) + 8\cos(1.2t) + w(t)$$

$$y(t) = x(t)^2 / 20 + e(t)$$

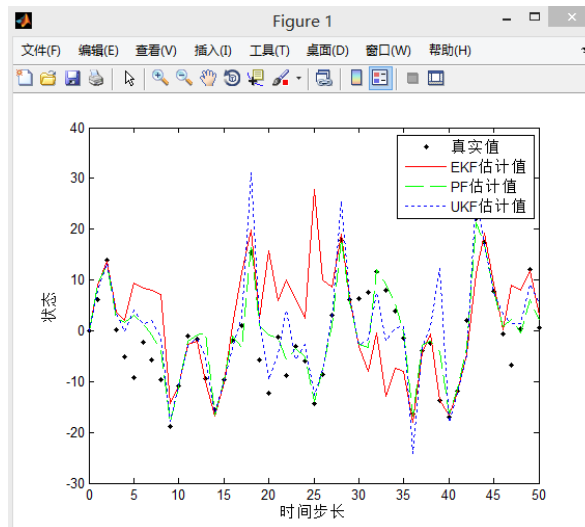


图 4.1: EKF、UKF 和 PF 系统估计值比较

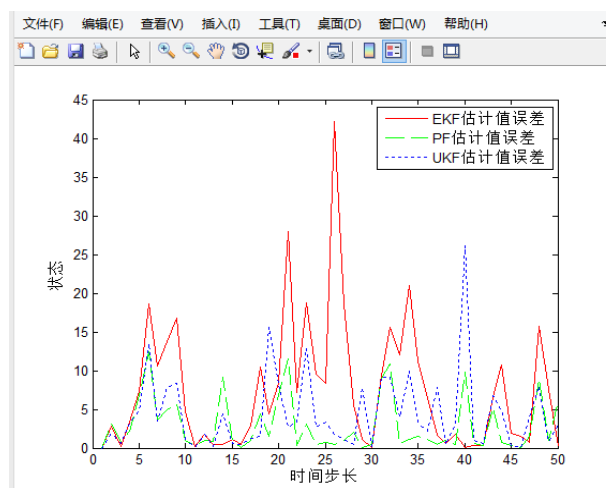


图 4.2: EKF、UKF 和 PF 估计值误差比较

图 4.1 中，黑色点代表系统的真实值，红线代表 EKF 估计值曲线，绿色虚线代表 PF 的估计值曲线，蓝色点状线代表 UKF 的估计值曲线。真实值的范围在 $(-20, 20)$ 之间，而 EKF 估计值得范围在 $(-20, 30)$ 之间，UKF 估计值得幅值范围在 $(-25, 30)$ 之间，PF 估计值的幅值范围为 $(-20, 20)$ 之间，在大部分时间里，PF 的估计值曲线比 EKF 和 UKF 很好的接近真实值状态曲线。并且从图 4.2 中，可以直观的看到 PF 的估计值误差曲线比 EKF 和 UKF 的估计误差曲线很小，更加的接近于真实值。总的来说，粒子滤波 (PF) 算法比扩展卡尔曼 (EKF) 算法和无迹卡尔曼算法 (UKF) 在系统状态估计具有较高的精度和准确性，并且粒子滤波算法的适用范围广泛。

虽然粒子滤波算法可以用来解决 SLAM 问题，但是粒子滤波算法仍然存在着一些缺点，为了能够很好的近似系统的后验概率密度需要用大量的粒子数量。而在 SLAM 问题中，移动机器人工作环境是多样且复杂的，那么描述 SLAM 问题的后验概率分布所需要的样本数量就会多，算法的复杂度就越高，计算量非常大。基于此，在 slam 研究中，粒子滤波算法主要分为 Rao-Blackwellise 粒子算法 (FastSLAM) 及其改进算法研究。

§ 4.2 基于 Rao-Blackwellise 粒子滤波的 Fastslam 算法

针对粒子滤波在高维状态空间中进行采样估计时，其计算量和复杂度大，计算效率低下的问题。Murphy 等人将系统状态向量进行分解，提出了 Rao-Blackwellise 粒子滤波，Rao-Blackwellise 粒子滤波是把状态空间向量分为两个部分，一部分状态使用 EKF 或者 UKF 解析的方法求得，另一部分状态使用粒子滤波算法的过程，从而得到了一种混合滤波器，降低了粒子滤波采样空间的维数，使其适用于高维空间，并且计算效率大大提高^[38]。

SLAM 问题是在观测数据集、控制数据集和初始位姿下的关于路径和地图构建的后验概率估计的问题 $p(x_{1:k+1}, m|z_{1:k+1}, \mu_{0:k}, x_0)$ 。其用 Rao-Blackwellise 粒子滤波的分解思想，可以对 SLAM 问题中的后验概率分布进行如下的分解：

$$\begin{aligned} p(x_{1:k+1}, m|z_{1:k+1}, \mu_{0:k}, x_0) &= p(m|x_{0:k+1}, z_{1:k+1}, \mu_{0:k})p(x_{1:k+1}|z_{1:k+1}, \mu_{0:k}, x_0) \\ &= p(x_{1:k+1}|z_{1:k+1}, \mu_{0:k}, x_0) \prod_{i=1}^M p(m_i|x_{1:k+1}, z_{1:k+1}) \end{aligned} \quad (4-8)$$

式中，M 为路标的集合。Rao-Blackwellise 粒子滤波对 SLAM 问题中的后验概率分布进行分解的思想就是将移动机器人位姿和地图的联合估计问题分解为移动机器人的位姿估计和地图估计两个部分，再将地图估计分解为 M 个相互独立的特征估计^[39]。Rao-Blackwellise 粒子滤波为解决 SLAM 问题提供了理论基础，将 Rao-Blackwellise 粒子滤波应用到移动机器人 SLAM 问题中，称之为 FastSLAM 算法。

Montemerlo 等人提出了 FastSLAM 算法，其就是 Rao-Blackwellise 粒子滤波 (RBPF) 在移动机器人 SLAM 方面的应用，该算法采用了 RBPF 算法的分解的思想，将移动机器人 SLAM 问题分解为用 PF 算法估计移动机器人的位姿，用 EKF 估计环境特征的位置，每一个 EKF 对应一个环境特征^[40]。FastSLAM 算法融合 EKF 和 PF 概率方法的优点，既降低了计算的复杂度，同时又具有较好的鲁棒性，对解决 SLAM 问题具有很好的效果。

FastSLAM 算法是将粒子滤波和扩展卡尔曼滤波结合起来的一种混合算法，其本质思想就是运用 Rao-Blackwellise 粒子滤波 (RBPF) 对移动机器人的后验概率进行因式分解，使用粒子滤波算法计算移动机器人的位姿估计 $p(x_{1:k+1}|z_{1:k+1}, \mu_{0:k}, x_0)$ ，使用扩展卡尔曼滤波算法计算环境特征的位置 $p(m_i|x_{1:k+1}, z_{1:k+1})$ ，相对与上一章所讲的 EKFSLAM 算法和 UKFSLAM 算法，FastSLAM 算法可以应用在大规模移动机器人运动的环境特征中，同时其计算效率大大提高^[41]。FastSLAM 算法的过程如下：

步骤 1 根据初始坐标随机生成 N 个粒子 x_0^i 、粒子权值 w_0^i 组成的粒子集，如下式：

$$x_0 = \{x_0^i, w_0^i\}_{i=1,2,\dots,N}, \quad x_k = \sum_{i=1}^N x_k^i w_k^i$$

步骤 2 预测移动机器人的位姿，根据 $k-1$ 时刻的粒子集 x_{k-1} 中每个粒子 x_{k-1}^i 、运动方程和控制量 u_k ，预测移动机器人在 k 时刻的近似位姿 $x_k^i \sim p(x_k|u_k, x_{k-1}^i)$ ，同时计算预测均值和方差。

步骤 3 计算粒子权重并归一化，假设采样函数用提议分布函数

$q(x_{1:k}|z_{1:k}, u_{0:k-1}, n_{0:k-1})$ ，权值的计算公式为：

$$w_k^i = \frac{p(x_{1:k}|z_{1:k}, u_{0:k-1}, n_{0:k-1})}{q(x_{1:k}|z_{1:k}, u_{0:k-1}, n_{0:k-1})}$$

最后对权重进行归一化处理：

$$w_k^i = w_k^i / \sum_{i=1}^N w_k^i$$

所采样的粒子数越多，其所计算的估计值就越接近于真实值。

步骤 4 重采样，在粒子算法中，重要性权值会出现倾斜，粒子会出现退化现象，为了改善这种算法需要对粒子进行重采样。重采样后的粒子权值为 $1/N$ 。

步骤 5 环境地标估计，FastSLAM 算法在环境特征估计上使用 EKF 算法来估计。对于每一个粒子，环境地图的估计 $p(m^i|x_{1:k}^i, z_{1:k})$ 由移动机器人的位姿 $x_{1:k}^i$ 和观测值 $z_{1:k}$ ，按照 EKF 算法进行环境地图的估计。

步骤 6 更新阶段，采用 EKF 更新各个粒子的位姿，同时更新计算各个特征的均值和方差。

FastSLAM 算法相比较于其他 SLAM 算法，在处理非线性非高斯系统上有许多的优势，并且对于移动机器人 SLAM 问题的估计精度准确，算法的鲁棒性好，同时在处理移动机器人在大规模环境中运动时的 SLAM 问题，降低了算法的复杂度，定位精度高等优点，但是也会造成粒子退化和一致性差的问题。

FastSLAM 算法中其样本权值方差随着时间和方程计算次数在不断地发生变化，从而产生样本退化的问题。样本退化就是随着运动时间和方程迭代次数的增加，样本的权值也在发生着变化，但是最终只有几个样本的权值可以表示机器人的位姿，其余的样本的权值为零，然而在迭代计算过程中那些最终没用的样本权值也参与到计算当中，这样做无疑浪费了 CPU 计算内存，而其他样本的权值几乎为零，从而产生一个退化的现象^[42]。解决样本退化的方法就是对 FastSLAM 算法进行重新采样。重采样顾名思义就是对样本进行重新选择，一方面增大那些有效的可以代表机器人位姿的样本，另一方面减少那些无用的不能代表机器人位姿的权值小的样本。虽然重采样可以解决样本退化的现象，但是也正是由于重采样，会带来样本耗尽的问题。样本耗尽是由于算法在进行多次递推迭代和重采样后，使得那些权值大的样本一直在不断地重采样，最后造成所有的样本来自于初始样本的同一个样本，使得样本的多样性不断降低，这样会导致算法在估计系统方差时逐渐减小，最后导致 FastSLAM 算法不能够满足一致性的要求^[43]。

§ 4.3 FastSLAM 算法的改进

针对 FastSLAM 算法在处理样本退化问题采用重采样的策略，造成许多权值小的

样本被删掉,而这些权值小的样本同样代表着移动机器人的位姿和地图信息也会被删掉;另一方面,那些权值大的样本经过多次重采样后,许多样本都有着同样的移动机器人位姿和地图信息,造成样本多样性的缺失和一致性降低问题^[44],同时 FastSLAM 算法的挑战是如何在减少样本的数量的同时保持估计精度的提高的问题。Unscented FastSLAM (UFastSLAM) 算法去克服 FastSLAM 算法框架存在的限制, UFastSLAM 算法是用 Unscented Transformation (UT)变化对环境特征进行初始化和 UKF 算法对环境特征的更新,同时在估计移动机器人的位姿方面,采用 UPF 算法对移动机器人进行状态估计。UFastSLAM 算法包含三个部分:移动机器人状态估计、环境特征估计和重要性权重计算。

§ 4.3.1 移动机器人状态估计

UFastSLAM 算法采用 UPF 算法用来估计移动机器人的位姿,其过程为:

状态向量的增广:

如果 $t-1$ 时刻状态向量的均值和方差为 $x_{t-1}^{[m]}$ 和 $P_{t-1}^{[m]}$, 对状态向量进行增广得到如下向量和方差。

$$x_{t-1}^{a[m]} = \begin{bmatrix} x_{t-1}^{[m]} \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} x_{x,t-1}^{[m]} \\ x_{y,t-1}^{[m]} \\ x_{\theta,t-1}^{[m]} \\ 0 \\ 0 \end{bmatrix}, \quad P_{t-1}^{a[m]} = \begin{bmatrix} P_{t-1}^{[m]} & 0 & 0 \\ 0 & Q_t & 0 \\ 0 & 0 & R_t \end{bmatrix} \quad (4-9)$$

其中, $x_{t-1}^{a[m]}$ 是状态增广向量, $P_{t-1}^{a[m]}$ 是增广方差矩阵, Q_t 和 R_t 是控制噪声和观测噪声方差。

计算 Sigma 点

$$\begin{aligned} \chi_{t-1}^{a[0][m]} &= x_{t-1}^{a[m]} \\ \chi_{t-1}^{a[i][m]} &= x_{t-1}^{a[m]} + \left(\sqrt{(L + \lambda) P_{t-1}^{a[m]}} \right)_i \quad (i = 1, 2, \dots, L) \\ \chi_{t-1}^{a[i][m]} &= x_{t-1}^{a[m]} - \left(\sqrt{(L + \lambda) P_{t-1}^{a[m]}} \right)_i \quad (i = L + 1, \dots, 2L) \end{aligned} \quad (4-10)$$

式中, $\left(\sqrt{(L + \lambda) P_{t-1}^{a[m]}} \right)_i$ 代表取均方根矩阵的第 i 列, L 为增广矩阵的维数。每个 sigma 点有状态、控制和测量三部分组成

$$\chi_{t-1}^{a[i][m]} = \begin{bmatrix} \chi_{t-1}^{[i][m]} \\ u_{t-1}^{[i][m]} \\ z_{t-1}^{[i][m]} \end{bmatrix} \quad (4-11)$$

根据移动机器人运动模型、前一时刻 sigma 点的位姿和控制量 $u_t^{[m]}$ 可以预测出下一时刻 sigma 点的位姿 $\chi_t^{[i][m]}$, 同时计算出其均值 $x_{t|t-1}^{[m]}$ 和方差 $P_{t|t-1}^{[m]}$ 。

$$\bar{\chi}_t^{[i][m]} = f\left(\chi_{t-1}^{[i][m]}, u_t^{[m]} + \chi_t^{u[i][m]}\right) \quad (4-12)$$

$$x_{t|t-1}^{[m]} = \sum_{i=0}^{2L} w_g^{[i]} \bar{\chi}_t^{[i][m]} \quad (4-13)$$

$$P_{t|t-1}^{[m]} = \sum_{i=0}^{2L} w_c^{[i]} \left(\bar{\chi}_t^{[i][m]} - x_{t|t-1}^{[m]}\right) \left(\bar{\chi}_t^{[i][m]} - x_{t|t-1}^{[m]}\right)^T \quad (4-14)$$

当一些特征被观测到时，数据关联会对这些特征进行判断，下式用观测值来更新状态估计得均值 $x_t^{[m]}$ 和方差 $P_t^{[m]}$ ：

$$z_t^{[i][m]} = h\left(\bar{\chi}_t^{[i][m]}, \mu_{k,t-1}^{[m]}\right) + \chi_t^{z[i][m]} \quad (4-15)$$

$$\hat{z}_t^{[m]} = \sum_{i=0}^{2L} w_g^{[i]} z_t^{[i][m]} \quad (4-16)$$

$$S_t^{[m]} = \sum_{i=0}^{2L} w_c^{[i]} \left(z_t^{[i][m]} - \hat{z}_t^{[m]}\right) \left(z_t^{[i][m]} - \hat{z}_t^{[m]}\right)^T \quad (4-17)$$

$$\Sigma_t^{x,n[m]} = \sum_{i=0}^{2L} w_c^{[i]} \left(\bar{\chi}_t^{[i][m]} - x_{t|t-1}^{[m]}\right) \left(z_t^{[i][m]} - \hat{z}_t^{[m]}\right)^T \quad (4-18)$$

$$K_t^{[m]} = \Sigma_t^{x,n[m]} \left(S_t^{[m]}\right)^{-1} \quad (4-19)$$

$$x_t^{[m]} = x_{t-1}^{[m]} + K_t^{[m]} \left(z_t - \hat{z}_t^{[m]}\right) \quad (4-20)$$

$$P_t^{[m]} = P_{t-1}^{[m]} - K_t^{[m]} S_t^{[m]} \left(K_t^{[m]}\right)^T \quad (4-21)$$

通过观测模型 h 和观测噪声向量 $\chi_t^{z[i][m]}$ 计算了 σ 点的观测预测值 $z_t^{[i][m]}$ 。其中 $\mu_{k,t-1}^{[m]}$ 为前一时刻第 k 个特征的重复观测值。 $\hat{z}_t^{[m]}$ 和 $S_t^{[m]}$ 表示为观测量预测均值和方差。 $\Sigma_t^{x,n[m]}$ 对应着 FastSLAM 算法中的雅可比项， $K_t^{[m]}$ 为观测更新阶段的卡尔曼增益。

§ 4.3.2 环境特征估计

特征更新阶段：使用先前特征的均值和协方差定义特征的 σ 点。

$$\begin{aligned} \chi^{[0][m]} &= \mu_{n_t,t-1}^{[m]} \\ \chi^{[i][m]} &= \mu_{n_t,t-1}^{[m]} + \left(\sqrt{(n+\lambda)\Sigma_{n_t,t-1}^{[m]}}\right)_i \quad (i = 1, \dots, n) \\ \chi^{[i][m]} &= \mu_{n_t,t-1}^{[m]} - \left(\sqrt{(n+\lambda)\Sigma_{n_t,t-1}^{[m]}}\right)_i \quad (i = n+1, \dots, 2n) \end{aligned} \quad (4-22)$$

其中 $\mu_{n_t,t-1}^{[m]}$ 是粒子初始化第 n 个特征的均值， $\Sigma_{n_t,t-1}^{[m]}$ 是第 n 个特征的协方差矩阵， n 是特征状态矩阵的维数，如果是平面上的地标，那么它的位数就是 2 维，即 $n=2$ 。

预测观测值 $\hat{z}^{[m]}$ 和卡尔曼增益 $K^{[m]}$ 的公式为：

$$\bar{Z}_t^{[i][m]} = h\left(\chi^{[i][m]}, x_t^{[m]}\right) \quad (4-23)$$

$$\hat{z}_t^{[m]} = \sum_{i=0}^{2n} w_g^{[i]} \bar{z}_t^{[i][m]} \quad (4-24)$$

$$\bar{S}_t^{[m]} = \sum_{i=0}^{2n} w_c^{[i]} \left(\bar{z}_t^{[i][m]} - \hat{z}_t^{[m]} \right) \left(\bar{z}_t^{[i][m]} - \hat{z}_t^{[m]} \right)^T + R_t \quad (4-25)$$

$$\bar{\Sigma}_t^{[m]} = \sum_{i=0}^{2n} w_c^{[i]} \left(\chi^{[i][m]} - \mu_{n_t, t-1}^{[m]} \right) \left(\bar{z}_t^{[i][m]} - \hat{z}_t^{[m]} \right)^T \quad (4-26)$$

$$\bar{K}_t^{[m]} = \bar{\Sigma}_t^{[m]} \left(\bar{S}_t^{[m]} \right)^{-1} \quad (4-27)$$

上式中， h 是观测模型函数， $x_t^{[m]}$ 是 t 时刻第 m 个粒子的位姿。 $\bar{z}_t^{[i][m]}$ 把 sigma 点通过非线性转化到极坐标上并用于计算观测值的预测 $\hat{z}_t^{[m]}$ 和协方差 $\bar{S}_t^{[m]}$ ， R_t 为测量噪声的协方差。卡尔曼增益通过 UfastSLAM 算法比通过 fastSLAM 算法要准确。最终，特征的更新均值和协方差为：

$$\mu_{n_t, t}^{[m]} = \mu_{n_t, t-1}^{[m]} + \bar{K}_t^{[m]} \left(z_t - \hat{z}_t^{[m]} \right) \quad (4-28)$$

$$\Sigma_{n_t, t}^{[m]} = \Sigma_{n_t, t-1}^{[m]} - \bar{K}_t^{[m]} \bar{S}_t^{[m]} \left(\bar{K}_t^{[m]} \right)^T \quad (4-29)$$

z_t 是用外部传感器观测到的真实测量值，通过对 UfastSLAM 算法的分析，可以看出，其不用计算特征协方差矩阵的雅可比矩阵。

特征初始化：UfastSLAM 算法在特征初始化使用当前观测值 z_t 和观测噪声矩阵 R_t 来计算 sigma 点的特征初始化。

§ 4.3.3 重采样

UfastSLAM 算法采用自适应策略的重采样，避免了由于重采样导致的粒子多样性的缺失，出现粒子耗尽的现象。UfastSLAM 算法对样本设置了一个阈值，其有效样本估计值为：

$$\hat{N}_{eff} = \frac{1}{\sum_{i=1}^N (w_i^t)^2} \quad (4-30)$$

在进行重采样时，只有当有效样本数低于样本总数的 50% 时，系统才进行重采样，避免了那些权值较小的粒子被删掉，浪费计算资源。

通过对 UfastSLAM 算法过程的详细介绍，可以看出 UfastSLAM 算法在对移动机器人即时定位与地图构建问题上比 fastSLAM 算法估计准确，减少了误差，提高了计算效率。下面通过实验对结论进行验证。

§ 4.4 实验仿真与分析对比

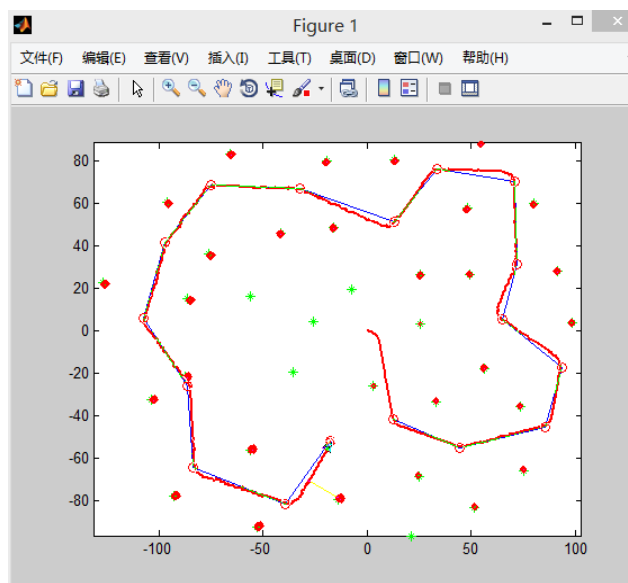
在 MATLAB 仿真平台上对 UFastSLAM 算法和 FastSLAM 算法进行仿真实验，仿真实验环境设置了一个 $250 \times 200m^2$ 的方形区域，机器人在这个设定的区域内运动，

实验参数设置如表 4.1 所示：

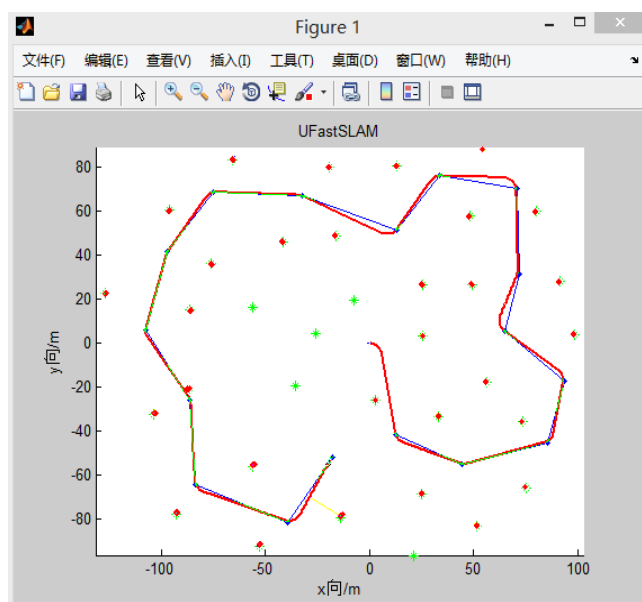
表 4.1 仿真实验参数设置

参数	设置的数值
控制 参数	地图大小
	$250 \times 200 \text{m}^2$
	移动速度
	3m/s
	最大舵角
	$\pi/6 \text{rad}$
	航向角速度
	$\pi/9 \text{rad/s}$
	采样时间
	0.025s
传感 器参 数	车轮大小
	4m
	速度误差
	0.3m/s
	角度误差
	3rad
	控制噪声时间间隔
	0.025s
	粒子样本
	60
数	重采样阈值
	45
	雷达扫描距离
	30m
数	检测路标时间间隔
	0.2s
	距离误差
数	0.1m
	角度误差
	1rad

按照表 4.1 的实验参数设置，在相同的样本数条件下使用仿真软件分别对 FastSLAM 算法和 UFastSLAM 算法进行实验分析对比。其仿真结果正如下图 4.3 所示，机器人的理论路径是蓝色实线，机器人的真实路径为红色实线，绿色 ‘*’ 表示在移动机器人路径两边加入的环境路标，设置移动机器人的位姿点数为 17 个，环境路标点数为 35 个。在仿真实验中，移动机器人是从(0, 0)初始位置开始逆时针运动，每一时刻，根据移动机器人的运动方程确定移动机器人的真实位姿，同时移动机器人使用外部传感器获取环境地标信息，相应的观测值由移动机器人的观测方程和移动机器人的真实位姿给出，将获取的环境信息提取出来的特征跟地图特征进行数据关联，同时使用观测值对移动机器人预测的位姿进行更新。



(a) fastSLAM 算法仿真结果



(b) UfastSLAM 算法仿真结果

图 4.3: (a) fastSLAM 算法仿真结果、(b) UfastSLAM 算法仿真结果

通过图 4.3 的分析可以看出, fastSLAM 算法和 UfastSLAM 算法在对移动机器人 SLAM 问题处理上都比 EKFSLAM 和 UKFSLAM 效果好, 估计出来的路径接近于真实路径。同时可以看出移动机器人的估计曲线跟真实曲线有一定的误差, 这两种算法的误差曲线如下图 4.4 和图 4.5 所示

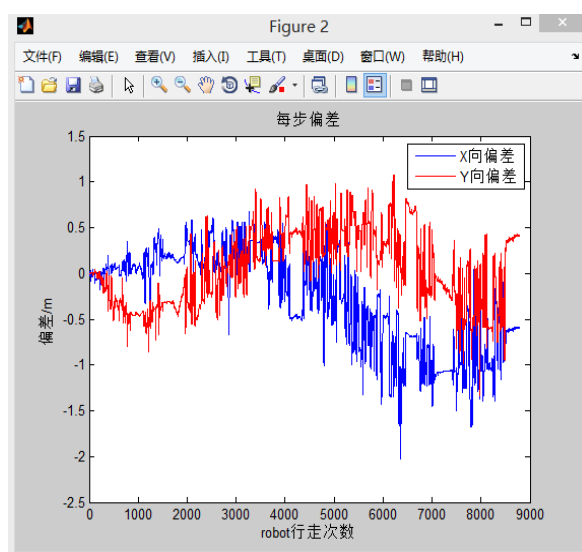


图 4.4: fastSLAM 算法误差曲线




图 4.5: UfastSLAM 算法误差曲线

通过误差曲线图可以明显的看出，总体来说，UfastSLAM 算法比 fastSLAM 算法在估计移动机器人的位姿和环境特征方面较好。UfastSLAM 算法中系统状态向量的预测值跟真实值之间的误差较小，估计误差小。

§ 4.5 本章总结

本章主要介绍了粒子滤波算法及其改进算法在移动机器人即时定位与地图构建问题的应用。首先，简单阐述了粒子滤波的原理和算法过程，然后结合了 SLAM 问题的数学模型，将粒子滤波应用到解决 SLAM 问题当中，同时与 EKF 和 UKF 进行了仿真实验对比分析，粒子滤波（PF）算法比扩展卡尔曼算法（EKF）和无迹卡尔曼

算法（UKF）在系统状态估计具有很高的精度和准确性。接着详细讲述了 PF 的改进算法基于 Rao-Blackwellise 粒子滤波的 Fastslam 算法的框架以及具体过程, FastSLAM 算法相比较于其他 SLAM 算法, 在处理移动机器人 SLAM 问题的估计精度准确, 算法的鲁棒性好, 同时在处理移动机器人在大规模环境中运动时的 SLAM 问题, 降低了算法的复杂度, 定位精度高等优点, 但是由于其粒子退化和一致性差的缺点, 对 fastSLAM 算法进行优化。对于 UfastSLAM 算法相比于 fastSLAM 算法的改进之处进行了分析。最后, 对于 fastSLAM 算法和 UfastSLAM 算法进行了实验仿真和分析对比, 通过仿真结果的对比, 在粒子数相同的情况下, UfastSLAM 算法比 fastSLAM 算法在移动机器人 SLAM 问题上具有更好的效果, 对于移动机器人位姿的估计和环境特征点估计更准确, 同时避免了粒子耗尽的现象, 保持了粒子多样性和算法的一致性。

第五章 SLAM 数据关联算法的研究

§ 5.1 数据关联概述

移动机器人 SLAM 是智能机器人实现自主导航的重要问题, SLAM 问题可以定义为一个移动机器人从一个位置在未知的环境中开始运动, 然后增量式的构建环境地图同时即时的用这个地图去计算机器人的位姿, 机器人的即时定位与增量式的地图构建融为一体, 从而完成移动机器人的自主导航^[45]。

移动机器人 SLAM 是机器人实现自主导航的研究重点, 数据关联是 SLAM 的基本组成部分和关键部分。数据关联是指建立在不同时间、不同地点所获得的传感器测量之间、传感器测量与地图特征之间的对应关系, 已确定它们是否来自同一物理实体的过程^[46]。在 SLAM 过程中, 数据关联是通过移动机器人携带的传感器经过对环境中的地标的观察所采集到的环境信息, 也就是观测值, 在更新阶段利用观测值对系统进行更新时, 需要清楚的知道这个观测值是对哪一个地标观测的, 简单来说就是建立观测值跟观测环境地标之间的一个匹配关系^[47]。数据关联一直是 SLAM 实现的一个关键问题, 在将数据融合到地图之前, 新的测量与现有的地图地标相关联, 在融合之后, 这些关联不能被修正。问题是单个错误的数据关联在地图估计中导致发散, 通常导致这个定位算法的失败。SLAM 算法要求准确的数据关联。

在机器人早期 SLAM 算法中, 最近邻数据关联算法 (nearest neighbor, NN) 被广泛使用, 其是把传感器获取到的数据单独的跟环境地图中的地标进行匹配。简单来说, 就是设置一个关联门 (阈值) 来判断环境中的地标与传感器之间的马氏距离, 如果它们之间的距离落在关联门内, 则认为它们之间是关联的, 否则不关联^[48]。最近邻数据关联算法 (NN) 原理简单, 计算复杂度小, 但是关联准确度容易受到环境中不确定性因素的影响, 鲁棒性低。还有联合相容分支定界算法 (Joint Compatibility Branch and Bound, JCBB) 和多假设跟踪算法 (multi-hypothesis tracker, MHT) 也是比较常用的数据关联算法。联合相容分支定界算法跟最近邻数据关联算法不同, 不再是把传感器获取的数据单独的跟环境地图中的地标进行关联, 而是同一时间全部的进行关联, 这样做使得它的关联准确性高于最近邻算法但是数据全部进行关联无疑使得计算量很大^[49]。多假设跟踪算法 (MHT) 是将观测特征维持多个关联假设, 通过跟踪多个假设来提高关联准确度, 然而, 假设的数目随着时间呈指数增加, 要求成指数增加的存储空间和计算资源, 不适合实时的应用^[50]。最近邻算法由于其计算量小算法简单, 是 SLAM 问题中数据关联的主要算法, 因此, 本文采用最近邻算法 (NN) 作为数据关联进行研究并改进。同时由于 EKF-SLAM 算法对数据关联很敏感, 在其上进行改进算法的仿真实验分析对比。

§ 5.2 最近邻算法

独立相容数据关联是指将观测信息中的各个观测特征单独的与地图特征进行关联,SLAM 中最常用的独立相容数据关联方法是最近邻算法(Nearest Neighbor, NN),最近邻算法是采用最近邻选择准则,选择正则距离最短的地图特征作为观测特征的最终结果^[51]。

在 SLAM 中,机器人实际观测值为 z_i ,然而地图特征 j 的计算观测值为 $\hat{z}_j = h(\hat{x}_j)$ 。第 i 个观测特征和第 j 个地图特征之间的距离用公式 5-1 表示,其中 M_{ij} 称为 Mahalanobis 距离:

$$M_{ij} = v_{ij}^T S_{ij}^{-1} v_{ij} \quad (5-1)$$

其中 v_{ij} 和 S 分别表示为实际观测值与计算观测值之差和协方差,用公式表示如下:

$$v_{ij} = z_i - h_j(\hat{x}) \quad (5-2)$$

$$S = \nabla h * P * \nabla h^T + R \quad (5-3)$$

上式中, ∇h 表示观测模型 $h(\cdot)$ 的雅克比矩阵, P 表示为状态向量的协方差, R 表示为观测过程噪声。确定观测特征和地图特征匹配的条件用下式表示为:

$$M_{ij} \leq \chi_{d,1-\alpha}^2 \quad (5-4)$$

其中 d 为 v_{ij} 的维数,对于距离传感器,观测值包括距离和方向角组成,则 $d = 2, 1 - \alpha$ 为置信水平。假如环境中有多特征跟观测信息中的特征匹配时,那这时不能把所有特征都与之对应,只能选择正则距离 N_{ij} 最小的特征 k 作为关联特征,如下式所示:

$$N_{ij} = v_{ij}^T S_{ij}^{-1} v_{ij} + \ln|S| \quad (5-5)$$

§ 5.3 优化最近邻数据关联算法

对于移动机器人在特征数量多的大规模环境中运动时,伴随着移动机器人随着时间的运动,通过传感器观测到的环境特征数量也在增多,那么系统状态向量的维数在增加,导致算法的计算效率降低和内存消耗增大,从而影响移动机器人的定位估计精度^[6]。

针对移动机器人在大规模环境中进行 SLAM 时,在标准的 EKF_SLAM 算法中数据关联鲁棒性、计算效率和定位精度低的问题,采用了局部圆域和闭环的关联策略。局部圆域就是移动机器人通过传感器观测到的特征限制在一定的范围之内,对观测范围之内环境特征进行数据关联,对超过观测范围的特征和没有关联到的环境特征进行删除,使得系统状态向量的维度保持在一个大致恒定的水平,对 EKF_SLAM 算法的实时计算有利。局部特征而不是全部特征进行数据关联,使得计算量降低,提高计算效率,同时采用闭环,提高鲁棒性。

§ 5.3.1 局部圆闭环数据关联

在 SLAM 构建地图中，地图随着传感器的扫描不断地增大，其中采集到的特征也不断增大，参与数据关联的特征随之增多，计算量相应的增加^[52]。但是，每一时刻机器人依靠外部传感器来获取外部环境特征，因此不需要把所有的特征与观测特征进行关联，提出局部圆的关联策略，其数学公式如下所示：

$$(x_i - x_v)^2 + (y_i - y_v)^2 < R^2 \quad (5-6)$$

式中， (x_i, y_i) 表示地图中的特征， (x_v, y_v) 表示机器人的位姿， R 为传感器的扫面半径。随着传感器的发展和精度的提高，采用精度和扫描范围高的激光雷达传感器，扩大其采样范围，使其在局部区域可以采集到更多的特征点，不仅降低了计算量，而且状态估计的准确性比原来有所提高。

同时采用循环闭环来提高算法的准确性。循环闭环是识别先前访问的位置并更新，其解决的问题是由于模型或算法误差而造成的定位不准确。闭环是检测新的观察到的环境确定是否到了一个曾经到过的地方，已消除定位的不准确性。

§ 5.3.2 改进的 EKF_SLAM 算法

改进的 EKF_SLAM 算法是在原 EKF_SLAM 算法基础之上对数据关联部分进行的改进，加入了局部圆闭环的策略。其算法的过程为^[52]：

1) 预测阶段：假设移动机器人在 $k-1$ 时刻的位姿为 $X_{v,k-1} = [x_{k-1}, y_{k-1}, \theta_{k-1}]^T$ ，地图特征的集合 $m = [m_1^T, m_2^T, m_3^T, \dots, m_i^T]^T$ ，其中 $i = 1, 2, 3, 4, \dots, N$ ， N 为环境特征的总的个数， $m_i = [m_x^i, m_y^i]^T$ 表示第 i 个环境特征在世界坐标系的位置，一般认为所观察到的路标是静止的，即 $m_{i,k+1} = m_{i,k} = m_i$ ，则移动机器人在 k 时刻系统的联合状态向量 X_k 表示为：

$$X_k = \begin{bmatrix} X_{v,k} \\ m \end{bmatrix} = \begin{bmatrix} f(X_{v,k-1}, \mu_k) + \varepsilon_k \\ m \end{bmatrix} \quad (5-7)$$

通过移动机器人的运动方程和 EKF 的预测估计，可估计得到 k 时刻系统的预测联合状态向量 $\hat{X}_{k|k-1}$ 和协方差矩阵 $P_{k|k-1}$ ：

$$\hat{X}_{k|k-1} = \begin{bmatrix} \hat{X}_{v,k|k-1} \\ m \end{bmatrix} \quad (5-8)$$

$$\begin{aligned} P_{k|k-1} &= \begin{bmatrix} P_{vv} & P_{vm} \\ P_{vm}^T & P_{mm} \end{bmatrix} = E[(X_k - \hat{X}_{k|k-1})(X_k - \hat{X}_{k|k-1})^T] \\ &= \begin{bmatrix} \nabla f_x \cdot P_{vv} \cdot \nabla f_x^T + \nabla f_\mu \cdot Q_{k-1} \cdot \nabla f_\mu^T & \nabla f_x P_{vm} \\ (\nabla f_x P_{vm})^T & P_{mm} \end{bmatrix} \end{aligned} \quad (5-9)$$

2) 观测阶段: 移动机器人通过携带的外部传感器获取对环境中路标进行观测, 假设对第 i 个路标的观测值为 $z_{i,k}$, 而通过移动机器人观测模型得到的观测预测值为 $\hat{z}_{j,k}$, 那么观测值的新息序列 v_{ij} 和协方差矩阵 S :

$$\hat{z}_{j,k} = h(\hat{X}_{k|k-1}) \quad (5-10)$$

$$v_{ij} = z_{i,k} - \hat{z}_{j,k} \quad (5-11)$$

$$S = \nabla h * P * \nabla h^T + R \quad (5-12)$$

3) 数据关联: 通过局部圆闭环策略, 在传感器范围内观测到的特征与地图中路标的马氏距离, 为

$$M_{ij} = v_{ij}^T S_{ij}^{-1} v_{ij} \quad (5-13)$$

判断第 i 个观测特征和第 j 个地图特征是否满足条件, 对于满足条件的路标, 选择马氏距离最短的路标作为观测路标的最佳匹配:

$$M_{ij} \leq \chi_{d,1-\alpha}^2 \quad (5-14)$$

4) 更新阶段: 计算卡尔曼增益 K_k :

$$K_k = P_{k|k-1} H_k^T (H_k P_{k|k-1} H_k^T + R_k)^{-1} \quad (5-15)$$

利用观测值对预测状态向量和协方差矩阵进行更新:

$$\hat{X}_{k|k} = \hat{x}_{k|k-1} + K_k (Z_k - h(\hat{X}_{k|k-1})) \quad (5-16)$$

$$P_{k|k} = (I - K_k) P_{k|k-1} \quad (5-17)$$


其中, R_k 为观测过程中的噪声的协方差矩阵。 H_k 为观测函数 $h(\cdot)$ 对系统状态向量的雅可比矩阵, 即:

$$H_k = \frac{\partial h}{\partial X} |_{(\hat{x}_{k|k-1})} \quad (5-18)$$


§ 5.4 仿真试验与分析

机器人从(0,0)开始逆时针速度均匀的穿过环境大小为 $250 \times 200m^2$ 的方形区域, 有 35 个路标, 机器人的速度为 $V = 3m/s$, 最大舵角为 30 度; 激光雷达的最大扫描距离和扫描频率为 30m 和 5Hz, 其他的实验参数设置于 EKF_SLAM 仿真实验参数相同。


图 5.1 是仿真环境下优化的 EKF_SLAM 算法和传统的 EKF_SLAM 算法的对比。绿线是机器人实际的路线, 黑色实线是估计的路径, *代表路标的实际位置, +字是特征估计的位置。




a.传统 EKF_SLAM 算法无闭环结果



b.优化 EKF_SLAM 算法无闭环结果



c.优化 EKF_SLAM 算法闭环 1 遍的结果



d.优化 EKF_SLAM 算法闭环 2 遍的结果

图 5.1 a.传统 EKF_SLAM 算法无闭环结果、

b.优化 EKF_SLAM 算法无闭环结果

c.优化 EKF_SLAM 算法闭环 1 遍的结果、

d.优化 EKF_SLAM 算法闭环 2 遍的结果

图 5.2 和图 5.3 是传统 EKF_SLAM 算法与优化的 EKF_SLAM 算法在相同条件下的预测位置和实际位置的误差的比较。

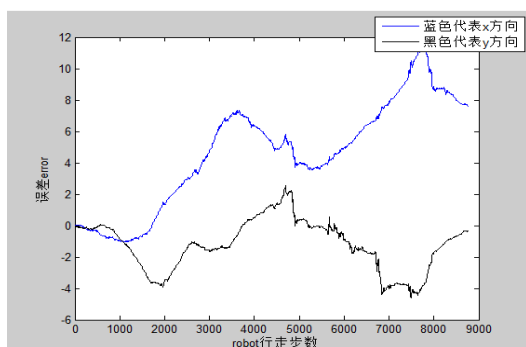


图 5.2:传统 EKF_SLAM 算法距离误差

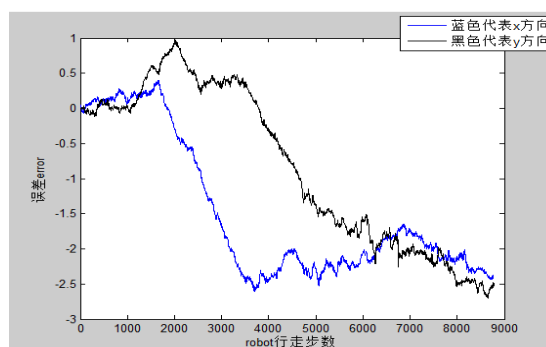


图 5.3 优化的 EKF_SLAM 算法距离误差

§ 5.5 本章总结

数据关联是移动机器人 SLAM 实现的关键环节，SLAM 的实现要求准确的数据关联，数据关联的正确与否影响着 slam 算法对状态估计的准确性。通过对最近邻算法的研究，提出局部圆闭环的数据关联。理论分析和实验表明，优化的 EKF_SLAM 算法对系统的状态估计更加准确，同时兼顾了计算效率。

第六章 移动机器人 SLAM 在 ROS 框架下的运用

移动机器人即时定位与地图构建是智能机器人自主导航的关键部分。通过上章对基于卡尔曼滤波及改进算法和基于粒子滤波及改进算法在移动机器人 SLAM 方面的分析对比,选用基于粒子滤波器的 FastSLAM 算法来完成移动机器人 SLAM。同时在 ROS 框架下编写 SLAM 软件包,使得移动机器人在 ROS 下完成即时定位与地图构建^[53]。在 ROS 的平台下进行仿真,移动机器人能够高效、实时的完成即时定位与地图构建。

§ 6.1 ROS 操作系统简介

ROS (Robot Operating System) 是一款机器人软件平台,为机器人的研究提供了开源的操作系统。ROS 对于机器人的快速发展起到了推动的作用,提供一系列程序库和工具以帮助软件开发者创建机器人应用软件,同时 ROS 也可以兼容一些外部设备,像摄像头和激光雷达采集的信息都可以在 ROS 上进行直观可视化的观察,此外 ROS 还为使用者提供了多款机器人模型,供开发者研究使用诸多功能,给开发者提供了一个简单快速机器人仿真和模拟的平台^[54]。

ROS 是高度完善且扩展性极强的机器人操作系统,包含了大量的软件包和软件开发工具,使用分布式、多级通讯和配置,实时系统调试和数据分析的处理框架^[55]。ROS 系统架构由文件系统级、计算图集和开源社区级三部分组成。

文件系统级是一个系统上代码和文件的组成形式,简单来说,就是利用包和堆来组织众多代码和文件,把系统上的代码和文件组织起来会让系统在运算速度和数据传输过程中更快,有效的管理了 ROS 系统中的众多代码,使得 ROS 系统在运行时可以更加便捷和分布式的运行,运行的文件之间互不影响^[56]。简单来说,ROS 文件系统级是 ROS 源代码以包 (package) 和堆 (stack) 的形式组织起来并便于使用者方便查看。

在 ROS 的计算图集下,进程和数据处理跟系统之间是通过点对点的网络形式进行通信的,这种点对点的通信方式使得数据在传输过程中更加快速和便捷。计算图集有几个重要概念如图 6.1 所示。节点相当于一个可以运行的文件,它是 ROS 实现某种功能的名称,例如用来驱动外部连接硬件的驱动程序或者让机器人的某个关节运动都可以作为节点,ROS 的框架就是有许多个节点组成的。每一个节点之间的联系或者说它们之间的数据传输是通过信息进行发布和订阅的,信息就是控制节点运行的程序和数据结构;控制节点的运行可能需要很多信息进行传输,许多信息的组合就是为了实现节点的某一个功能,把实现节点某个功能的信息组合起来并同时起个名字就是

主题，简单来说，主题就是用来描述消息内容的名字；节点用来发布主题的称为发布者，而用来接收主题的称为订阅者，节点之间可以通过主题的订阅与发布来进行彼此之间的消息传输；而服务是节点之间另外一种通信方式，其主要是一种一对一并且是双向的模式^[57]。

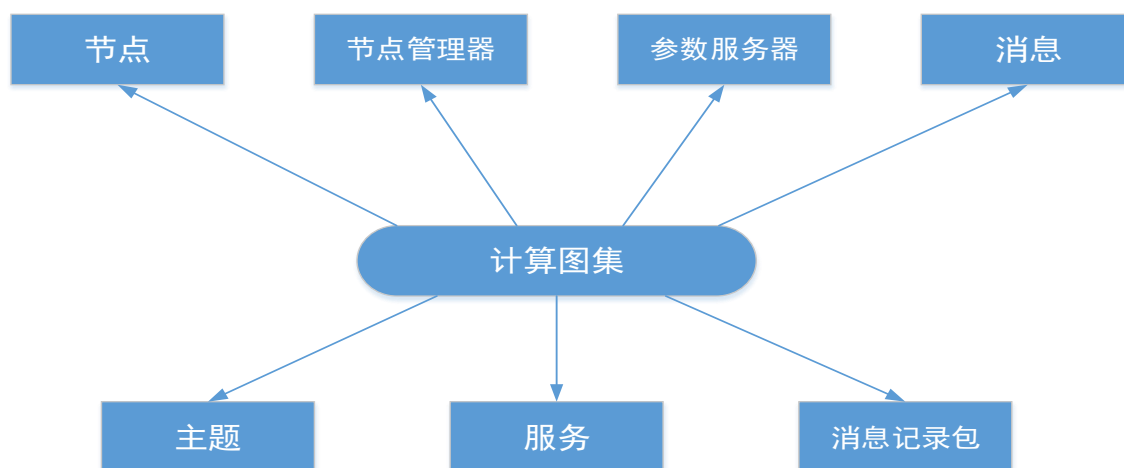


图 6.1: ROS 计算图结构

ROS 的社区级概念是 ROS 允许用户在网络上进行代码发布的一种表现形式，允许使用者可以把 ROS 的资源在不同的社交平台之间进行交流和交换，类似于一个社交平台，使用者可以把 ROS 的一些理念、知识、代码或者在运行 ROS 过程中遇到的问题上传，同时也可以下载和发布^[58]。这种平台便于使用者之间的交流和信息的共享，并且 ROS 社区还有指定的人对其进行更新和管理，这样也促进 ROS 迅速发展。

§ 6.2 ROS 框架下机器人平台

在 ROS 框架下进行移动机器人即时定位与地图构建实验，首先需要创建一个机器人模型，ROS 为使用者提供了许多款的机器人，像 Pr2 机器人、Turtlebot 机器人等，用户只需要从库里进行调用就可以。同时 ROS 还可以让使用者通过代码创建或者通过 Solidworks 来创建机器人。本实验通过代码创建了一个简单的四轮移动机器人模型，如下图 6.2 所示，用来执行移动机器人即时定位与地图构建。其中在机器人模型中，base_footprint 用来描述机器人在环境中的位姿，base_link 用来表示机器人本体的坐标系，laser_link 表示激光雷达的坐标系，坐标系之间是通过 TF 进行转换的。




图 6.2: ROS 机器人模型

通过前几章对机器人 SLAM 算法的比较和分析，可知基于粒子滤波的 FASTSLAM 算法在处理机器人 SLAM 方面有许多的优势，故采用 FastSLAM 算法在 ROS 框架下，编写和改进 gmapping 功能包来实现移动机器人的 SLAM 仿真运动实验。ROS 操作系统给移动机器人提供了使用激光雷达的外部传感器的 SLAM 功能包，其在 ROS 中是以 SLAM 包的形式存放在 slam_gmapping 中。使用 slam_gmapping 可以创建一个覆盖网络地图（Occupancy Grid Map, OGM），每当机器人移动时，SLAM_GMAPPING 节点都会更新地图状态，或者更详细的说，是在机器人移动之后，它会更新激光雷达和里程计数据，并在机器人的位置估计和地图的计算上获得更优的计算结果，并将 OGM 发布到屏幕上显示^[59]。如图 6.3 所示，是在 ROS 下导航的结构图。矩形和圆表示 ROS 下的不同节点，其余的表示 ROS 下的消息类型。

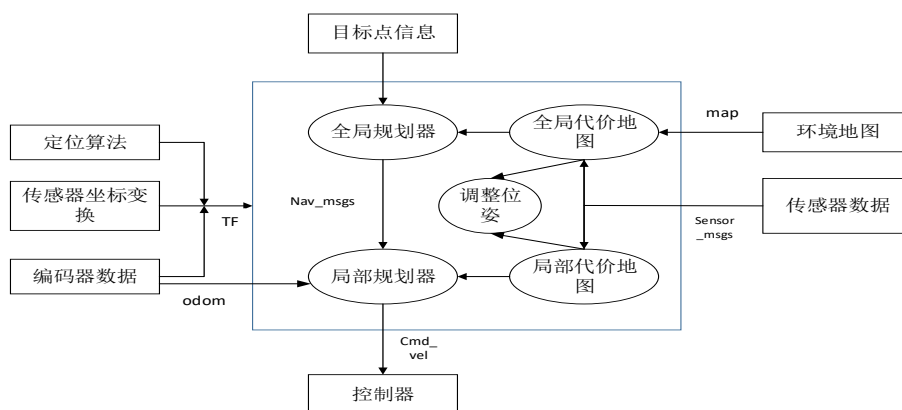


图 6.3: ROS 导航结构图

按照 ROS 系统提供的 SLAM 所需功能包进行配置和编写代码，在 slam_gmapping 功能包中的定位算法采用基于粒子滤波的 FastSLAM 算法来对构建的移动机器人进行定位，同时采用激光雷达作为移动机器人外部传感器来采集运动环境中的特征并创建运动环境模型栅格地图^[60]。图 6.4 为在 ROS 框架下通过配置 SLAM 功能包来驱动构建的移动机器人模型的运动，并利用构建机器人模型上的外部传感器激光雷达模型采集环境信息来建立的部分地图和对机器人的定位的更新。在 ROS 中可以直观可视化的看到机器人构建的环境地图模型和机器人实时的位姿。

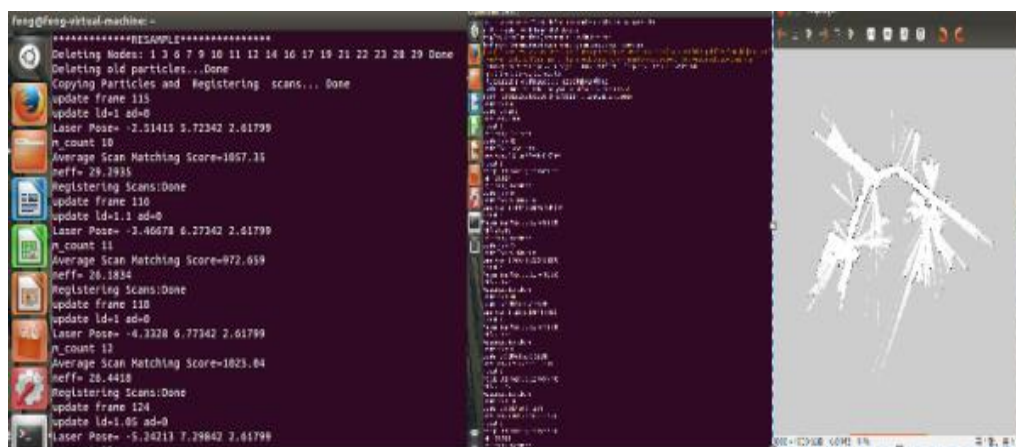


图 6.4: ROS_SLAM

通过在 ROS 框架下的仿真实验，解决了移动机器人即时定位与地图构建问题。因 ROS 的实现原理只需较少的计算量和内存，实现了数据之间的同步性和实时性问题，可以快速更新机器人位姿和状态协方差矩阵。并且 ROS 系统具有较高的兼容性，可以方便的移植到其他系统，具有较好的开发效率。

§ 6.3 本章总结

本文对 ROS 系统进行了介绍，同时对基于 ROS 操作系统下的移动机器人即时定位与地图构建进行了简要的阐述。在 ROS 系统上利用自己构造的移动机器人，通过改进系统中的 SLAM_Gmapping 软件包，实现了移动机器人即时定位与地图构建，达到了较理想的结果。

第七章 总结与展望

§ 7.1 总结

移动机器人即时定位与地图构建 (SLAM) 是机器人实现自主导航的关键部分, 具有重要的研究价值和意义。因而本文对移动机器人 SLAM 技术的研究现状和基本理论进行了介绍, 着重阐述了解决移动机器人 slam 问题的算法, 讨论了基于扩展卡尔曼滤波的 EKF_SLAM 算法、无迹卡尔曼滤波 UKF_SLAM 算法、基于粒子滤波的 FastSLAM 算法和改进 FastSLAM 算法的 UFastSLAM 算法, 并对这些算法的原理和过程进行了推导, 同时对这些算法进行了仿真实验对比。最后基于 ROS 系统实现了移动机器人即时定位与地图构建实验。本文的主要工作可总结如下:

(1) 首先介绍了 SLAM 原理系统图和流程图, 同时构建了 SLAM 问题中的概率模型、移动机器人运动模型和机器人观测模型。通过对 SLAM 问题中模型的研究为后续 SLAM 算法的研究提供了基础知识。

(2) 接着阐述了卡尔曼滤波及其改进算法在移动机器人 SLAM 方面的应用。阐述了卡尔曼滤波、扩展卡尔曼滤波和无迹卡尔曼滤波的原理和算法过程, 详细讲述了 EKF-SLAM 和 UKF_SLAM 的算法框架以及具体过程。最后, 对于 EKF_SLAM 和 UKF_SLAM 进行了实验仿真和分析。

(3) 然后介绍了粒子滤波算法及其改进算法在移动机器人即时定位与地图构建问题的应用。首先, 简单阐述了粒子滤波的原理和算法过程, 然后结合了 SLAM 问题的数学模型, 将粒子滤波应用到解决 SLAM 问题当中, 同时与 EKF 和 UKF 进行了仿真实验对比分析。接着详细讲述了粒子滤波的改进算法基于 Rao-Blackwellise 粒子滤波的 Fastslam 算法的框架以及具体过程, 同时针对 FastSLAM 算法的缺点, 对 fastSLAM 算法进行了优化。对于 UfastSLAM 算法相比于 fastSLAM 算法的改进之处进行了详细的描写和算法推导。最后, 对于 fastSLAM 算法和 UfastSLAM 算法进行了实验仿真和分析对比。

(4) 数据关联是 SLAM 问题的关键环节之一, 数据关联的正确与否影响着 slam 算法对状态估计的准确性。通过对最近邻算法的研究, 采用局部圆闭环的数据关联。理论分析和实验表明, 优化的 EKF_SLAM 算法对系统的状态估计更加准确, 同时兼顾了计算效率。

(5) 最后基于 ROS 系统进行了介绍, 并且在 ROS 系统上利用自己构造的移动机器人, 通过改进系统中的 SLAM_Gmapping 软件包, 实现了移动机器人即时定位与地图构建。

§ 7.2 展望

伴随着科学技术和人工智能技术的快速发展,移动机器人即时定位与地图构建也取得了重要研究成果,但真正实现移动机器人的精准定位和高精度构图还存在一些待解决的问题。未来 SLAM 发展的方向主要从以下几个方面:

(1) 动态目标三维环境下 SLAM 问题。动态目标的存在是三维环境下主要的难题之一,而目前移动机器人即时定位与地图构建主要是基于二维环境,对于动态目标的处理没有实现即时性。

(2) 多传感器数据融合。目前传感器的种类有很多,像摄像机、激光雷达和 GPS 等,都可以作为移动机器人的外部传感器,怎样把多传感器的采集信息进行融合,提高移动机器人的定位精度是目前研究的主要问题。

总的来说,移动机器人即时定位与地图构建的研究仍然具有很大的研究意义和挑战。

参考文献

- [1] 夏翠萍. 移动机器人的同时定位与地图构建方法研究[D]. 燕山大学,2015.
- [2] 郑丽楠. 移动机器人同时定位与地图构建方法研究[D]. 南昌: 华东交通大学学位论文,2012.
- [3] Hugh Durrant-Whyte,Tim Bailey. Simultaneous Localization and Mapping: Part I[J]. IEEE Robotics & Automation Magazine,2006:99-108.
- [4] Hugh Durrant-Whyte,Tim Bailey. Simultaneous Localization and Mapping: Part II[J]. IEEE Robotics & Automation Magazine,2006:108-117.
- [5] 朱晓辉. 轮式仿人机器人导航与路径规划研究[D]. 上海: 上海交通大学,2012.
- [6] 唐俊淮. 移动机器人同时定位与地图构建研究[D]. 浙江: 浙江工业大学,2014
- [7] 曾品善,妙全法,徐磊. 自主移动机器人即时定位与地图构建方法研究[J]. 电子科技,2013:177-179.
- [8] 夏汉均. 基于 ROS 的机器人即时定位与地图构建技术研究[D]. 东北: 东北大学, 2013
- [9] 王珊珊. 轮式移动机器人控制系统设计[D]. 南京: 南京理工大学,2013
- [10] 杨倩,宋柯,章桐. 移动机器人三维地图创建的仿真研究[J]. 机电一体化,2015(11): 17-22
- [11] 康俊民. 城市环境下无人车自主定位关键技术研究[D]. 长安大学,2016
- [12] Xiaotong Xie, Yao Yu, Xiaobo Lin, Changyin Sun. An EKF SLAM algorithm for mobile robot with sensor bias estimation[J]. 2017 32nd Youth Academic Annual Conference of Chinese Association of Automation (YAC),2017:281-285.
- [13] 朱志宇. 粒子滤波算法及其应用[M]. 北京: 科学出版社, 2010,19-63,193-150
- [14] Hector Barron-Gonzalez, Tony J Dodd. RBPF_SLAM based on probabilistic geometric planar constraints[J]. 2010 5th IEEE International Conference Intelligent Systems,2010:260-265.
- [15] G. Dissanayake, P. Newman, H.F. Durrant-Whyte, S. Clark, and M. Csobra, A solution to the simultaneous localization and mapping problem[J]. IEEE Trans. Robot. Automat., vol. 17, no. 3, pp.229–241, 2001
- [16] 魏杨. 基于激光雷达的即时定位与制图技术[D]. 哈尔滨工业大学,2017.
- [17] 徐曙. 基于 SLAM 的移动机器人导航系统研究[D]. 华中科技大学,2014.
- [18] 赵黎明. 智能移动机器人的定位与环境建模研究[D]. 重庆邮电大学,2011.
- [19] 雷碧波. 基于 ROS 平台的室内定位算法设计与实现[D]. 浙江理工大学,2016.
- [20] 陈晓燕,程志江,姜波,朱玉龙. 基于多传感器信号融合的数字滤波[J]. 电气传动,

- 2015,12:54-57.
- [21] 杨承凯,曾军,黄华. 多传感器融合中的卡尔曼滤波探讨[J]. 现代电子技术, 2009,14:159-162
- [22] Feng Zhang; Siqi Li; Shuai Yuan; Enze Sun; Languang Zhao. Algorithms analysis of mobile robot SLAM based on Kalman and particle filter[J]. 2017 9th International Conference on Modelling, Identification and Control (ICMIC),2017:1050-1055.
- [23] Darko Trivun, Edin Šalaka, Dinko Osmanković,et. Active SLAM-based algorithm for autonomous exploration with mobile robot[J]. Industrial Technology (ICIT), 2015 IEEE International Conference on,2015(3):17-19.
- [24] 许迅雷. 无迹卡尔曼滤波(UKF)的应用比较分析[J]. 西安文理学院学报: 自然科学版,2011,14(2):57-60
- [25] Zeyneb Kurt Yavuz; Sirma Yavuz. Improvement of the measurement update step of EKF-SLAM[J]. 2012 IEEE 16th International Conference on Intelligent Engineering Systems (INES),2012:61-65.
- [26] 薛永胜,张华,霍建文. EKF-SLAM 算法的改进及其在 Turtlebot 的实现[J]. 西南科技大学学报,2015:54-59.
- [27] Ankit A. Ravankar; Yukinori Kobayashi; Takanori Emaru. Clustering Based Loop Closure Technique for 2D Robot Mapping Based on EKF-SLAM[J]. 2013 7th Asia Modelling Symposium,2013:72-73
- [28] 陈晨,程荫杭. 基于迭代无迹卡尔曼滤波的 SLAM 算法仿真研究[J]. 系统仿真学报,2012,24(8):1643-1670
- [29] R. Havangi; M. A. Nekoui; H. D. Taghirad; M. Teshnehlab. SLAM based on intelligent unscented Kalman filter[J]. The 2nd International Conference on Control, Instrumentation and Automation,2011:877-882
- [30] Julier S J,Uhlmann J K. Unscented filter and nonlinear estimation[J].Proceeding of the IEEE,2004,92(3):401-422
- [31] Liping Qu; Shuiqing He; Yongyin Qu. An SLAM algorithm based on improved UKF[J]. 2012 24th IEEE Chinese Control and Decision Conference (CCDC),2012:4154-4157.
- [32] 刘洞波. 移动机器人粒子滤波定位与地图创建方法研究[D]. 湖南大学,2012.
- [33] 曹蓓. 粒子滤波改进算法及其研究应用[D]. 中国科学院研究生院,2012.
- [34] 郭剑辉, 赵春霞. 一种新的粒子滤波 SLAM 算法[J]. 计算机研究与发展,2008,45(5):853-860
- [35] 胡士强,敬忠良. 粒子滤波原理及其应用[M]. 北京: 科学出版社,2010,1-52
- [36] M. Sanjeev Arulampalam, Simon Maskell, Neil Gordon, and Tim Clapp. A Tutorial

- on Particle Filters for Online Nonlinear/Non-Gaussian Bayesian Tracking[J]. IEEE TRANSACTION ON SIGNAL PROCESSING.2002,174-188.
- [37] Sebastian Thrun. Probabilistic robotics[M]. Communications of the ACM . 2002.
- [38] 罗元,傅有力,程铁凤. 基于改进 Rao-Blackwellized 粒子滤波器的同时定位与地图构建[J]. 控制理论与应用,2015(32):267-272..
- [39] Keith Y. K. Leung,Felipe Inostroza, Martin Adams. An Improved Weighting Strategy for Rao-Blackwellized Probability Hypothesis Density Simultaneous Localization and Mapping[J]. 2013 International Conference on Control, Automation and Information Sciences (ICCAIS),2013:103-110
- [40] Grisetti Giorgio, Cyrill Stachniss, Wolfram Burgard. Improved techniques for grid mapping with Rao-Blackwellized particle filters[J]. IEEE Transactions on Robotics, v.23, no.1, 2007 Feb, p.34(13) (ISSN: 1552-3098)
- [41] Abdallah Hammad,Shimaa S. Ali,Adly S. Tag Eldien. A novel implementation for FastSLAM 2.0 algorithm based on cloud robotics[J]. 2017 13th International Computer Engineering Conference (ICENCO),2017:184-189.
- [42] Montemerlo M,Thrun S,Koller D,et al. FastSLAM: A factored solution to the simultaneous localization and mapping problem[J].Proceeding ofthe AAAI National Conference on Artificial Intelligence,Edmonton,Canada,2002.593-598
- [43] 左军毅,张怡哲,梁彦.自适应不完全重采样粒子滤波器[J]. 自动化学报, 2012,38(4):647-651.
- [44] 冯驰,王荫,汲清波. 粒子滤波器重采样算法的分析与比较[J]. 系统仿真学报, 2009,21(4):1101-1106.
- [45] 李晨曦,张军,靳欣宇,李强. 激光雷达 SLAM 技术及其在无人车中的应用研究进展[J]. 北京联合大学学报,2017(31):61-69.
- [46] 田舒. 数据关联技术在 AUV 同时定位与地图构建算法中的应用[D]. 中国海洋大学,2011.
- [47] Neira J, Tardos J D. Data association in stochastic mapping using the joint compatibility test[J]. IEEE Transactions on Robotics and Automation, 2001,17(6):890-897.
- [48] Wu Zhou, Shiju E, Zhenxin Cao, Ying Dong. Review of SLAM Data Association Study[J]. Proceeding of 6th International Conference on Sensor Network and Computer Engineering,2016:14-19
- [49] Rex H. Wong, Jizhong Xiao, Samleo L. Joseph. An adaptive data association for robotic SLAM in search and rescue operation[J]. 2011 IEEE International Conference on Mechatronics and Automation,2011:997-1003.

-
- [50] 周武. 面向智能移动机器人的同时定位与地图创建研究[D]. 南京: 南京理工大学,2009
- [51] Sean L.Bowman, Nikolay Atanasov, Kostas Daniilidis, George J. Pappas. Probabilistic data association for semantic SLAM[J]. 2017 IEEE International Conference on Robotics and Automation (ICRA),2017:1722-1729.
- [52] 李延炬,肖宇锋,古松,等. 基于激光传感器的 SLAM 数据关联算法的研究[J]. 微型机与应用,2017,36(2):78-82.
- [53] <http://blog.csdn.net/chenxingwangzi/article/details/49802763>
- [54] ROS Wiki: documentation[EB/OL].(2017-7-10):<http://wiki.ros.org>.
- [55] Yassin Abdelrasoul, Abu Bakar Sayuti HM Saman, Patrick Sebastian. A Quantitative Study of Tuning ROS Gmapping Parameters and Their Effect on Performing Indoor 2D SLAM [J]. Robotics and Manufacturing Automation (ROMA), 25-27 Sept. 2016
- [56] 张鹏. 基于 ROS 的全向移动机器人系统设计与实现[D]. 中国科学技术大学,2017.
- [57] 董学会. 基于 ROS 的移动服务机器人进门过程关键技术研究[D]. 哈尔滨工业大学,2016.
- [58] Jo~ao Machado Santos, David Portugal and Rui P. Rocha. An Evaluation of 2D SLAM Techniques Available in Robot Operating System[J]. Safety, Security, and Rescue Robotics (SSRR), 21-26 Oct. 2013
- [59] <https://blog.csdn.net/wangchao7281/article/details/53647481>
- [60] 刘锦涛, 张瑞雪等译. ROS 机器人程序设计 (原书第 2 版) [M]. 北京: 机械工业出版社, 2016.9

致 谢

转眼间研究生三年的学习生涯即将结束，三年来我身边一直有很多默默帮助、关心、引导、激励我的人，对此我心中充满了感谢。

首先要感谢我的导师张彤老师。在我攻读硕士研究生期间，张老师引导我学习了很多专业技能知识。在论文写作期间，张老师也花了很多精力帮助和指导我论文写作。在生活上，张老师对我们关怀备至，让人感念至深。张老师学识渊博、思想敏锐、敢于创新，他对我的学习和生活产生了重要影响，是我终生学习的榜样。在此谨向张老师表示我最诚挚的敬意和感谢！

由衷感谢图像所首照宇、莫建文、欧阳宁、陈利霞、袁华老师三年来对我学习和生活上的帮助。

同时，我要感谢实验室一同学习的师兄师姐们：陈凡、曹鹏、高于、曾梦平等，你们在学习生活上的指导和关心让我在研究生三年期间少走了许多弯路，谢谢你们！

感谢一直关心与支持我的同学和朋友们！我的舍友，陈厚锦、陈综艺、葛文成，感谢你们的鼓励和帮助。我的同门，刘阿康、田浩、刘力元、杨晓青、朱婷、黄慧领，感谢你们的关心和照顾。我的师弟师妹，李月、宋晨菲、王少辉、李佳雨、梁婷、程夏威，感谢你们在工作生活上给我的帮助，你们使我度过了愉快而充实的研究生生涯。

在此要感谢我生活学习了三年的母校——桂林电子科技大学，母校给了我一个宽阔的学习平台，让我不断吸取新知识，充实自己。

感谢我的父母，父母的养育之恩无以为报，他们对我无私的爱与照顾是我不断前进的动力。

特别感谢为本论文送审、评阅和答辩付出了辛勤劳动的各位专家和老师们！

作者在攻读硕士期间主要研究成果

- [1] 张彤,冯磊. 移动机器人地面目标导航定位仿真研究[J]. 计算机仿真 (中文核心, 已录用)
- [2] Zhang Tong, Feng Lei, Li Yue, Chen fei Song. Research of SLAM data association algorithm[J]. 2018 2nd International Conference on Innovation in Artificial Intelligence (ICIAI 2018) (EI 检索会议, 已录用)